

Alten *Labs*

ESPORTS TWIN

VoiceCom Analysis
Speech Emotion Recognition

Bilan Scientifique et Technique

Stagiaire Ingénieur
Arthur BERNEL

Pilote Innovation
Sébastien RICCIARDI & Manuel CARVALHO

Du 09/03/2026 au 11/09/2026

Sensitivity: C1-Internal

Table des matières

Glossaire ---- ***4***

Table des illustrations ---- ***6***

1. Contexte applicatif et objectif technique ---- ***7***

1.1 Contexte général ---- **7**

1.2 Contexte technique ---- **8**

1.3 Difficulté et objectif technique ---- **8**

1.3.1 Détection des émotions dans un environnement vocal bruité ---- 8
1.3.2 Absence de base de données émotionnelles spécifique à l'eSport ---- 8
1.3.3 Modèle émotionnel ---- 9
1.3.4 Exploitation temporelle de l'émotion ---- 9

2. Synthèse critique de l'état de l'art ---- ***11***

2.1 Théorie des émotions ---- **11**

2.1.1 Ekman ---- 11
2.1.2 Plutchik ---- 12
2.1.3 Russell ---- 14
2.1.4 Conclusion ---- 16

2.2 Dataset ---- **16**

2.2.1 RAVDESS ---- 16
2.2.2 Toronto Emotional Speech Set Data (TESS) ---- 17
2.2.3 MSP-Podcast ---- 17

2.3 Approches techniques de la reconnaissance vocale des émotions ---- **18**

2.3.1 Extraction des caractéristiques ---- 18
2.3.2 Méthode de classification des émotions ---- 18

2.4 Emotion dans l'eSports ---- **19**

2.4.1 Reconnaissance des émotions appliquée à l'eSport ---- 19
2.4.2 Rôle des émotions sur la performance et leur régulation ---- 20

3. Problématique scientifique ---- ***21***

3.1 Formulation du sujet de recherche ---- **21**

3.2 Verrous et/ou incertitudes techniques et scientifiques ---- **21**

4. Démarche et travaux réalisés ---- ***23***

4.1 Protocole de Labélisation ---- **23**

4.1.1 Objectif et choix méthodologique ---- 23
4.1.2 Fondement théorique : le modèle PAD ---- 23
4.1.3 Phase de calibration des annotateurs ---- 24
4.1.4 Procédure d'annotation ---- 24
4.1.5 Structuration et export des données annotées ---- 26
4.1.6 Contrôle qualité et gestion de la subjectivité ---- 27
4.1.7 Limites et discussion ---- 27

4.2 Extraction des features ---- **27**

4.2.1 Features interprétables ---- 27
4.2.2 Features d'entrée du modèle ---- 29

Sensitivity: C1-Internal

4.3 Modèle ---- 34
4.3.1 Choix méthodologique ---- 34
4.3.2 Modèle utilisé ---- 35
4.3.3 Sauvegarde ---- 35
4.3.4 Limites ---- 35

4.4 Prédiction ---- 36
4.4.1 Objectif de la comparaison ---- 36
4.4.2 Résultats attendus ---- 36
4.4.3 Meilleur scénario envisageable ---- 37

5. Analyse des résultats et interprétations ---- 38

5.1 Résultat annotation manuelle ---- 38
5.1.1 Résultat transcription ---- 38
5.1.2 Résultat PAD ---- 39
5.1.3 Attribution des émotions et interprétation ---- 41

5.2 Résultat annotation automatique ---- 44
5.2.1 Résultats PAD ---- 44
5.2.2 Comparaison différentielle ---- 46

5.3 Features interprétables ---- 48
5.3.1 Résultats Factuels ---- 48
5.3.2 Comparaison avec l'évolution du match ---- 50

6. Conclusion ---- 53

7. Ressources humaines ---- 54

Bibliographie ---- 55

Annexe ---- 58

Sensitivity: C1-Internal

Glossaire

L'eSport : Compétition électronique sur des jeux vidéo en multijoueur.

LoL : League of Legends

SER : Speech Emotions Recognition (Reconnaissance des émotions par la voix)

In-game : Action dans la partie jouée

Dataset : un dataset est un ensemble de données, organisées et stockées à des fins d'analyse ou de traitement

Le tilt : un état émotionnel d'indignation et de frustration qui perturbe la prise de décision

La valence : mesure le plaisir ou le déplaisir d'un état émotionnel, il juge la positivité de l'émotion

L'activation : mesure l'excitation ou le calme d'un état émotionnel, il juge l'intensité de l'émotion

La dominance : mesure le control ou la soumission d'un état émotionnel, il juge la dominance de l'émotion

Un modèle psycho-évolutionnaire : modèle utilisant la théorie de l'évolution pour mieux comprendre le comportement humain

Un espace latent : un espace de représentation réduit qui capture les informations importantes des données

Une feature : C'est une donnée informative extraite d'un signal grâce à différentes méthodes mathématiques

MFCC : Mel Frequency Cepstral Coefficients (voir Annexe)

LPCC : Linear Predictive Cepstral Coefficients (voir Annexe)

Un formant : pics d'énergie dans le spectre de la parole correspondant aux résonances du conduit vocal

Baseline : méthode ou un résultat de référence utilisé pour comparer et évaluer les performances d'un modèle ou d'une approche plus avancée

Machine learning : domaine IA qui permet à un modèle d'apprendre automatiquement à partir de données pour effectuer une tâche sans être explicitement programmé.

Deep learning : Une technique d'IA qui apprend à partir de grandes quantités de données grâce à des réseaux de neurones

Transformer : architecture de deep learning basée sur le mécanisme d'attention

Tête de régression : dernière couche d'un modèle qui prédit une ou plusieurs valeurs numériques continue

Backbone (colonne vertébrale) : le réseau de neurones principal qui extrait les caractéristiques importantes des données

Sensitivity: C1-Internal

Fine-tuning : consiste à réentraîner un modèle déjà pré-entraîné sur un dataset spécifique afin de l'adapter à une tâche précise

Un embedding : une représentation de données numériques dans un espace vectoriel à plusieurs dimensions

Pré-game : phase avant la partie jouée

Early game : phase de début de partie, ou il n'y a généralement pas d'action forte

Midgame : phase intermédiaire de partie, où les premières rotations, teamfights et prises d'objectifs deviennent plus importantes.

Endgame : phase finale de partie, ou les décisions ont un impact direct sur l'issue de la partie

Pooling : Technique de moyennage de plusieurs données afin d'en extraire une seule

Sensitivity: C1-Internal

Table des illustrations

Figure 1 : Roue de Plutchik 12
Figure 2 : Cône de Plutchik 13
Figure 3 : Circumplex Model of Affect 14
Figure 4 : Model PAD 15
Figure 5 : Grille PAD - Emotions....24
Figure 6 : Interface d'annotation 25
Figure 7 : Pipeline d'extraction des features Wav2Vec2 31
Figure 8 : Couche 1 Conv1D 32
Figure 9 : Couche 2 Conv1D 32
Figure 10 : Détail d'une couche Transformer 33
Figure 11 : Pipeline de la tête de régression PAD....35
Figure 12 : Résultats de la transcription sur l'ensemble 1er game 38
Figure 13 : Résultats de la transcription sur les données annotables 1er game 38
Figure 14 : Evolution du Plaisir 1ère game 39
Figure 15 : Evolution de l'Activation 1ère game 40
Figure 16 : Evolution de la Dominance 1ère game 40
Figure 17 : Emotions Pré-game....41
Figure 18 : Emotions Earlygame 42
Figure 19 : Emotions Midgame....42
Figure 20 : Emotion Endgame 43
Figure 21 : Evolution du Plaisir entre l'annotation manuelle et automatique 1ère game 44
Figure 22 : Evolution de l'Activation entre l'annotation manuelle et automatique 1ère game...45
Figure 23 : Evolution de la Dominance entre l'annotation manuelle et automatique 1ère game 46
Figure 24 : Quantité de différences significatives du Plaisir 47
Figure 25 : Quantité de différences significatives de l'Activation 47
Figure 26 : Quantité de différences significatives de Dominance....47
Figure 27 : Distribution des features acoustiques par joueur 48
Figure 28 : RMS au cours du match 50
Figure 29 : Fréquence au cours du match....51
Figure 30 : Jitter au cours du match 51
Figure 31 : Durée entre les segments audios au cours du match....52
Figure 32 : Construction des MFCCs....58
Figure 33 : Construction des LPCCs 58

Sensitivity: C1-Internal

1. Contexte applicatif et objectif technique

1.1 Contexte général

Le monde de *l'eSport* s'est fortement démocratisé au cours des dernières années. Les tournois majeurs de certains jeux sont devenus des phénomènes de société n'ayant rien à envier, en popularité comme en visibilité, aux sports conventionnels. Au nombre de ces compétitions prestigieuses, nous pouvons citer l'ELEAGUE, tournoi majeur de CS:GO (Counter Strike Global Offensive), ayant regrouper 1 400 000 de visionnages pour la somme de 1 000 000€ à gagner en 2017, ou encore le championnat du monde de Fortnite, qui fut visionné par 2 500 000 de téléspectateurs désireux de voir qui se fera la part belle dans les 30 000 000€ de prix.

Mais en dépit de ce palmarès prestigieux, un jeu reste maître dans le domaine de *l'eSport* : League of Legends. Culminant à 7 000 000 de spectateurs pour son championnat du monde promettant des récompenses de plusieurs millions, il est la tête de proue du domaine. C'est avec cet essor de popularité que *l'eSport* connu également un essor de professionnalisation. En son centre, des coachs et entraineurs, ayant un besoin perpétuel de données pertinentes. Que cela soit pour l'entrainement, la mise en place de stratégie, le développement de structure, la data s'est révélée un élément clé pour travailler.

Ces informations essentielles sont le plus souvent des données techniques de la partie en elle-même, c'est-à-dire des données sur le jeu et les performances de chaque joueur dans le jeu mais sont rarement des données sur les joueurs eux même. Pourtant, comme dans de nombreux jeux professionnels, la préparation des joueurs avant la compétition est primordiale pour les préparer à endurer le stress, la panique ou bien encore l'exaltation. Pour pouvoir préparer au mieux les joueurs, les données vocales sont la porte d'entrée des ressenties des joueurs dans le match et de mieux comprendre leurs émotions. Cependant, ce travail d'analyse vocale des matchs est un travail fastidieux, qui demande beaucoup de temps et de concentration. De plus, l'analyse des émotions est subjective à chacun et est très peu développée dans le milieu de *l'eSport*. C'est pourquoi, nous nous demandons si cela serait possible d'automatiser l'analyse vocal des parties de *LoL* afin d'en saisir les émotions des joueurs au cours de la partie.

Avec pour ambition de promouvoir la marque Alten, l'entreprise s'est associée avec l'équipe *eSport* de Lille, Lille eSport. Créée en 2021, cette équipe française joue dans l'ancienne division 2 de LFL (ligue française de League of Legends), la Nexus Ligue. Cette ligue regroupe 8 équipes et dispute des matchs tous les weekends durant chaque saison. Les objectifs de Lille eSport sont clairs, monter en première ligue de la LFL. Pour ce faire, ils ont appelé Alten afin d'apporter une expertise technique dans la récupération et l'analyse des datas des différentes parties. L'idée est simple ; ils veulent avoir un outil pratique qui leur permet de voir concrètement et facilement les erreurs et défauts des parties afin de s'améliorer durablement.

Sensitivity: C1-Internal

1.2 Contexte technique

Cette analyse des émotions par la voix s'inscrit dans le domaine scientifique *SER* (Speech Emotion Recognition) et se base sur les éléments prosodiques de la voix (timbre, hauteur, intensité, etc). Mais, pour pouvoir être plus précis dans la reconnaissance des émotions, une approche multimodale serait la solution la plus pertinente. Cependant, seule l'analyse prosodique est prise en compte dans l'état actuel des travaux.

1.3 Difficulté et objectif technique

1.3.1 Détection des émotions dans un environnement vocal bruité

Contexte :

Les modèles *SER* traditionnels sont généralement entrainés sur des données contrôlées (RAVDESS par exemple), ces jeux de données sont réalisés par des acteurs qui jouent des émotions précises avec de l'entrainement et avec une grande précision dans l'intonation de la voix.

Contrairement à notre jeu de données, ou nous pouvons retrouver du bruit *in-game*, des bruits parasites extérieurs (clavier, souris, microphones), des différences de qualité audio (si un joueur est plus ou moins loin du micro) ou encore des chevauchements de plusieurs locuteurs malgré le prétraitement réalisé. De plus les joueurs ne sont pas des acteurs et vivent réellement les émotions qu'ils traduisent.

Difficulté :

Pour notre cas d'étude, les indices émotionnels sont souvent faibles comparés au bruit présent dans le signal. Par exemple, un joueur frustré et un joueur neutre peuvent présenter des caractéristiques acoustiques similaires lorsque la communication est parasitée. Donc la difficulté sera de bien choisir les audios et les méthodes d'encodage pour avoir une bonne précision.

Objectif :

Obtenir une précision supérieure à 70% sur plusieurs classes émotionnelles malgré la dégradation du signal

1.3.2 Absence de base de données émotionnelles spécifique à l'eSport

Contexte :

Malgré certaines bases de données conséquentes et non jouées par des acteurs, le cas spécifiques au jeu vidéo et plus précisément à League of Legends rajoute une difficulté supplémentaire. Car les données existantes dans le domaine sont généralement des données issues de contextes plus ou moins généraux pour pouvoir capter le plus de nuance possible et adaptable à plusieurs cas de figure. Les locuteurs sont en plus, généralement tous issues de la même culture, s'exprimant dans la même langue et ne rencontrent donc aucunes difficultés à se comprendre.

Sensitivity: C1-Internal

Alors que notre jeu de données est complexe, avec des termes techniques et très spécifiques à *LoL*. De plus, les joueurs sont issus de culture différentes (occidentale et orientale) et doivent s'exprimer en anglais, qui n'est pas leur langue maternelle.

Difficulté :

Les émotions exprimées dans *l'eSport* diffèrent fortement des émotions des corpus académiques. Pour cela, créer un *dataset* d'entrainement est la solution la plus performante à notre cas. Donc, la difficulté est de créer un protocole de labellisation précis et flexible tout en aillant le plus de fiabilité possible vis-à-vis de la complexité du contexte et au vu des données utilisées.

Objectif :

Construire un système d'annotation performant et adapté à notre jeu de données afin de créer un *dataset* utile à l'entrainement et à l'évaluation du modèle.

1.3.3 Modèle émotionnel

Contexte :

Certaine étude existe pour essayer de classer les émotions et les différentier entre elles afin de pouvoir les identifier plus facilement. Car, différentier émotion et ressenti est déjà une question complexe que les psychologues, philosophe ou encore les anthropologues cherchent à définir pour mieux appréhender les comportements humains. Dans le contexte de compétitions *eSport*, la reconnaissance d'une même émotion peut varier d'un joueur à l'autre, d'une situation à une autre et énormément de facteurs sont à prendre en compte, ce qui rend une classification des émotions très compliquée.

De plus, la nuance des émotions dites « de bases » est beaucoup plus importante dans le milieu compétitif car une émotion simple comme la colère peut se décliner de plein de manière différente comme le *tilt*, la rage, l'agacement, etc…

Difficulté :

Les émotions exprimées ne pourront donc pas être catégoriser simplement par des mots figés dont même les définitions peuvent prêter à différentes interprétations. La difficulté est donc de trouver un modèle émotionnel exploitable dans notre cas qui permet de prendre en compte le plus possible d'émotion, sans avoir à faire de compromis entre choisir une émotion car aucune de convient, ou plusieurs à la fois car certaines émotions se mélangent entre elles.

Objectif :

Trouver un modèle émotionnel qui nous permet de mieux comprendre les émotions des joueurs et de pouvoir les classer clairement.

1.3.4 Exploitation temporelle de l'émotion

Contexte :

Les *games* de *LoL* durent en générale autour des 40min, ce qui laisse beaucoup d'état émotionnel évoluer au cours du temps. Chaque joueur évolue différemment dans la partie et réagit différemment aux événements de celle-ci. Cependant, nos données d'entrées se contentent seulement de prendre en compte quelques secondes isolées du match, perdant

Sensitivity: C1-Internal

donc le contexte global du match et de son évolution. Ce qui peut conduire à mauvaise interprétation de certaine émotion dû aux évènements précédents non pris en compte.

Difficulté :

La difficulté est donc de prendre en compte tous les segments audios au cours du temps, et de garder en mémoire l'évolution de ceux-ci afin de mieux comprendre les suivant.

Objectif :

Adapter la manière d'annoter les données pour prendre en compte les données précédemment annotées pour que l'évolution de ceux-ci soit la plus cohérente possible.

Sensitivity: C1-Internal

2. Synthèse critique de l'état de l'art

L'état de l'art a été structuré selon quatre axes afin de couvrir l'ensemble des verrous scientifiques et techniques liés au développement d'un système de reconnaissance automatique des émotions vocales dans un contexte *eSportif*. Ces axes portent respectivement sur les modèles théoriques de l'émotion, les bases de données existantes dans ce domaine, l'approche techniques de la SER et les travaux spécifiquement liés à *l'eSport*. Cette organisation vise à dépasser une analyse purement descriptive des solutions existantes en identifiant, pour chaque famille de travaux, leur contexte d'application, leurs objectifs, leur apport potentiel au projet, ainsi que leurs limites dans le cadre particulier de communications vocales issues de parties de League of Legends. Elle permet ainsi de faire apparaître l'écart entre les conditions expérimentales généralement étudiées dans la littérature et les contraintes rencontrées dans un environnement réel de jeu compétitif : bruit, spontanéité de la parole, variabilité inter-joueurs, émotions mixtes, temporalité de la partie et manque de bases de données spécialisées.

2.1 Théorie des émotions

Dans notre étude, nous cherchons une solution technique à un problème en partie psychologique, ce qui ne peut pas être résolu simplement par une division binaire des émotions, comme on pourrait faire pour de la séparation des voix entre locuteurs (qui parle quand). Car nous voulons savoir comment caractériser ces émotions et comment les classer dans notre contexte *eSports*. En effet, définir une émotion n'est pas chose aisée, la simple définition d'une émotion ne peut pas nous donner la manière de la percevoir ou de l'identifier clairement. De plus, certaines émotions ne sont pas comprises de la même manière entre les individus et les cultures, ce qui pose un problème si l'on veut faire de l'identification avec un seul modèle. Enfin, les dénominations des émotions ne sont pas globales et intrinsèques, elles sont variables entre elles et peuvent même se croiser entre émotions, par exemple une même expérience peut être classée sous plusieurs émotions proches et leurs catégories peuvent se chevaucher. Ce qui pose une réelle question de savoir comment classer les émotions vis-à-vis des données audios réalistes que nous avons. Ce domaine d'étude s'inscrit davantage dans une démarche anthropologique et psychologique, qu'une étude technique d'ingénierie. C'est encore un domaine actif et toujours en évolution.

2.1.1 Ekman

Tout d'abord, une première étude menée par **Paul Ekman** dans les années 1970 [2] montre qu'il existe un nombre limité d'émotions fondamentales, universelles, reconnaissables par tous et associées à des expressions faciales spécifiques. Ces émotions incluent : la colère, la tristesse, la peur, le dégoût, la joie et la surprise, et sont considérées comme une base biologique innée [3], [4].

Par la suite, **Paul Ekman** (1992) [5] précise que ces émotions ont émergé au cours de l'évolution pour leur valeur adaptative, permettant une réponse rapide et efficace face à des situations vitales pour l'individu. Elles se caractérisent par une apparition rapide, une durée brève et un

Sensitivity: C1-Internal

déclenchement souvent automatique, reposant sur des mécanismes d'évaluation largement non conscients.

Chaque émotion se distingue également par des profils physiologiques et des contextes déclencheurs spécifiques, tout en partageant des propriétés communes qui les différencient d'autres états affectifs, tels que les humeurs ou les traits émotionnels. Ces catégories constituent ainsi une base théorique largement adoptée pour l'analyse émotionnelle, en particulier dans l'étude des liens entre cognition, émotion et comportement.

Forces :

- L'aspect universel des émotions primaires permet de s'assurer d'une certaine base émotionnelle entre culture
- Base de nombreuses études scientifiques sur le sujet
- Le lien de causalité entre émotion et comportement est directement lié au contexte
- La définition d'un panel d'émotions primaires assez significatif

Limites :

- Ses études se limitent aux expressions faciales et ne concernent pas les émotions vocales
- Le manque de diversité d'émotions ne permet pas de couvrir l'ensemble des états émotionnels
- Un manque de classification entre ces émotions primaires pour ensuite les distinguer

2.1.2 Plutchik

Robert Plutchik (1980) [6] propose un modèle psycho-évolutionnaire dans lequel les émotions complexes émergent à partir de combinaisons d'émotions primaires organisées selon des relations d'opposition et de proximité. Représentées sous la forme d'une roue (cf : Figure 1: Roue de Plutchik), ces émotions sont structurées en paires de pôles opposés (par exemple joie–tristesse, confiance–dégoût), ce qui confère au modèle une forte valeur explicative tant sur le plan théorique que méthodologique.

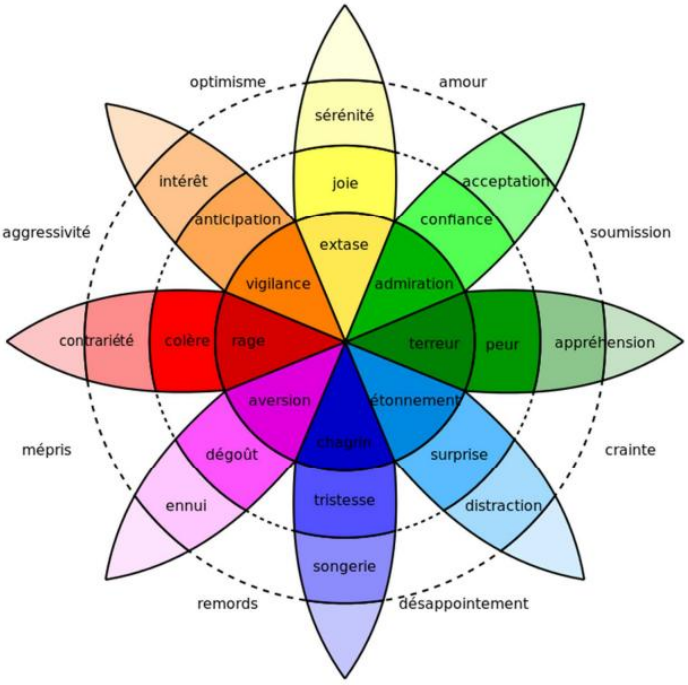


Figure 1 : Roue de Plutchik

Sensitivity: C1-Internal

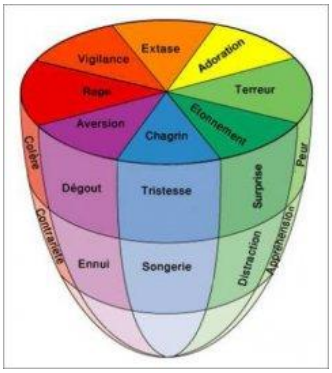


Figure 2 : Cône de Plutchik

De plus, cette roue peut être représentée sous la forme d'un cône en 3D (cf : Figure 2), car chaque émotion possède une intensité propre. Par exemple, pour la colère, l'intensité la plus élevée correspond à la rage, tandis que l'intensité la plus faible correspond à l'agacement.

Cette approche légitime conceptuellement la représentation des émotions secondaires comme des constructions dynamiques issues d'émotions primaires. Dans le domaine de l'analyse automatique des émotions, cette structuration a notamment été exploitée par **Mondal et Gokhale** (2020) [7], qui montrent que l'organisation en paires d'émotions opposées issue de la roue de Plutchik se prête naturellement à des problèmes de classification binaire, facilitant ainsi la détection émotionnelle dans les textes.

Leurs résultats soulignent toutefois que, malgré leur opposition théorique, certaines paires émotionnelles sont inégalement discriminables en pratique, ce qui met en évidence la complexité cognitive et contextuelle des émotions secondaires.

Forces :

- La classification d'émotion par opposition permet de structurer les émotions entre elles à partir de leur parité
- L'intensité des émotions permet de graduer les émotions afin de découper les émotions primaires en familles d'émotion à partir d'un paramètre : l'intensité
- L'association des émotions primaires permet de créer des nouvelles émotions, émotions secondaires, qui élargit le panel d'émotion définit
- La construction dynamique des émotions, comme celui des couleurs, permet de créer de nouvelle émotion qui ne serait pas définit avec des dénominations existantes

Limites :

- Manque de clarté sur les éléments de comparaison pour des émotions secondaires
- Manque de flexibilité entre les émotions primaires, car une émotion ne se définit pas seulement à sa définition mais aussi par son contexte
- Cloisonnement des émotions entre elles, ce qui ne permet pas facilement de comprendre comment passer d'une émotion à une autre

Sensitivity: C1-Internal

2.1.3 Russell

Les modèles dimensionnels, tels que le modèle PAD développé par **Albert Mehrabian et James A. Russell** (1977) [8], décrivent les états émotionnels selon des axes continus, avec **la Valence** (plaisir/déplaisir), **l'Activation** (niveau d'excitation) et **la Dominance** (sentiment de contrôle).

En 1980, **James A. Russell** propose d'avoir une continuité dans le classement des émotions. Il va montrer qu'elles peuvent toutes se trouver dans un même espace à 2D (valence-arousal), il l'appelle le **Circumplex Model of Affect** [9] (cf : Figure 3: Circumplex Model of Affect).

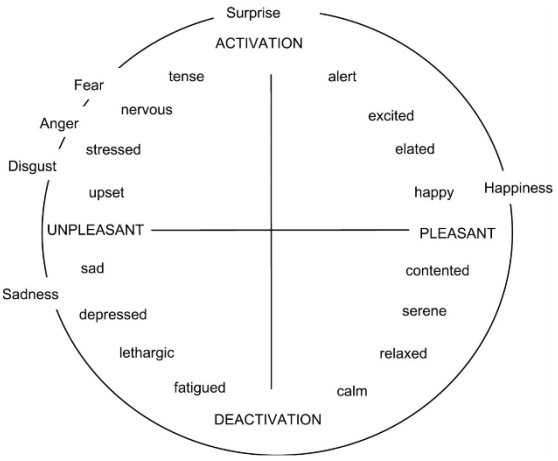


Figure 3 : Circumplex Model of Affect

Dans le modèle PAD, les émotions jouent un rôle médiateur entre les stimuli environnementaux et les comportements, orientant les réponses d'approche ou d'évitement. Ces cadres théoriques permettent ainsi de rendre compte des proximités et des transitions graduelles entre les états affectifs, plutôt que de frontières catégorielles strictes. Ils soutiennent également l'idée que les émotions se déploient selon des axes dynamiques, sensibles au contexte ainsi qu'aux variations cognitives et environnementales.

Les travaux en linguistique pragmatique de **Kerbrat-Orecchioni** (2000) [10] soulignent que les termes émotionnels employés dans le discours ne reflètent pas nécessairement l'émotion réellement ressentie par le locuteur. Comme elle l'établit, les émotions procèdent à la fois des mots de la langue, de la manière de s'exprimer et de la réalité de la situation de communication. Le sens émotionnel d'un énoncé se construit ainsi au sein de l'interaction, en fonction du contexte et des intentions communicatives.

Dans la continuité de cette réflexion, **Plantin** (2020) [11], distingue les véritables termes d'émotion, qui nomment directement un état affectif, des mots à orientation émotionnelle, dont la dimension émotionnelle dépend surtout du contexte dans lequel ils sont utilisés. Cette distinction est particulièrement visible dans le langage familier. Par exemple, le terme « dégoûté » est souvent employé pour exprimer une déception ou une frustration, sans pour autant renvoyer à l'émotion de dégoût au sens strict. **Plantin** souligne également que les émotions ne sont pas de simples réactions automatiques à une situation. Elles peuvent être expliquées, justifiées ou discutées dans l'échange. Ainsi, les émotions sont envisagées comme des constructions cognitives et linguistiques dont le sens se construit et se négocie au cours des interactions.

Cette variabilité sémantique rend nécessaire une analyse contextuelle approfondie, prenant en compte non seulement le lexique, mais également les implicites, les dynamiques interactionnelles et l'ensemble des choix discursifs du locuteur. Elle justifie également le recours à un espace de représentation continu plutôt qu'à un ensemble de catégories discrètes.

Sensitivity: C1-Internal

À cet égard, les travaux de **Belaref et al.** [12], [13] apportent un éclairage décisif. Partant du constat que les modèles catégoriels, comme celui d'**Ekman**, offrent une granularité insuffisante pour rendre compte de la richesse des états affectifs, ils s'appuient sur le modèle circulaire de **Russell**, qui organise les émotions dans un espace continu selon deux axes : la valence (négatif à positif) et l'arousal (de calme à excité). Leurs résultats montrent qu'une approche multimodale permet de retrouver automatiquement cette structure circulaire, démontrant ainsi que l'organisation dimensionnelle des émotions est intrinsèquement encodée dans les *espaces latents* (cf : Figure 4) appris, et non un simple artefact du processus d'annotation humaine.

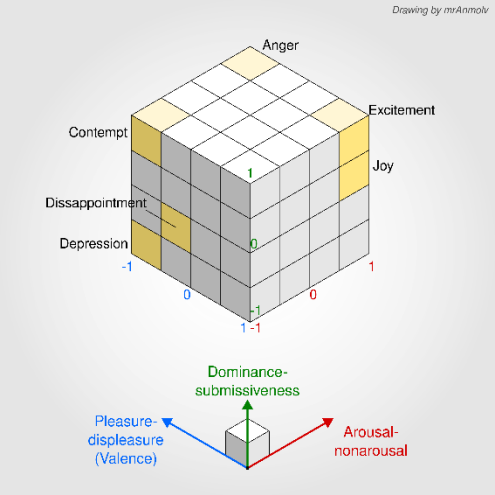


Figure 4 : Model PAD

Forces :

- Les émotions se différencient par un score à seulement 3 critères
- Le score PAD est un score interprétable par l'humain et applicable à l'ensemble des émotions afin de les catégoriser
- Ce score s'inscrit dans un *espace latent* qui permet de mieux appréhender la continuité des émotions entre elles et leur flexibilité vis-à-vis de l'interprétabilité.
- Ce modèle est exploitable dans un contexte technique car il limite le biais de subjectivité à 3 critères et permet d'utiliser des modèles mathématiques pour placer et reconnaitre des émotions.

Limites :

- Difficulté d'attribution du score, car même si les critères sont clairs, il peut être difficile de différencier des valeurs très proches.
- Malgré la limitation de la subjectivité à 3 critères, ce biais reste néanmoins présent et peut biaiser l'interprétabilité.
- Certains scores ne sont pas qualifiables dans le lexique émotionnel car certain mot n'existe tout simplement pas, donc difficulté d'explicabilité.
- Au contraire, un mot émotionnel peut être attribué à plusieurs score à la fois, dû à leur nombreuse définition, donc il ne suffit pas de répondre par des mots mais aussi par un contexte.

Sensitivity: C1-Internal

2.1.4 Conclusion

S'inscrivant dans notre perspective d'une annotation simple mais précise, nous retiendrons pour notre étude une approche fondée sur le modèle **PAD** (Plaisir–Activation–Dominance), qui étend le modèle de **Russell** en ajoutant une troisième dimension, la dominance, permettant de capturer des nuances supplémentaires telles que le sentiment de contrôle ou de soumission face à une situation [14]. Ce modèle tridimensionnel permettra d'attribuer à chaque échantillon audio trois scores compris entre -1 et 1, positionnant ainsi chaque donnée dans un *espace latent* émotionnel continu et interprétable.

2.2 Dataset

Il existe une multitude de dataset sur le sujet mais avec des manières différentes d'annotation, de création et d'enregistrement. Pour ce faire, nous avions besoin de classer les différents *dataset* existants avant de pouvoir réellement les exploiter. C'est pour cela, que nous nous sommes basés sur une liste référençant tous les *dataset* produit sur le sujet, depuis 1997, avec chacun leurs caractéristiques propres [15]. Nous avons choisi 3 *dataset* différents pour entrainer nos modèles afin de voir lesquels est le plus pertinent par rapport à notre jeu de données.

2.2.1 RAVDESS

Ce *dataset* est composé de 1440 fichiers audios issus de 24 acteurs nord-américain différents (12 femmes et 12 hommes) donc 60 fichiers audios par acteur, il est en libre accès pour toute utilisation sauf commerciale. Il se base sur 8 émotions distinctes : Calme, Joie, Tristesse, Colère, Peur, Surprise, Dégout et l'état Neutre. Tous les audios ont été enregistrés avec une bonne qualité audio dans un environnement adapté [16].

Forces :

- Ce *dataset* permet d'avoir un large panel différent de personne pour avoir des voix différentes
- Ce *dataset* est en anglais pour garder la similarité de la langue
- Il est annoté de façon claire sur 8 émotions précises

Limites :

- Peu d'audio par acteur (que 60) pour avoir une bonne analyse des émotions global
- Aucune hétérogénéité du *dataset*, tous les acteurs sont issus de la même culture/langue
- Amplification des émotions jouées car produites par des acteurs
- Le peu d'émotions différentes jouées ne couvre pas l'ensemble du spectre émotionnel

Sensitivity: C1-Internal

2.2.2 Toronto Emotional Speech Set Data (TESS)

Ce *dataset* est composé de 2800 fichiers audios issus de 2 actrices anglophones différentes. Chacune des actrices a 200 mots différents à prononcer pour chacune des 7 émotions prédéfinies : Colère, Dégout, Peur, Joie, Neutre, Tristesse et Surprise. Tous les audios ont été enregistrés avec une bonne qualité audio dans un environnement adapté [17].

Forces :

- Ce *dataset* permet d'avoir beaucoup de données différentes issues de mots différents
- Ce *dataset* est en anglais pour garder la similarité de la langue
- Il est annoté de façon claire sur 7 émotions précises

Limites :

- Il ne comporte pas beaucoup d'actrices différentes et ne contient aucun homme
- Aucune hétérogénéité du *dataset*, tous les acteurs sont issus de la même culture/langue
- Amplification des émotions jouées car produites par des acteurs
- Le peu d'émotions différentes jouées ne couvre pas l'ensemble du spectre émotionnel

2.2.3 MSP-Podcast

Ce *dataset* est différent des précédents. Les locuteurs ne sont plus des acteurs jouant des émotions prédéfinies mais des personnes interagissant entre elles dans un contexte de podcast anglophone et en ressentant de réel état émotionnel vis-à-vis d'un contexte. Il y a au total 151 654 audios annotés que nous exploiterons par la suite. L'annotation des audios a été faite selon un protocole strict avec différent annotateur pour réduire le biais de subjectivité sur l'interprétabilité des émotions. De plus, l'annotation s'est faite avec le modèle PAD de Russell qui attribue un score entre 1 et 7 sur les critères de Plaisir, Activation et Dominance. Puis, à partir de ce score, une émotion proche est déduite entre : Colère, Tristesse, Joie, Surprise, Peur, Dégout, Content, Neutre, Autre (une autre liste exhaustive d'émotions) et non Attribuable [18].

Forces :

- Beaucoup de données différentes issues de mots différents, de personnes différentes et de contextes variés
- Ce *dataset* est en anglais pour garder la similarité de la langue
- Annotation claire sur 3 critères émotionnels afin d'avoir beaucoup d'émotion possible différente
- Une grande quantité d'annotateur a permis d'éliminer le plus possible, le biais de subjectivité d'interprétabilité des émotions

Sensitivity: C1-Internal

Limites :

- Aucune hétérogénéité du *dataset*, tous les acteurs sont issus de la même culture/langue
- Contexte de podcast avec des sujets généraux mais différent de notre contexte de *LoL* avec un vocabulaire spécifique

2.3 Approches techniques de la reconnaissance vocale des émotions

2.3.1 Extraction des caractéristiques

Deux grandes approches coexistent dans la littérature *SER* pour transformer le signal vocal brut en une représentation exploitable par un modèle : **l'extraction de *features* acoustiques**, construites manuellement ou via des outils standardisés, et **l'apprentissage de représentations profondes** par des modèles auto-supervisés.

Les *features* manuelles reposent sur des grandeurs physiques directement interprétables. Elles peuvent être regroupées en trois familles complémentaires : **des *features* temporelles** (dynamique et énergie du signal), **des *features* fréquentielles** (répartition spectrale), et **des *features* de qualité vocale** (stabilité et régularité de la voix). Parmi les plus utilisées, les *MFCC* offrent une représentation compacte et standardisée de la forme globale du spectre vocal [18], [19], tandis que les *LPC/LPCC*, fondés sur un modèle physique de production de la parole, apportent une information complémentaire liée aux *formants* [21]. D'autres descripteurs globaux énergétiques (RMS, enveloppe d'amplitude), spectraux (centroïde, bande passante, flatness, contraste, rolloff [22], [23], [24], [25]), ou de qualité vocale (HNR [26], jitter, shimmer [27], [28], F0 estimée par l'algorithme YIN [29]) permettent de couvrir un spectre plus large de dimensions acoustiques. Ces *features* restent toutefois fortement dépendantes du protocole d'extraction et des conditions d'enregistrement, ce qui limite leur robustesse sur des communications courtes, bruitées ou avec voix superposées.

Pour dépasser cette limite tout en conservant l'interprétabilité, des outils standardisés comme **OpenSMILE** ont été développés [30]. L'ensemble **eGeMAPS** propose notamment 88 descripteurs sélectionnés pour leur pertinence perceptive et leur robustesse [31], ce qui en fait une référence largement utilisée comme *baseline* dans la littérature *SER*.

À l'opposé de ces approches manuelles, les modèles auto-supervisés comme **Wav2Vec2-large** apprennent directement une représentation du signal audio brut, sans définition a priori des descripteurs à extraire [1], [32]. Pré-entraînés sur de grandes quantités de parole non annotée, ces modèles capturent des informations acoustiques, prosodiques et contextuelles plus riches, au prix d'une perte d'interprétabilité et d'un coût computationnel plus élevé.

2.3.2 Méthode de classification des émotions

Plusieurs approches sont mobilisées dans la littérature pour prédire une émotion à partir des *features* extraites. Les méthodes classiques de *machine learning*, telles que les **SVM** ou le

Sensitivity: C1-Internal

XGBoost, s'appuient sur des *features* acoustiques extraites manuellement ou via des outils standardisés comme **eGeMAPS**. Elles présentent l'avantage d'être efficaces avec peu de données annotées, peu coûteuses en calcul et facilement interprétables [33], [34], mais restent dépendantes de la qualité des *features* en amont et ne capturent pas les dépendances temporelles du signal vocal.

Les **CNN** (Convolutional Neural Network) appliqués sur ces mêmes *features* constituent une approche intermédiaire, capable d'apprendre des combinaisons non linéaires entre descripteurs, au prix d'une perte d'information temporelle fine et d'une dépendance plus forte au volume de données disponible [35], [36].

À l'inverse, les modèles de type **Wav2Vec2** encodent directement le signal audio brut à l'aide de couches convolutives puis d'un *Transformer*, capturant le contexte global grâce au mécanisme d'attention, avant qu'une couche de classification légère ne prédise l'émotion [1], [32]. Cette approche permet de mieux généraliser à des émotions subtiles, au prix d'une interprétabilité plus faible et d'une dépendance forte au volume de données pour entraîner la tête de classification.

2.4 Emotion dans l'eSports

2.4.1 Reconnaissance des émotions appliquée à l'eSport

Abramov et al. ont mené une étude de cas sur un tournoi eSport (Team Fortress 2), en collectant des enregistrements audios et des logs de jeu réels afin d'entraîner un classifieur d'émotions à partir de la voix des joueurs. Ne disposant pas d'émotions annotées sur leurs propres données, les auteurs ont entraîné leur modèle sur un jeu de données public annoté (**RAVDESS**), puis l'ont appliqué à leur corpus *eSport*, atteignant une précision de 92,7 % sur une classification à six classes d'émotions. Les résultats montrent une corrélation forte entre la performance de l'équipe, la fréquence de communication entre joueurs et le ton émotionnel de leurs échanges, les équipes les plus performantes communiquant davantage et de façon plus positive [37].

Forces :

- Validation en conditions réelles de compétition, contrairement à la majorité des études de *SER* menées sur des corpus acted en laboratoire
- Mise en évidence d'un lien mesurable entre émotions vocales et performance d'équipe, ouvrant la voie à des applications concrètes pour le coaching eSport

Limites :

- Absence d'émotions réellement annotées sur le corpus eSport, le classifieur étant entraîné sur un jeu de données externe (**RAVDESS**) puis simplement appliqué aux données du tournoi
- Bruit ambiant important (clavier, souris, discussions parasites) nécessitant l'ajout artificiel de classes de bruit de fond pour rendre le modèle robuste
- Jeu de données d'entrainement (**RAVDESS**) limité et ne peut couvrir toutes les émotions si l'on veut réellement identifier les émotions des joueurs

Sensitivity: C1-Internal

2.4.2 Rôle des émotions sur la performance et leur régulation

La revue systématique de **Beres et al.** synthétise 32 études portant sur le rôle des émotions dans la performance en eSport, ainsi que sur les stratégies de régulation émotionnelle employées par les joueurs. Les auteurs montrent que les émotions positives sont globalement associées à une meilleure performance, tandis que les émotions négatives (colère, frustration) ont un effet plus ambigu, certaines études rapportant même un effet bénéfique de l'anxiété modérée sur la performance. Les joueurs *eSport* ont par ailleurs tendance à privilégier des stratégies d'évitement plutôt que des stratégies de régulation active, notamment en raison du rythme rapide des compétitions qui laisse peu de place à une gestion réfléchie des émotions [38].

Forces :

- Lien entre émotions et performance en *eSport*
- Mise en évidence du besoin d'interventions technologiques pour accompagner les joueurs dans la régulation de leurs émotions, ce qui légitime directement l'intérêt d'un outil de *SER* en contexte *eSport*

Limites :

- Grande diversité des méthodologies utilisées dans les études rendant difficile une comparaison directe des résultats
- Peu d'études expérimentales permettant d'établir un lien de causalité clair entre émotions et performance

Sensitivity: C1-Internal

3. Problématique scientifique

3.1 Formulation du sujet de recherche

La reconnaissance vocale des émotions (**Speech Emotion Recognition,** *SER*) est un domaine de recherche toujours actif, marqué récemment par l'implémentation du *deep learning* comme technique d'encodage de l'information et de classification des émotions. Ce domaine ne se limite pas à un aspect technique : il s'appuie aussi sur des travaux d'ordre psychologique portant sur l'interprétation et la catégorisation des émotions. Dans ce cadre, plusieurs modèles ont été proposés pour couvrir un maximum d'émotions, sans pour autant constituer des vérités absolues, ces modèles reposant sur des cadres théoriques concurrents de la classification des émotions qui ne font pas consensus au sein de la communauté scientifique.

Dans *l'eSport*, dans quelle mesure est-il possible d'appliquer des modèles de reconnaissance vocale des émotions afin d'interpréter, après leurs matchs, le ressenti de joueurs professionnels durant la partie, dans l'optique d'aider à leur préparation mentale ?

Les solutions actuelles dans ce domaine s'appuient sur :

- Des jeux de données non-actés, plutôt spontanés, annotés par plusieurs annotateurs afin de réduire le biais de subjectivité
- Des modèles d'encodage de *features* ciblés sur le traitement audio, plus précisément sur des motifs temporels récurrents
- Des modèles de *machine learning* qui utilisent des approches différentes pour maximiser le gain
- Des représentations émotionnelles précises et suffisamment larges pour couvrir l'ensemble des émotions existantes

Cependant, notre contexte eSport nous contraint sur :

- Un jeu de données spécifique au contexte *eSport*, spontané, capté en situation réelle et non annoté
- Des émotions non interprétables avec la seule voix
- Des indices vocaux inexploitables, car très courts et peu pertinents
- Une qualité vocale médiocre, avec des différences de volume, du bruit ambiant et des enregistrements parfois inaudibles

3.2 Verrous et/ou incertitudes techniques et scientifiques

1. Qualité audio

Notre *dataset* réel, issu d'enregistrements *in-game*, contient de nombreux facteurs perturbateurs : bruits parasites, qualité variable des micros, sons du jeu, chevauchements de parole et

Sensitivity: C1-Internal

interruptions entre joueurs. De plus, les segments audios sont souvent très courts, ce qui limite les indices vocaux exploitables et complique l'interprétation des émotions.

2. Contexte eSport

Notre étude porte sur un contexte League of Legends très spécifique, avec un vocabulaire dédié et une communication parfois limitée. Les différences culturelles et linguistiques entre joueurs peuvent également biaiser l'interprétation émotionnelle, certaines hésitations pouvant par exemple être perçues à tort comme du stress.

3. Jeu de données d'entraînement

Le modèle sera entraîné sur des audios émotionnellement annotés provenant de *dataset* existants, bien que hors contexte *eSport*. Cette étape est nécessaire pour fine-tuner le modèle et disposer d'une base de comparaison avec notre jeu de données réel, non annoté.

4. Annotation manuelle

Une partie du *dataset* réel devra être annotée afin d'adapter et d'évaluer le modèle. Le défi consiste à définir un schéma d'annotation simple et cohérent, tout en limitant le nombre de classes émotionnelles afin de réduire les ambiguïtés et les cas à traiter.

5. Extracteur de features

Les extracteurs de *features* existants peuvent être coûteux en calcul et générer un volume important de données. L'enjeu est donc d'identifier les *features* les plus pertinentes et d'évaluer leur contribution à la classification émotionnelle.

6. Modèle de classification

Le choix du modèle est complexe compte tenu du grand nombre d'approches disponibles. Bien que les méthodes supervisées semblent les plus adaptées, il reste nécessaire de comparer plusieurs solutions et de définir des métriques d'évaluation pertinentes.

Sensitivity: C1-Internal

4. Démarche et travaux réalisés

4.1 Protocole de Labélisation

4.1.1 Objectif et choix méthodologique

L'absence de base de données émotionnelles adaptée au contexte spécifique de l'eSport (cf : section 1.3.2) a rendu nécessaire la constitution d'un *dataset* annoté à partir d'enregistrements audio réels, issus des communications vocales de l'équipe Lille eSports de League of Legends. Un protocole de labellisation a ainsi été conçu et mis en œuvre afin de produire des annotations émotionnelles fiables, reproductibles et exploitables pour l'entraînement de modèles de reconnaissance des émotions.

Le *dataset* est constitué d'extraits audio d'une durée minimale de 0,2 seconde, extraits de sessions de jeu réelles. Les échanges analysés se déroulent presque exclusivement en anglais, bien que les joueurs ne soient pas anglophones, ce qui constitue une contrainte supplémentaire prise en compte dans la sélection des annotateurs.

4.1.2 Fondement théorique : le modèle PAD

Contrairement à une annotation par catégories discrètes d'émotions (cf : section 2.1.1 Ekman, section 2.1.2 Plutchik), le choix a été fait de s'appuyer sur le modèle dimensionnel **PAD** (Pleasure, Arousal, Dominance) proposé par **Russell et Mehrabian**, qui permet de représenter l'émotion dans un espace continu à trois dimensions plutôt que dans un ensemble figé de catégories. Cette approche graduelle offre l'avantage de produire des scores continus, quantifiables et comparables entre eux, plus adaptés à la variabilité et à la nuance des expressions émotionnelles observées en contexte compétitif.

Chaque extrait audio est ainsi évalué selon trois critères, sur une échelle de 1 à 7 :

- **Valence (Pleasure)** : caractère agréable ou désagréable de l'émotion perçue (1 = très négatif, 7 = très positif) ;
- **Activation (Arousal)** : niveau d'énergie ou d'éveil associé à l'état émotionnel (1 = très inactif, 7 = très actif) ;
- **Dominance** : sentiment de contrôle ou de soumission face à l'émotion ressentie (1 = très soumis, 7 = très dominant).

Une grille de correspondance a également été établie (cf : Figure 5), associant des plages de scores PAD à des émotions discrètes suggérées (par exemple, joie/exaltation pour des scores élevés sur les trois dimensions, ou anxiété/stress pour une valence et une dominance faibles associées à une activation modérée à élevée). Cette grille constitue un outil d'aide à la décision pour l'annotateur, sans se substituer à son jugement : elle ne prétend pas couvrir l'ensemble des états émotionnels possibles, un nombre trop important de catégories proposées risquant au contraire de complexifier inutilement la tâche d'annotation.

Sensitivity: C1-Internal

#	Valence (V)		Activation (A)		Dominance (D)		Émotion discrète suggérée
	Min	Max	Min	Max	Min	Max	
1	5	7	5	7	5	7	Joie / Exaltation
2	5	7	5	7	1	4	Enthousiasme contraint
3	5	7	1	3	5	7	Sérénité / Satisfaction
4	5	7	1	3	1	4	Contentement passif
5	5	7	4	6	5	7	Confiance / Fierté
6	4	6	4	6	4	6	Concentration neutre
7	1	3	5	7	5	7	Colère / Mépris
8	1	3	5	7	1	4	Peur / Panique
9	1	3	1	3	5	7	Ennui / Lassitude
10	1	3	1	3	1	4	Tristesse / Résignation
11	1	3	4	6	5	7	Agacement / Frustration
12	1	3	4	6	1	4	Anxiété / Stress

Figure 5 : Grille PAD - Emotions

4.1.3 Phase de calibration des annotateurs

Afin de garantir la cohérence et la fiabilité des annotations, une phase **de calibration préliminaire** a été intégrée au protocole. Avant toute annotation du *dataset* réel, chaque annotateur est soumis à un test de positionnement sur des extraits déjà labellisés, disposant de scores **PAD** de référence issus de travaux existants, l'un portant sur des émotions jouées (volontairement exagérées), l'autre sur des extraits de podcast non joués. L'annotateur est considéré comme prêt lorsque ses scores s'écartent de moins d'un point (±1) de la référence. S'il échoue, l'exercice est répété sans que la réponse attendue ne soit communiquée directement, l'objectif étant de développer une compréhension fine des critères plutôt que de mémoriser des réponses.

4.1.4 Procédure d'annotation

Une fois la phase de calibration validée, chaque annotateur procède à l'évaluation des extraits réels du *dataset* à l'aide d'une interface logicielle dédiée, spécifiquement développée pour cette campagne de labellisation (cf : Figure 6). Cette interface centralise l'ensemble des éléments nécessaires à l'annotation, afin de limiter la charge cognitive de l'annotateur et de fiabiliser la procédure.

Sensitivity: C1-Internal

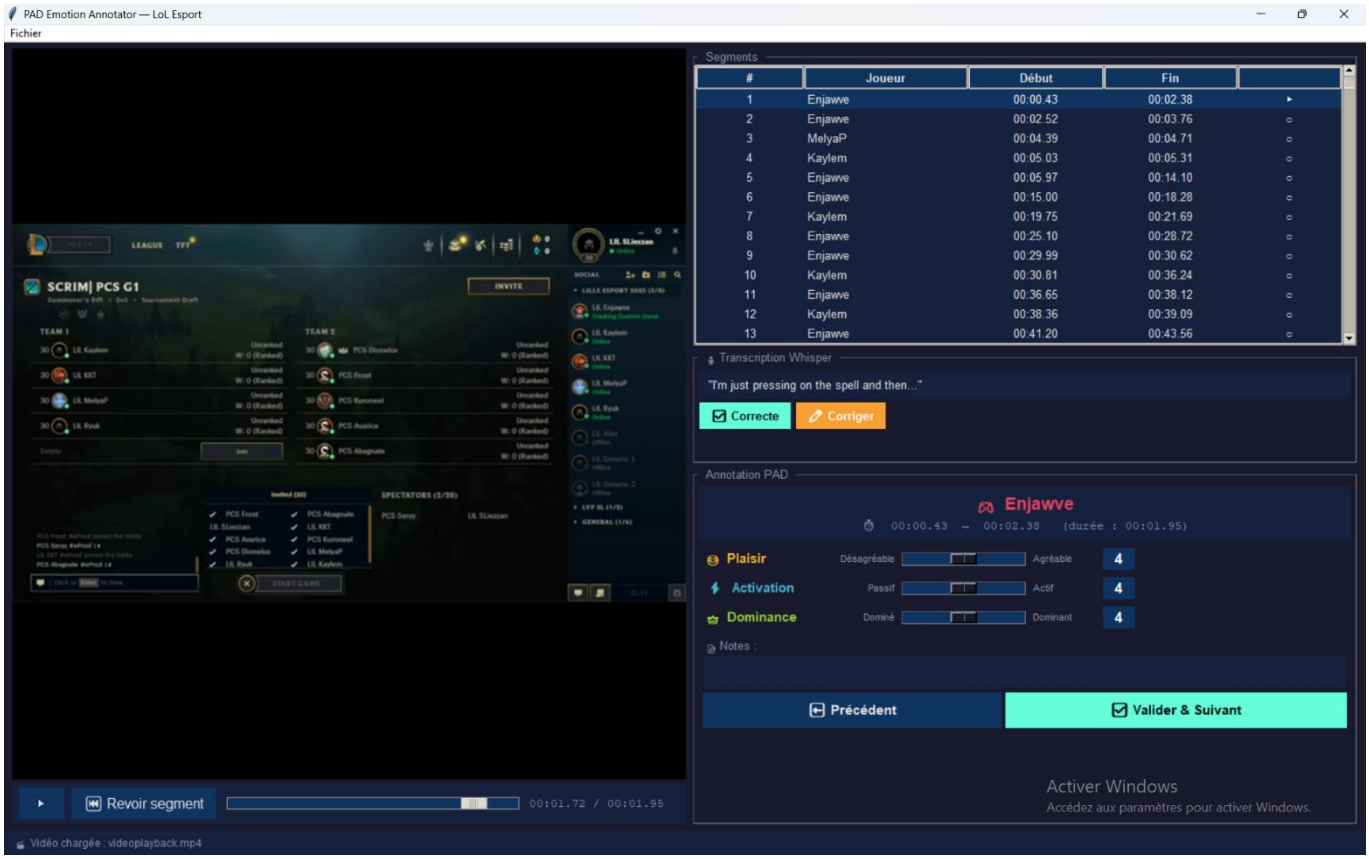


Figure 6 : Interface d'annotation

Organisation de l'interface

L'interface s'articule autour de quatre zones fonctionnelles principales :

- **Zone de lecture audio/vidéo**, dans laquelle le segment sélectionné est automatiquement chargé et peut être rejoué à volonté, permettant à l'annotateur d'écouter et de visionner, le contenu autant de fois que nécessaire avant de statuer sur son évaluation
- **Liste de navigation des segments**, offrant une vue d'ensemble de la progression de la campagne d'annotation grâce à un code couleur distinguant les segments déjà annotés, le segment en cours de traitement, et les segments restant à traiter
- **Panneau de transcription automatique**, affichant le texte généré par un modèle de reconnaissance vocale (Whisper) pour le segment considéré
- **Panneau d'annotation PAD**, composé de trois curseurs correspondant aux dimensions de valence, d'activation et de dominance (échelle de 1 à 7, cf : section 4.1 Protocole de Labélisation), accompagné d'un champ de notes libres.

Sensitivity: C1-Internal

Déroulement de l'annotation d'un segment

Pour chaque segment, l'annotateur suit une séquence de traitement standardisée :

- Écoute du segment audio (avec possibilité de réécoute)
- Vérification de la transcription automatique proposée
- Attribution des trois scores **PAD** sur la base du ressenti et du profil vocal habituel du joueur identifié

L'annotation est ensuite validée, ce qui déclenche le passage automatique au segment suivant et garantit l'enregistrement des données saisies.

Vérification et correction de la transcription automatique

Une attention particulière est portée à la qualité de la transcription générée automatiquement. Celle-ci n'étant pas fiable à 100 %, notamment en raison du bruit ambiant et des recouvrements de parole propres à un contexte de jeu compétitif, l'annotateur doit systématiquement comparer le texte proposé au contenu réellement énoncé par le joueur. Deux cas de figure se présentent :

- si la transcription correspond fidèlement à ce qui a été dit, elle est validée telle quelle
- sinon, l'annotateur procède à sa correction manuelle, en saisissant le texte exact prononcé

Cette étape de correction ne relève pas d'un simple souci de qualité documentaire : elle répond à un objectif méthodologique à part entière. En effet, disposer d'une transcription textuelle fiable, alignée avec les scores émotionnels PAD attribués à chaque segment, permet de constituer un second jeu de données exploitable pour l'entraînement d'un modèle de reconnaissance des émotions fondé sur le texte. Cette double annotation ouvre ainsi la voie à une approche multimodale de la reconnaissance émotionnelle, où les prédictions issues du canal audio pourront être comparées, voire combinées, avec celles issues du canal linguistique.

Les segments jugés inexploitables (audio inaudible, locuteur non identifiable) sont explicitement signalés par l'annotateur afin d'être exclus du corpus final.

4.1.5 Structuration et export des données annotées

À l'issue de chaque session d'annotation, les données produites sont exportées au format csv, afin d'entrainer le modèle utilisé par la suite. Pour chaque segment audio traité, l'export regroupe l'ensemble des informations nécessaires à la reconstitution du contexte d'annotation ainsi qu'aux besoins d'entraînement des modèles de reconnaissance émotionnelle, à savoir :

- **Identification du segment** : nom du fichier audio source, numéro du segment, joueur identifié, timestamps de début et de fin, durée du segment
- **Scores émotionnels** : valeurs attribuées sur les trois dimensions du modèle PAD (valence, activation, dominance)

Sensitivity: C1-Internal

- **Annotations complémentaires** : notes libres éventuellement renseignées par l'annotateur, utiles pour documenter les cas ambigus ou justifier un choix de score particulier
- **Données textuelles** : transcription automatique brute issue de Whisper, statut de validation de cette transcription (validée, corrigée, non vérifiée), et transcription corrigée manuellement le cas échéant.

Gestion de la continuité des campagnes d'annotation

Une campagne d'annotation impliquant un grand nombre de segments et plusieurs annotateurs, le protocole prévoit un mécanisme de sauvegarde et de reprise de session, permettant à un annotateur d'interrompre puis de reprendre son travail sans perte de données ni doublon d'annotation. Le fichier exporté fait ainsi office à la fois de livrable final et de point de reprise intermédiaire.

4.1.6 Contrôle qualité et gestion de la subjectivité

Afin de limiter le biais de subjectivité inhérent à toute annotation manuelle d'émotions, le protocole prévoit le recours à un nombre élevé d'annotateurs (entre 20 et 50), permettant de diluer statistiquement les écarts individuels d'interprétation. Une moyenne et un écart-type sont ensuite calculés pour chaque segment à partir de l'ensemble des scores recueillis. Un écart-type jugé trop élevé traduit une absence de consensus entre annotateurs ; dans ce cas, le segment est classé dans une catégorie « émotion non reconnue » plutôt que de se voir attribuer un score peu fiable, préservant ainsi la qualité globale du *dataset*.

4.1.7 Limites et discussion

Cette méthodologie, fondée sur les travaux de **Russell et Mehrabian**, ne constitue pas la seule approche possible pour l'évaluation des émotions dans un signal vocal ; d'autres modèles, potentiellement plus fins, existent dans la littérature. Le choix du modèle **PAD** répond ici à un choix pratique entre rapidité de mise en œuvre, robustesse et facilité d'exploitation des données produites, plutôt qu'à une recherche de précision maximale. Par ailleurs, la fiabilité du protocole repose fortement sur la disponibilité d'annotateurs maîtrisant l'anglais et disposant d'une connaissance suffisante du contexte de jeu (League of Legends), condition nécessaire à une interprétation juste des réactions vocales observées.

4.2 Extraction des features

4.2.1 Features interprétables

4.2.1.1 Choix méthodologique

En complément des représentations profondes issues de modèles pré-entraînés (cf. section **Erreur ! Source du renvoi introuvable.**), le choix a été fait d'extraire, dans un premier temps, un ensemble de **features acoustiques manuelles interprétables** par segment audio, telles que :

Sensitivity: C1-Internal

l'amplitude maximale, amplitude RMS, la fréquence fondamentale, le jitter, le shimmer, l'HNR et le temps entre les prises de parole. Contrairement aux embeddings produits par des architectures de type **Wav2vec2**, ces features reposent sur des grandeurs physiques, ce qui permet d'en interpréter le comportement des joueurs à partir de valeurs numériques et de disposer d'une base de référence, simple et explicable, avant l'introduction de représentations plus complexes.

Le choix des descripteurs retenus a été guidé par les contraintes spécifiques de notre *dataset* : communications courtes, bruitées, parfois compressées ou avec voix superposées. Plusieurs familles de *features* classiquement utilisées en SER : *MFCC*, *LPC/LPCC*, descripteurs spectraux tels que le centroïde, la bande passante, la flatness, le contraste ou le rolloff ; ont ainsi été écartées à ce stade, car leur interprétation émotionnelle reste indirecte et leurs performances se dégradent fortement dans les conditions rencontrées dans notre corpus.

À l'inverse, les descripteurs retenus ont été choisis pour leur robustesse relative et leur lien plus direct avec des marqueurs émotionnels documentés : l'amplitude maximale et l'amplitude RMS pour capter les ruptures d'énergie ; la F0 moyenne, estimée par l'algorithme YIN pour sa faible marge d'erreur ; le jitter et le shimmer, qui peuvent à eux seuls constituer un jeu de *features* minimal et efficace pour la *SER* ; le HNR, qui caractérise la qualité de la production vocale ; ainsi qu'un descripteur contextuel de temps de silence inter-locution.

Un module d'extraction dédié `AudioFeatureExtractor()` a été développé afin de calculer, pour chaque segment audio du dataset, un ensemble de descripteurs acoustiques classiques ainsi qu'un descripteur contextuel propre à la structure temporelle des échanges en jeu.

4.2.1.2 Descripteurs extraits

Le tableau suivant présente les features calculées, leur signification et la méthode retenue pour leur estimation (avec les librairies numpy et librosa sous python).

Features	**Description**	**Méthode de calcul**
Amplitude maximale	Amplitude maximale du signal	$\max = max(signal)$
Amplitude RMS	Amplitude moyenne du signal	$rms = \sqrt{mean(signal)^2}$
F0 moyenne (Hz)	Fréquence fondamentale moyenne	$f0 = mean\left(\int_{-\infty}^{+\infty} signal\, e^{-j2\pi ft}\, dt\right)$
Jitter	Variation cycle-à-cycle de la période fondamentale	$jitter = \text{mean}\left(\left\lvert \frac{diff\left(\frac{1}{f_0}\right)}{\text{mean}\left(\frac{1}{f_0}\right)} \right\rvert\right)$

Sensitivity: C1-Internal

Shimmer	Variation cycle-à-cycle de l'amplitude	$shimmer = \text{mean}\left(\left\|\frac{diff(amp)}{\text{mean}(amp)}\right\|\right)$
HNR (dB)	Rapport harmonique/bruit	$hnr = \frac{10\,log_{10}(energy_noise + \varepsilon)}{energy_noise + \varepsilon}$
Temps de silence inter-locution	Durée de silence précédent la prise de parole d'un joueur par rapport à la précédente	Récupération du début de la durée d'un segment d'un joueur et comparaison avec la fin de la durée d'un autre segment du même joueur

4.2.1.3 Exploration visuelle des features

Afin d'explorer le comportement des *features* extraites à l'échelle du *dataset*, deux modes de visualisation ont été développés :

- **Une visualisation par distribution inter-joueurs**, représentant, pour une *feature* donnée, la dispersion des valeurs obtenues pour chaque joueur du *dataset*. Cette représentation vise à identifier des profils vocaux individuels (par exemple une F0 moyenne ou une énergie RMS caractéristique d'un joueur) et à permettre une comparaison entre joueurs.
- **Une visualisation temporelle intra-partie**, représentant l'évolution d'une *feature* donnée au fil du temps de jeu pour un joueur spécifique, chaque segment de parole étant positionné selon ses phases de début et de fin. Cette représentation vise à observer les variations d'une *feature* au cours d'une session de jeu et à repérer visuellement des phases susceptibles de correspondre à des pics d'intensité émotionnelle.

Ces deux outils de visualisation ont été conçus comme un moyen d'exploration et de contrôle qualité de l'extraction des features, en amont de l'analyse de la relation entre ces descripteurs et les scores PAD annotés.

4.2.2 Features d'entrée du modèle

4.2.2.1 Choix méthodologique

En complément des *features* interprétables, une seconde approche a été mise en œuvre afin d'extraire des représentations profondes du signal vocal. Deux options existaient à ce stade : s'appuyer sur un ensemble standardisé de descripteurs acoustiques comme **eGeMAPS**, extrait via **OpenSMILE**, ou exploiter directement les représentations apprises par un modèle auto-supervisé de type **Wav2Vec2**.

Sensitivity: C1-Internal

eGeMAPS présente l'avantage d'être un standard largement adopté dans la littérature *SER*, avec 88 descripteurs interprétables couvrant simultanément les dimensions prosodiques, énergétiques, spectrales et de qualité vocale [30], [31]. Cette standardisation facilite la comparaison entre travaux scientifiques et constitue une référence fréquemment utilisée comme *baseline*. Il reste cependant construit sur un ensemble de descripteurs définis manuellement, non optimisés pour une tâche spécifique, et ne peut pas capturer toute la richesse émotionnelle contenue dans des situations complexes ou fortement contextualisées telles que nos communications de jeu.

Le choix s'est donc porté sur **Wav2Vec2-large**, un modèle auto-supervisé pré-entraîné sur de grandes quantités de parole non annotée [1], [32], capable d'apprendre directement une représentation du signal brut sans définition a priori des descripteurs à extraire. Cette approche permet de capturer des informations acoustiques, prosodiques et contextuelles plus riches que celles issues des *features* manuelles ou **d'eGeMAPS**, ce qui s'avère particulièrement utile pour des émotions subtiles comme le stress ou la concentration, difficiles à isoler avec un jeu de descripteurs fixé à l'avance. Cette richesse se fait toutefois au prix d'une interprétabilité plus faible et d'un coût computationnel significativement plus élevé, en entraînement comme en inférence, ce qui justifie de conserver en parallèle le jeu de *features* interprétables présenté en section 5.2.1.

Ces représentations profondes ne correspondent à aucune grandeur physique ou perceptive directement identifiable : elles résultent de l'apprentissage auto-supervisé du modèle sur le *dataset* audio **MSP-Podcast**, et capturent des informations complexes du signal (prosodie, timbre, structure phonétique) difficilement accessibles par une extraction manuelle.

Le modèle est utilisé ici en mode extracteur de *features* uniquement, sans sa *tête de régression* : seul le *backbone* **Wav2Vec2Model** est chargé, les poids du réseau pré-entraîné restent figés, et seule la représentation interne produite par le modèle est exploitée en sortie.

4.2.2.2 Modèle utilisé et pipeline d'extraction

L'extraction repose sur le checkpoint audeering/wav2vec2-large-robust-12-ft-emotion-msp-dim, disponible sur la plateforme HuggingFace. Ce modèle est issu d'un *fine-tuning* de **Wav2Vec2-Large-Robust** sur le *dataset* **MSP-Podcast**, un *dataset* anglophone annoté selon les dimensions du modèle **PAD**. Le réseau a par ailleurs été élagué de 24 à 12 couches de *transformeurs* avant son *fine-tuning*, ce qui en fait une version allégée, plus rapide à exécuter, tout en conservant les capacités de représentation acquises lors du pré-entraînement.

Le pipeline complet, depuis le segment audio brut jusqu'à *l'embedding* final, est résumé en Figure 7.

Sensitivity: C1-Internal

Ce schéma synthétise les quatre grandes étapes du script d'extraction : un **prétraitement du signal** (conversion mono, rééchantillonnage à 16 kHz), une normalisation par le **Wav2Vec2Processor** (centrage/scaling de l'amplitude, mise en forme en tenseurs PyTorch), le passage dans le **Wav2Vec2Model** proprement dit (encodeur convolutif, projection dans l'espace latent, puis *Transformer* à 12 couches), et enfin un pooling temporel produisant un vecteur unique de 1024 dimensions par segment, sauvegardé au format .pkl.

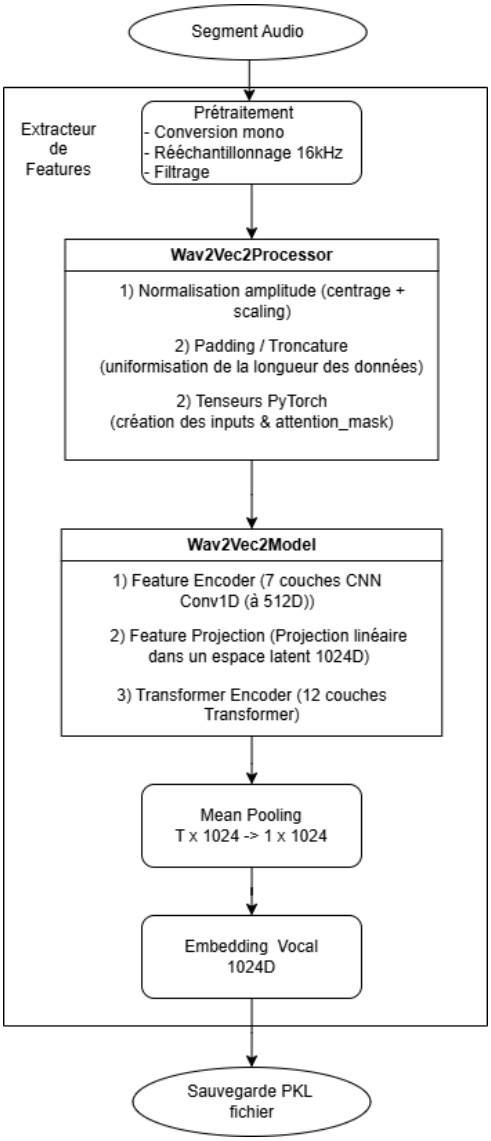


Figure 7 : Pipeline d'extraction des features Wav2Vec2

Deux composants sont utilisés conjointement pour extraire les représentations :

- **Wav2Vec2Processor**, qui normalise l'audio brut et le met sous une forme numérique standardisée, exploitable par le réseau de neurones. Ce composant ne réalise aucun apprentissage : il s'agit d'une étape de mise en forme des données.
- **Wav2Vec2Model**, qui constitue le réseau de neurones à proprement parler. C'est lui qui, à partir du signal normalisé, produit la représentation profonde du segment audio.

a) Le Feature Encoder : encodeur convolutif

Avant d'atteindre le *Transformer*, le signal audio normalisé traverse une succession de couches convolutives 1D (7 couches au total dans **Wav2Vec2**), dont le rôle est de transformer le signal brut, échantillonné à 16 kHz, en une séquence de représentations locales à 512 dimensions. Le principe des deux premières couches sont détaillées en Figure 8 et Figure 9. Même si le nombre de kernel et de stride change par rapport à notre modèle réel.

Couche 1 Conv1D — 512 filtres, kernel 3, stride 2

Cette première couche applique 512 filtres convolutifs sur le signal d'entrée, chacun regardant une fenêtre de 3 échantillons consécutifs à la fois (kernel = 3), en avançant de 2 échantillons à chaque déplacement (stride = 2). Ce stride divise donc par 2 la longueur de la séquence à chaque couche, ce qui explique pourquoi, après les 7 couches convolutives, une séquence audio de plusieurs milliers d'échantillons est réduite à quelques centaines de "trames" temporelles. Chaque position de sortie $P_{1/j}$résulte d'une combinaison linéaire pondérée des échantillons couverts par la fenêtre, suivie d'une activation GELU, qui introduit de la non-linéarité et permet au réseau d'apprendre des motifs acoustiques plus complexes qu'une simple moyenne pondérée.

Sensitivity: C1-Internal

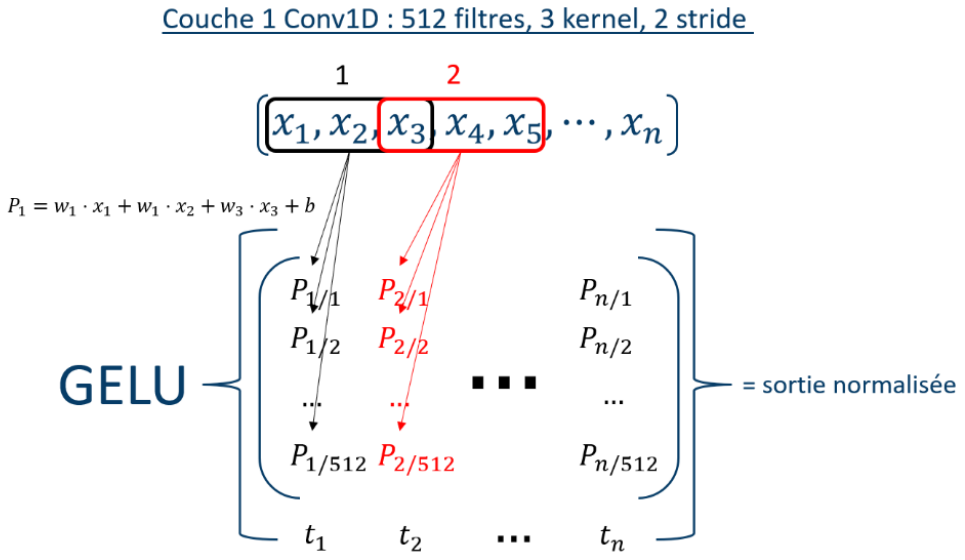


Figure 8 : Couche 1 Conv1D

Couche 2 Conv1D — 512 filtres, kernel 2, stride 2

La deuxième couche reprend le même principe, mais s'applique cette fois sur la sortie de la couche précédente (déjà en 512 dimensions), avec un kernel plus petit (2) puisque chaque position contient déjà une information agrégée sur plusieurs échantillons originaux. Cet empilement de couches convolutives permet au réseau de construire progressivement des représentations de plus en plus abstraites et de plus en plus larges en contexte temporel, sans perdre en résolution de traitement, chaque couche successive "voit" une portion plus large du signal original tout en manipulant une séquence plus courte.

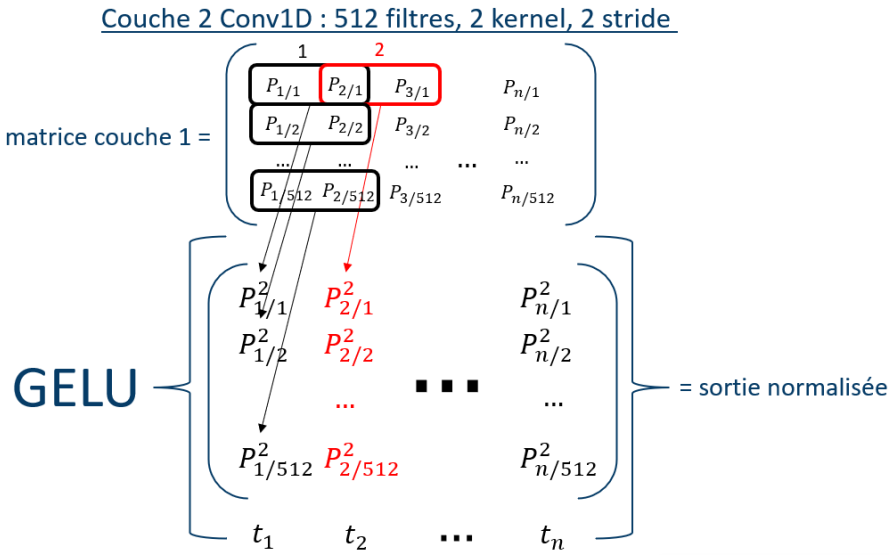


Figure 9 : Couche 2 Conv1D

Sensitivity: C1-Internal

b) Feature Projection

À l'issue des 7 couches, la sortie est projetée linéairement de 512 vers 1024 dimensions (**Feature Projection**), afin de correspondre à la dimension d'entrée attendue par le Transformer.

c) Le Transformer Encoder

La séquence de représentations en 1024 dimensions est ensuite propagée à travers 12 couches *Transformer* identiques dans leur structure. Le détail du fonctionnement interne d'une seule de ces couches est présenté en Figure 10.

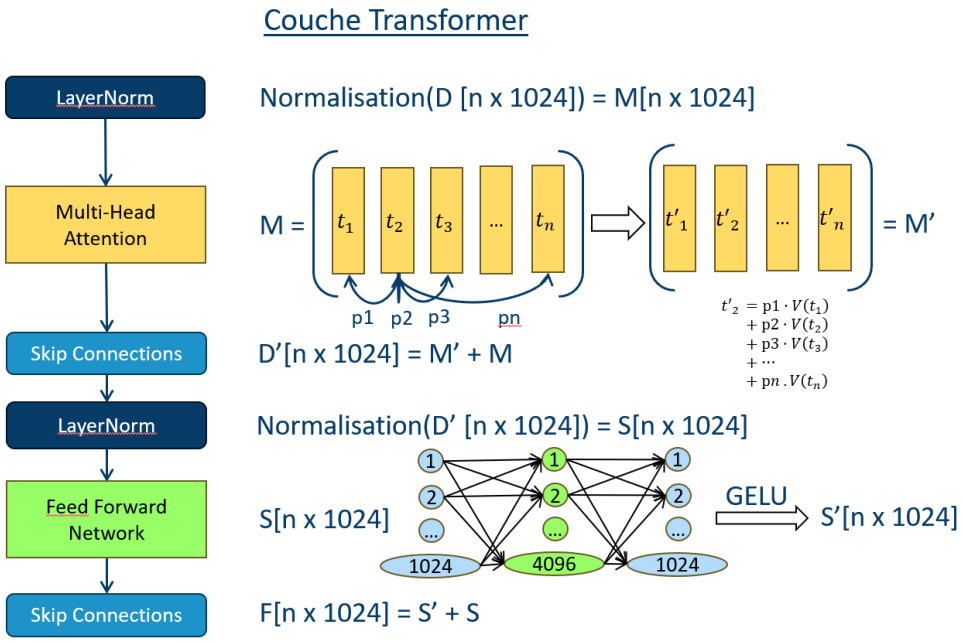


Figure 10 : Détail d'une couche Transformer

Chaque couche applique successivement : une **normalisation** (LayerNorm) du vecteur d'entrée D, un bloc de **Multi-Head Attention** qui recalcule chaque token t_i comme une combinaison pondérée de tous les tokens de la séquence (les poids $p_1, p_2, \ldots, p_n$ traduisant l'importance relative de chaque position par rapport aux autres), une **skip connection** qui additionne cette sortie au vecteur D d'origine (évitant la perte d'information et facilitant la propagation du gradient), une seconde normalisation, un **Feed Forward Network** qui projette chaque position individuellement dans un espace intermédiaire à 4096 dimensions avant de revenir à 1024 (avec une activation GELU au passage), puis une seconde skip connection. C'est ce mécanisme d'attention, répété 12 fois, qui permet au modèle de construire une représentation contextuelle de chaque segment de parole : contrairement aux couches convolutives qui ne voient qu'un voisinage local, l'attention permet à chaque position de la séquence d'intégrer directement l'information de n'importe quelle autre position, même distante.

La sortie du dernier état **(last_hidden_state)** de cette pile de 12 couches constitue la représentation finale retenue, avant l'étape de **pooling temporel** décrite ci-dessous.

Sensitivity: C1-Internal

d) Mean pooling et embedding vocal

A la sortie du dernier état, une matrice temporelle des 1024 est transformer en un vecteur à seulement 1024 informations. Pour se faire, un **mean pooling** temporel est effectuer afin de réduire le segment audio à un seul vecteur. Ensuite, le vecteur est placé dans un espace **embedding** afin d'être classé par rapport aux autres.

4.2.2.3 Sauvegarde et format de sortie

L'ensemble des vecteurs de features extraits est structuré sous forme de dictionnaire associant, pour chaque segment audio traité avec succès, son nom de fichier au vecteur de représentation correspondant (1024 dimensions). Ce dictionnaire est sérialisé et sauvegardé au format pickle (.pkl), choisi pour sa capacité à conserver la structure de tableaux NumPy contrairement à un export classique (CSV). Les segments écartés ne sont volontairement pas inclus dans le dictionnaire final. Ce fichier .pkl constitue le second jeu de features d'entrée destiné à l'entraînement des modèles de reconnaissance émotionnelle (cf : section 3.4), en complément du jeu de features interprétables généré.

4.3 Modèle

4.3.1 Choix méthodologique

Pour prédire les scores **PAD** à partir des *features* déjà extraites, plusieurs approches ont été envisagées. Les méthodes classiques comme le **SVM ou le XGBoost** offrent une bonne interprétabilité et un coût computationnel faible, ce qui les rend efficaces avec peu de données annotées ; elles restent cependant fortement dépendantes de la qualité des *features* extraites manuellement et ne capturent pas les dépendances temporelles du signal vocal, ce qui limite leur pertinence pour des émotions qui évoluent au fil du match. Les **CNN** appliqués sur des *features* de type **eGeMAPS** constituent une approche intermédiaire, capable d'apprendre des combinaisons non linéaires entre descripteurs, mais restent limités par la qualité des *features* en amont et par le volume de données disponible pour l'entraînement.

Le choix s'est donc porté sur **Wav2Vec2**, déjà mobilisé comme extracteur de représentations profondes (cf. section 5.2.2), afin d'exploiter directement la richesse contextuelle apportée par son architecture encodeur convolutif + *Transformer*. Ce choix permet en outre de réutiliser le modèle audeering/wav2vec2-large-robust-12-ft-emotion-msp-dim comme modèle de prédiction : ce modèle intègre nativement une tête de régression **PAD**, ce qui évite d'avoir à entraîner un classifieur supplémentaire à partir de zéro. Comme les *embeddings* sont déjà calculés et sauvegardés, seule cette *tête de régression* est appliquée, ce qui rend la prédiction quasi instantanée, sans avoir à repasser les fichiers audios dans le *backbone* **Wav2Vec2** déjà exécuté une première fois. Cette approche présente en contrepartie les limites classiquement associées aux modèles profonds : une interprétabilité plus faible que les méthodes classiques, et une dépendance forte au volume de données disponible pour l'entraînement de la tête de classification (cf. section 5.3.4).

Sensitivity: C1-Internal

4.3.2 Modèle utilisé

Le **modèle audeering** est composé de deux blocs : le **backbone Wav2Vec2** qui produit les embeddings et **une tête de régression** qui convertit ces embeddings en trois scores. Elle a été *fine-tunée* sur **MSP-Podcast** (cf. section 3.2), lui-même annoté selon le modèle **PAD**, ce qui la rend directement cohérente avec le modèle théorique retenu pour notre propre annotation. Le pipeline appliqué à chaque vecteur de features est détaillé en Figure 11.

- **Pipeline de la tête de régression PAD**

Le vecteur audio (1024 dimension) issu de l'extraction traverse successivement : un premier **dropout** (désactivé en mode inférence, puisqu'il ne sert qu'à limiter le surapprentissage pendant l'entraînement), une couche dense **(Dense Layer)** qui reprojette le vecteur de 1024 vers 1024 dimensions, une **activation tanh()** qui écrase les valeurs dans l'intervalle [-1, +1] et introduit la non-linéarité nécessaire pour que cette seconde couche apporte une information différente de la première, un second **dropout** (également désactivé), et enfin une couche de sortie **(Output Layer)** qui réduit le vecteur de 1024 à 3 dimensions, les scores Arousal, Dominance et Valence. Ce résultat est ensuite exporté au format CSV.

Concrètement, on récupère uniquement les poids de cette tête, et on l'applique à chaque vecteur de features déjà extrait, sans jamais recalculer les 1024 dimensions d'entrée.

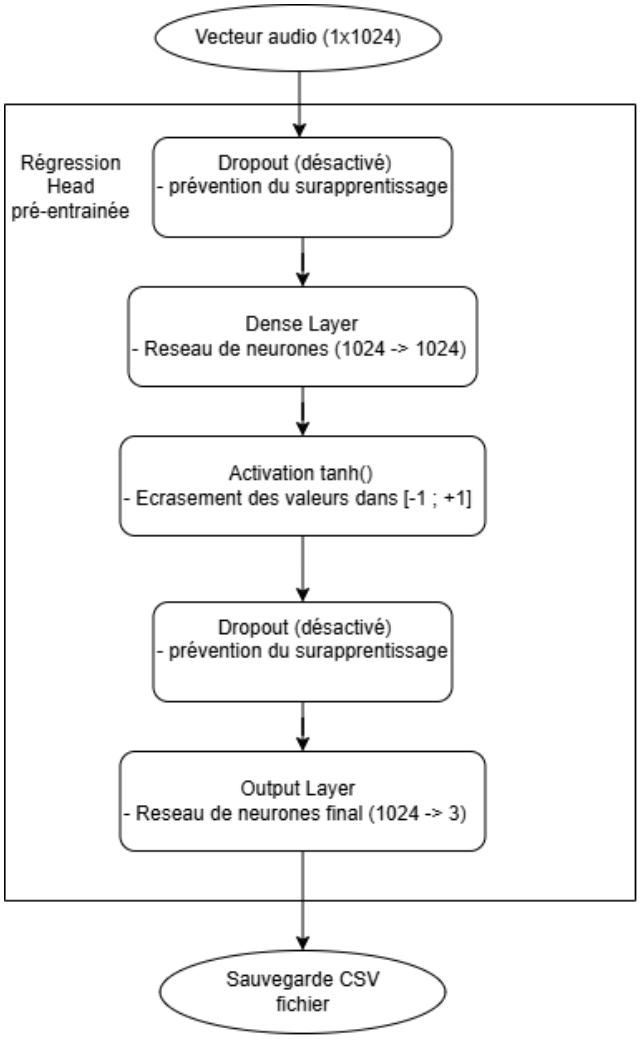


Figure 11 : Pipeline de la tête de régression PAD

4.3.3 Sauvegarde

Les prédictions obtenues pour chaque segment sont exportées dans un fichier CSV, associant à chaque nom de fichier audio ses trois scores **PAD** (arrondis à 4 décimales). Contrairement aux *embeddings*, le format CSV est ici suffisant, car les données de sortie sont de simples valeurs numériques. Ce fichier sert de base à la comparaison avec les scores attribués manuellement par les annotateurs.

4.3.4 Limites

- Le modèle sort des scores entre 0 et 1, alors que notre annotation manuelle utilise une échelle de 1 à 7 : une étape de rescaling sera nécessaire avant toute comparaison directe.

Sensitivity: C1-Internal

- Le modèle n'a jamais été entraîné ni *fine-tuné* sur des données *eSport* : il reste entraîné sur un *dataset* de podcast anglophone.
- La qualité de la prédiction **PAD** dépend entièrement de la qualité des *embeddings* extraits en amont (cf. limites du *backbone* **Wav2Vec2**, section 3.3.3).
- Aucune réévaluation ni *fine-tuning* de *la tête de régression* n'a été réalisé à ce stade : elle est utilisée telle quelle, sans adaptation à notre propre distribution de scores.

4.4 Prédiction

4.4.1 Objectif de la comparaison

L'objectif de cette étape est de confronter les scores **PAD** prédits automatiquement par le modèle **Wav2vec2-large-robust-12-ft-emotion-msp-dim** (cf. section 5.3) aux scores **PAD** attribués manuellement par les annotateurs lors de **la campagne de labellisation** (cf. section 5.1), afin d'évaluer dans quelle mesure un modèle pré-entraîné sur un *dataset* généraliste (podcast anglophone) est capable de généraliser à notre contexte spécifique de communications vocales en compétition eSport.

Cette comparaison nécessite au préalable un rescaling des scores prédits (bornés entre 0 et 1) vers l'échelle utilisée lors de l'annotation manuelle (1 à 7), afin de rendre les deux jeux de données directement comparables. Pour comparer le score manuel avec le score prédit par le modèle, on superposera directement chacun des scores au cours du match. De plus, on calculera la différence entière et absolue entre nos scores pour voir si le modèle se rapproche de ce que l'annotateur a perçu.

4.4.2 Résultats attendus

Contexte :
Le modèle utilisé a été *fine-tuné* sur **MSP-Podcast**, des podcasts spontanés dans un contexte conversationnel généraliste, en anglais, sans vocabulaire technique ni contrainte environnementale. Nos données présentent au contraire un niveau de bruit plus élevé, des locuteurs non-natifs anglophones, des segments plus courts et un contexte émotionnel spécifique (stress compétitif, tilt, exaltation liée aux mécaniques du jeu).

Attendu :
Dans ce contexte, on peut anticiper une ressemblance modérée plutôt que forte entre les scores prédits et les scores annotés, avec des performances meilleures sur la dimension Activation (l'énergie vocale étant relativement bien capturée indépendamment du contexte culturel ou linguistique) que sur les dimensions Valence et Dominance, plus dépendantes du contenu et des codes culturels d'expression émotionnelle, davantage susceptibles d'être mal transférés d'un *dataset* à l'autre.

Sensitivity: C1-Internal

On peut également s'attendre à des écarts plus marqués sur les segments les plus bruités ou les plus courts, cohérents avec les limites déjà identifiées pour le *backbone* **Wav2Vec2** (cf. section 3.3.3) et pour le contexte *eSport* en général (cf. section 4.2).

Objectif :
Confirmer ou infirmer ces hypothèses à partir des données réellement recueillies, et identifier, dimension par dimension, les cas où le modèle généraliste reste exploitable en l'état et les cas où un *fine-tuning* sur des données *eSports* annotés serait nécessaire.

4.4.3 Meilleur scénario envisageable

Dans le meilleur des cas, le modèle pré-entraîné montrerait une corrélation suffisamment forte avec les annotations manuelles sur les trois dimensions du modèle PAD (une attendue plus forte sur l'Activation), pour être directement exploitable comme indicateur de tendance générale de l'état émotionnel d'un joueur au cours d'une partie, sans nécessiter de *fine-tuning* supplémentaire dans un premier temps.

Ce résultat permettrait de valider l'hypothèse selon laquelle des représentations profondes apprises sur un *dataset* généraliste gardent les traces suffisantes pour un cas d'usage aussi spécifique que *l'eSport*, et fournirait une base de comparaison solide pour évaluer, dans un second temps, l'apport réel d'un *fine-tuning* sur données annotées spécifiques à League of Legends.

À plus long terme, un tel résultat ouvrirait également la voie à l'exploitation des *features* interprétables (cf. section 5.2.1) en complément des *embeddings* **Wav2Vec2**, dans une logique de modèle hybride combinant richesse contextuelle et interprétabilité, afin de proposer à Lille eSport un outil à la fois performant et exploitable pour le coaching mental des joueurs.

Sensitivity: C1-Internal

5. Analyse des résultats et interprétations

Pour l'analyse des résultats préliminaires, nous nous intéressons d'abord à l'annotation manuelle du *dataset*. À ce stade, l'annotation a été réalisée sur la première game de Lille Esport, avec 543 segments audio annotés. Cette annotation suit le protocole de labélisation présenté précédemment. Nous analyserons ensuite les prédictions du modèle **Wav2Vec2-Large** sur l'ensemble du *dataset*. Enfin, nous étudierons les features brutes et interprétables afin d'identifier d'éventuelles correspondances avec certains joueurs.

5.1 Résultat annotation manuelle

Pour l'analyse du protocole de labélisation, nous nous basons uniquement sur le premier match joué par l'équipe de Lille Esport, à partir de 543 segments audios. Cette annotation a été réalisée par un seul labéliseur, faute de temps pour lancer une campagne d'annotation. Nous analyserons d'abord les transcriptions générées par Whisper sur le *dataset*. Nous étudierons ensuite la répartition des scores PAD. Des émotions seront aussi attribuées à partir de ces scores afin d'obtenir une première estimation de leur répartition dans une partie de *LoL*. Enfin, nous interpréterons ces résultats au regard du déroulement du match.

5.1.1 Résultat transcription

Dans un premier temps, nous avons réalisé une analyse globale de la transcription. L'objectif était d'évaluer la part de segments correctement transcrits par rapport aux segments mal transcrits. Certains segments ne sont pas transcriptibles, car leur contenu audio est inaudible.

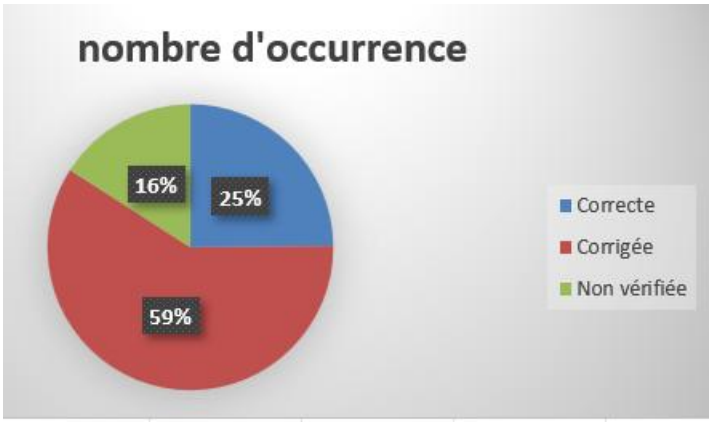


Figure 12 : Résultats de la transcription sur l'ensemble 1er game

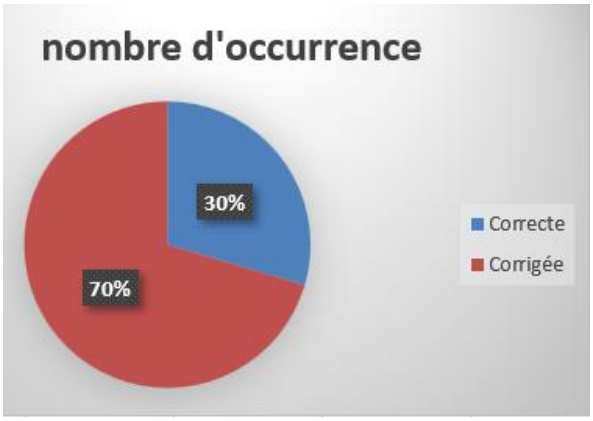


Figure 13 : Résultats de la transcription sur les données annotables 1er game

Les résultats montrent qu'une part importante des segments annotés n'est pas correctement transcrite, avec environ 70 % d'erreurs sur les segments évalués (cf : Figure 13). Cela peut limiter la compréhension des communications par notre modèle. De plus, 16 % des segments sont

Sensitivity: C1-Internal

inexploitables, principalement en raison d'un contenu audio inaudible (cf : Figure 12). Cette part reste non négligeable dans le *dataset*.

Ce résultat doit toutefois être nuancé. Lors de la labélisation, nous avons observé que de nombreux segments étaient proches de la transcription attendue. Les erreurs semblent en partie liées au fait que Whisper est entraîné sur des données génériques, peu adaptées au vocabulaire spécifique de *l'eSport* et de *LoL*.

Ainsi, Whisper ne reconnaît pas toujours correctement le lexique utilisé par les joueurs. Malgré cela, les transcriptions restent exploitables pour obtenir une compréhension générale des segments. À terme, les segments déjà annotés pourraient servir à entraîner un modèle de transcription plus adapté, avec un dataset d'entraînement propre et spécifique.

5.1.2 Résultat PAD

Après l'annotation de la première game, nous avons tracé les trois scores **PAD** : Plaisir, Activation et Dominance. Ces scores sont représentés selon l'ordre des segments au cours du match.

Pour l'analyse, la partie est découpée en quatre phases. **La pré-game** correspond aux segments 1 à 147 (de 1s à 602s). **L'early game** s'étend des segments 148 à 252 (de 611s à 1006s). **Le midgame** couvre les segments 253 à 398 (de 1007s à 1436s). Enfin, **l'endgame** correspond aux segments 399 jusqu'à la fin de la partie (de 1439s à 1974s).

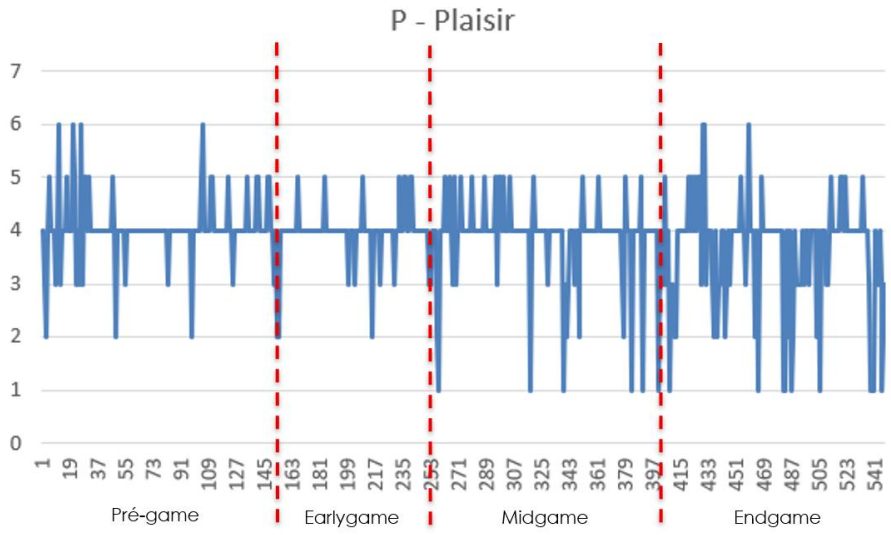


Figure 14 : Evolution du Plaisir 1ère game

Pour le score de **Plaisir**, les joueurs présentent un état plutôt positif durant **la pré-game**. À partir de **l'early game** puis du **midgame**, le score devient plus négatif. En moyenne, le score reste compris entre 3 et 5, ce qui correspond à un état globalement neutre, avec des émotions peu expressives. On observe toutefois deux pics de positivité vers **l'endgame**. Malgré ces variations, le score reste globalement faible sur cette phase.

Sensitivity: C1-Internal

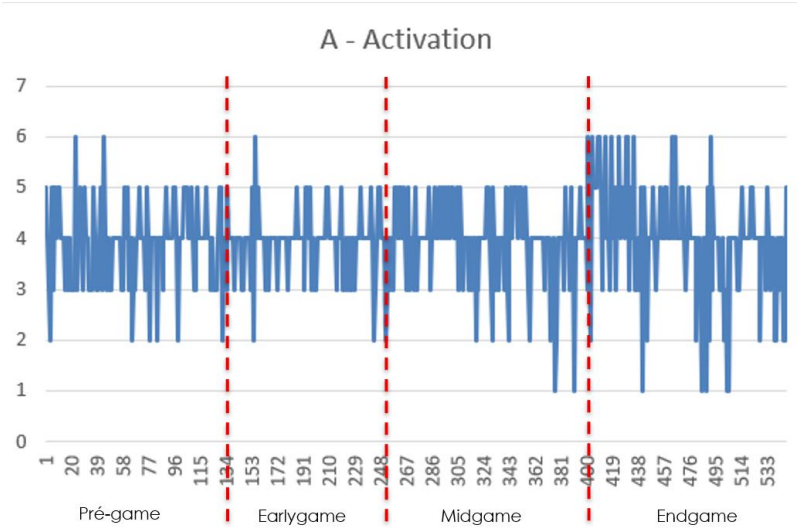


Figure 15 : Evolution de l'Activation 1ère game

Le score **d'Activation** reste plus neutre que le score de Plaisir. Il se situe plus souvent entre 3 et 5, ce qui indique une activation globalement modérée. Quelques pics élevés sont observés durant **la pré-game**, ainsi que certains scores plus faibles. En **early game** et en **midgame**, le score reste plutôt neutre, avec quelques baisses ponctuelles. Au début de **l'endgame**, certains pics deviennent plus positifs. En fin de game, on observe davantage de pics négatifs. Les scores les plus extrêmes indiquent donc une intensité plus forte, mais globalement orientée négativement.

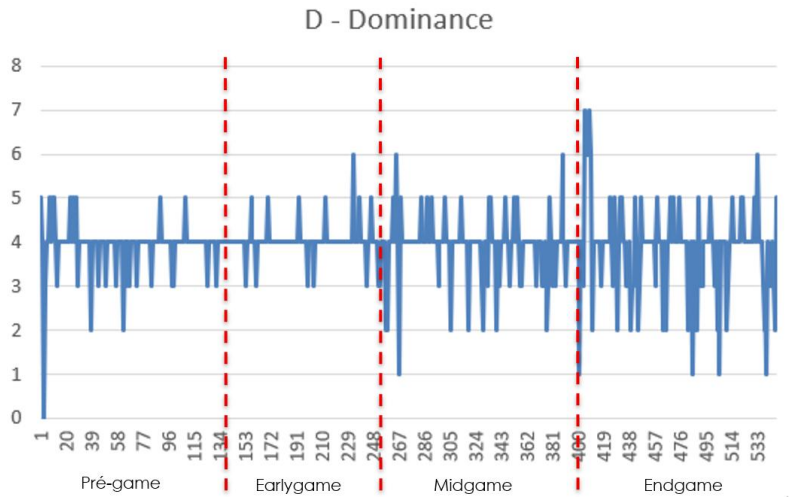


Figure 16 : Evolution de la Dominance 1ère game

Le score de **Dominance** reste majoritairement neutre, avec quelques pics ponctuels. En **pré-game**, les pics observés sont principalement négatifs. En **midgame**, les variations sont plus marquées, avec une majorité de pics négatifs et deux pics positifs. Au début de **l'endgame**, une courte période de pics positifs apparaît. Sur le reste de la fin de game, les valeurs redeviennent largement négatives. Globalement, ce score varie peu. Il est donc difficile d'identifier une tendance nette sur l'ensemble de la partie.

Sensitivity: C1-Internal

En conclusion, une corrélation semble apparaître entre les scores PAD. En **pré-game**, le score de **Plaisir** est plutôt positif, avec une **Activation** moyenne mais légèrement positive, et une **Dominance** plutôt négative. En **early game**, les trois scores restent globalement neutres. En **midgame**, les scores de **Plaisir**, **d'Activation** et de **Dominance** deviennent plus négatifs. **L'endgame** présente davantage de pics. Au début de cette phase, les scores **d'Activation** et de **Dominance** sont fortement positifs, avec un **Plaisir** également plutôt positif. En fin de game, les trois scores deviennent nettement négatifs.

5.1.3 Attribution des émotions et interprétation

Après l'annotation de la première partie, nous pouvons associer des émotions aux segments audio. Pour cela, nous nous appuyons sur le tableau présenté dans la section 4.1.2 Fondement théorique : le modèle PAD (cf : Figure 5) afin de limiter l'analyse à un nombre restreint d'émotions. L'objectif est de mieux comprendre les émotions ressenties par l'équipe au cours de la game, puis de mettre ces résultats en lien avec le déroulement de celle-ci.

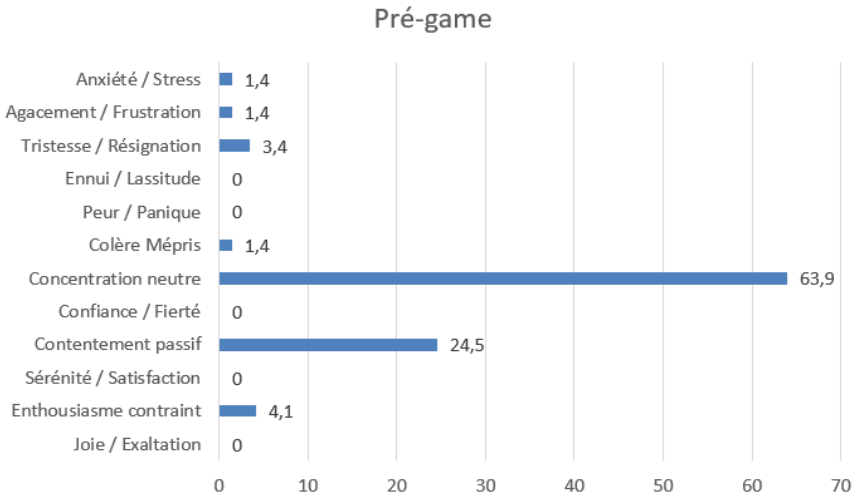


Figure 17 : Emotions Pré-game

Durant la **pré-game**, une grande partie des segments est associée à une émotion de **concentration/neutre**. Ce résultat est cohérent avec les scores PAD, majoritairement proches de 4 pour les trois dimensions. Dans la plupart des segments audio, les joueurs n'expriment pas d'émotion marquée. Cela explique la forte proportion de segments neutres, qui représente **63,9 %** des cas. L'émotion de **contentement** apparaît ensuite avec **24,5 %** des segments. Elle correspond à un score de Plaisir positif, associé à une Dominance plutôt faible. Les joueurs semblent donc dans un état positif, sans forte expressivité. Les émotions de **tristesse/résignation** (**3,4 %**) et d'**enthousiasme contraint** (**4,1 %**) sont moins présentes. Elles apparaissent surtout lors de pics sur les scores de Plaisir ou d'Activation. Ces résultats doivent être interprétés avec prudence, car de faibles variations dans l'annotation PAD peuvent modifier l'émotion attribuée.

Sensitivity: C1-Internal

En résumé, la **pré-game** montre une équipe plutôt concentrée et positive. Cette tendance peut être liée aux retrouvailles entre joueurs, ainsi qu'à la préparation de la game. Certains pics peuvent correspondre à des moments de rire ou de joie plus marqués.

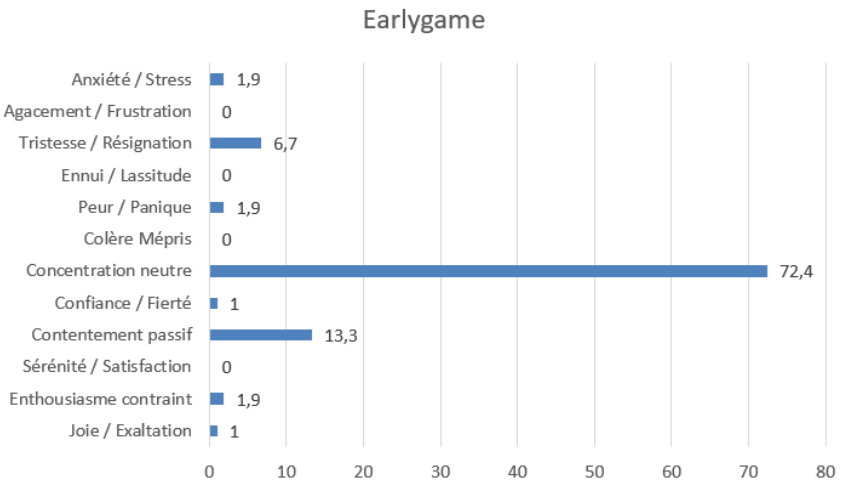


Figure 18 : Emotions Earlygame

Durant l'**early game**, une part encore plus importante des segments audio est associée à une émotion de **concentration/neutre** (**72,4 %**). Les scores PAD restent globalement proches de 4 sur cette phase, ce qui indique l'absence d'émotion marquée. Ce résultat est cohérent avec le début de game, où les joueurs sont concentrés et expriment peu d'émotions dans leur voix. Les émotions de **contentement passif** (**6,7 %**) et de **tristesse/résignation** (**13,3 %**) sont aussi présentes. Elles semblent liées à de légères variations des scores PAD. Ces variations peuvent correspondre à des actions de gameplay plus ou moins réussies, générant des réactions vocales ponctuelles.

Globalement, l'**early game** est dominée par un état neutre et concentré. Malgré cela, certaines émotions apparaissent ponctuellement, comme lors de leur first blood à 7 min 45, où le toplaner exprime de la joie.

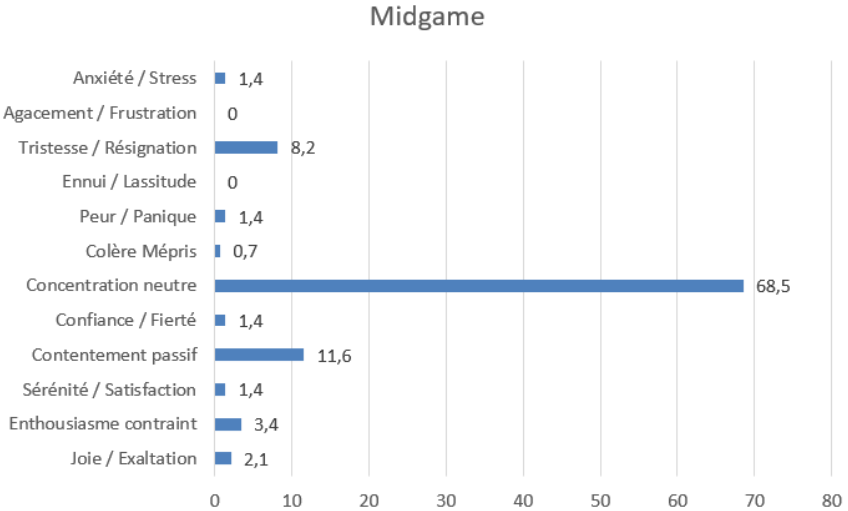


Figure 19 : Emotions Midgame

Sensitivity: C1-Internal

Durant le **midgame**, l'émotion la plus représentée reste la **concentration/neutre** (**68,5 %**). Cette tendance est cohérente avec des scores PAD encore proches d'un état moyen. On observe toutefois une légère baisse de cette émotion par rapport aux phases précédentes. Cette baisse peut être liée aux duels perdus face à l'équipe adverse, ce qui augmente la part de **tristesse/résignation** (**8,2 %**). À ce stade de la game, aucune équipe ne prend clairement le dessus, même si l'avantage semble être du côté adverse. D'autres émotions apparaissent aussi, comme l'**enthousiasme contraint** (**3,4 %**), la **joie/exaltation** (**2,1 %**) et le **contentement passif** (**11,6 %**). Cependant, les scores PAD montrent en général un Plaisir et une Dominance plutôt négatifs, avec une Activation neutre. Cela met en évidence un décalage entre l'analyse directe des scores PAD et l'émotion déduite à partir du tableau utilisé. Ce décalage peut venir de la subjectivité de l'annotation, mais aussi de la métrique utilisée pour associer les scores PAD aux émotions. Cette méthode n'est donc pas toujours assez précise pour représenter finement l'état émotionnel des joueurs.

Malgré cette limite, l'analyse permet tout de même d'identifier une tendance globale : le **midgame** reste principalement marqué par un état de **concentration/neutre**, avec une présence secondaire de **contentement passif**.

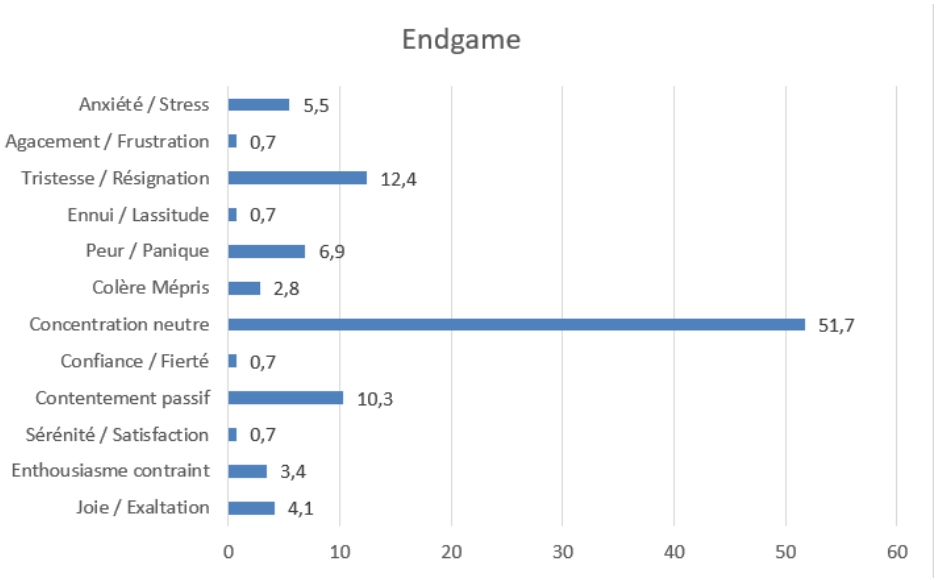


Figure 20 : Emotion Endgame

Durant l'**endgame**, plusieurs émotions se distinguent plus nettement. L'état **concentration/neutre** reste majoritaire (**51,7 %**), mais sa part diminue par rapport aux phases précédentes. On observe aussi davantage de **tristesse/résignation** (**12,4 %**), de **peur/panique** (**6,9 %**) et d'**anxiété/stress** (**5,5 %**). Cette évolution peut s'expliquer par la perte rapide de contrôle en fin de game, avec peu de possibilités de revenir. D'autres émotions restent présentes, comme le **contentement passif** (**10,3 %**), l'**enthousiasme contraint** (**3,4 %**) et la **joie/exaltation** (**4,1 %**). Ces émotions peuvent être liées au début de l'**endgame**, où les joueurs tentent encore d'inverser la tendance. Cette tentative fonctionne partiellement, mais devient rapidement limitée par l'écart entre les deux équipes.

Sensitivity: C1-Internal

Globalement, l'**endgame** permet de capter une plus grande diversité d'émotions. Cela semble lié à la pression de fin de game et à un dénouement de plus en plus difficile à éviter. La méthode permet donc d'identifier les grandes tendances émotionnelles, même si elle reste limitée pour distinguer précisément les nuances entre émotions.

En conclusion, cette métrique fonctionne globalement bien pour obtenir une première interprétation des émotions. Elle présente toutefois certaines limites, liées notamment aux choix arbitraires effectués lors de l'association entre scores PAD et émotions. Cette méthode permet donc une lecture directe des tendances émotionnelles, mais ne couvre pas toutes les nuances que peuvent exprimer les joueurs.

5.2 Résultat annotation automatique

Tout d'abord, les scores **PAD**, initialement compris entre 0 et 1, ont été convertis sur une échelle de 1 à 7 afin de correspondre à notre annotation manuelle. Pour cela, nous avons appliqué une formule de mise à l'échelle : $6x + 1 = y$ avec $x \in [0,1]$ et $y \in [1,7]$. Nous avons ensuite repris la même démarche d'analyse, en étudiant l'évolution des scores **PAD** selon l'ordre des segments audio au cours de la game. Enfin, nous analyserons l'écart entre les scores annotés manuellement et ceux prédits par le modèle.

5.2.1 Résultats PAD

Pour analyser les scores, nous allons les superposer afin d'évaluer la proximité entre les scores annotés manuellement et ceux prédits par le modèle. Les scores ne pourront pas être strictement identiques, car l'annotation manuelle utilise des valeurs entières, tandis que le modèle produit des valeurs décimales. L'analyse sera donc approximative. L'objectif est d'observer si l'enveloppe globale des scores prédits suit la même tendance que celle des scores annotés manuellement.

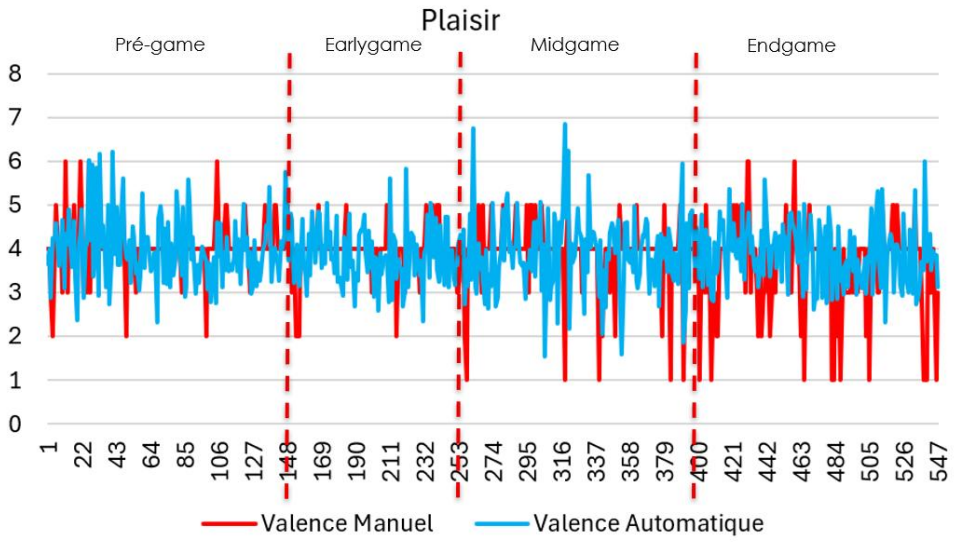


Figure 21 : Evolution du Plaisir entre l'annotation manuelle et automatique 1ère game

Sensitivity: C1-Internal

Pour le score de **Plaisir**, le modèle prédit majoritairement des valeurs proches de la moyenne, autour de 4. En **pré-game**, le modèle capte certains pics de Plaisir, même s'ils ne correspondent pas toujours aux mêmes segments que l'annotation manuelle. En **early game**, les scores sont très proches entre les deux approches. En **midgame**, le modèle détecte davantage de valeurs proches de 7, donc très positives, par rapport à notre annotation manuelle. Il identifie aussi quelques valeurs proches de 1, mais moins fréquemment que dans l'annotation manuelle. En **endgame**, le modèle prédit surtout des valeurs moyennes, autour de 4, alors que notre annotation manuelle tend davantage vers des valeurs proches de 1.

Globalement, les valeurs restent proches sur certaines phases, notamment en **pré-game** et en **early game**. Cependant, des écarts apparaissent sur certains pics : le modèle n'identifie pas toujours les mêmes variations que l'annotation manuelle. À l'inverse, il détecte parfois des pics là où l'annotation manuelle indiquait des valeurs moyennes. Le modèle semble donc plus fiable sur la **pré-game** et l'**early game**, mais moins précis sur le **midgame** et l'**endgame**.

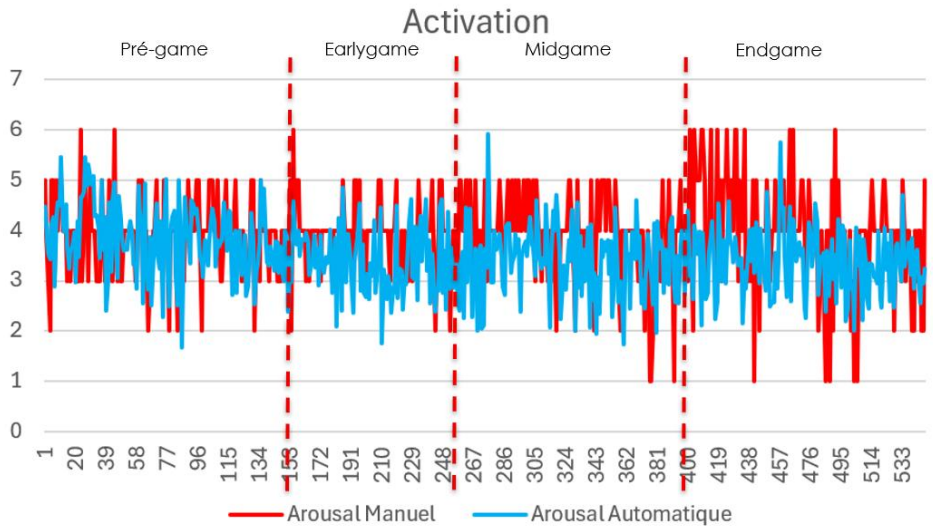


Figure 22 : Evolution de l'Activation entre l'annotation manuelle et automatique 1ère game

Pour le score d'**Activation**, le modèle prédit principalement des valeurs comprises entre 3 et 4. Ces valeurs sont légèrement plus faibles que celles de l'annotation manuelle, dont la moyenne est plutôt proche de 4. En **pré-game**, le modèle capte bien les petits pics positifs et négatifs d'Activation. En **early game**, les scores sont très proches de l'annotation manuelle, même s'ils restent légèrement plus faibles en raison des valeurs décimales produites par le modèle. En **midgame**, le modèle identifie correctement certaines valeurs négatives, mais détecte moins bien les valeurs plus positives, proches de 5. En **endgame**, le score reste globalement stable autour de 3. Le modèle ne capte pas correctement les forts pics positifs ni les forts pics négatifs observés dans l'annotation manuelle.

Globalement, les prédictions du modèle sont légèrement décalées vers des valeurs plus basses. Les pics sont bien détectés en **pré-game** et en **early game**, mais beaucoup moins en **midgame**

Sensitivity: C1-Internal

et en **endgame**. Cette baisse globale reste toutefois cohérente avec le contexte de fin de game, où l'équipe perd progressivement la partie.

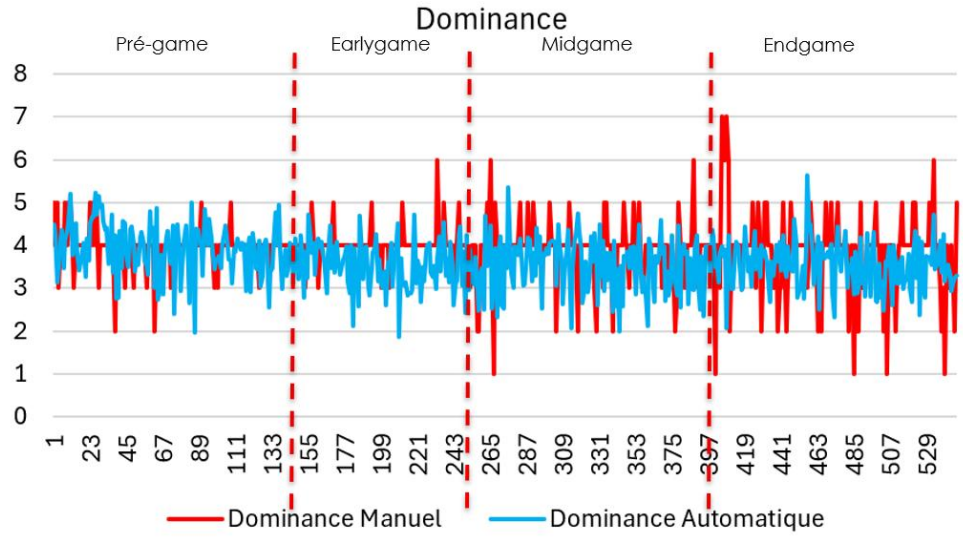


Figure 23 : Evolution de la Dominance entre l'annotation manuelle et automatique 1ère game

Pour le score de **Dominance**, le modèle prédit majoritairement des valeurs proches de 4. Cela correspond globalement à ce qui est observé dans l'annotation manuelle. En **pré-game**, presque toutes les valeurs sont proches entre les deux approches. Le même constat peut être fait pour l'**early game** et le **midgame**, à l'exception de quelques pics significatifs. Dans l'ensemble, les scores restent très proches. En **endgame**, les écarts deviennent plus importants. Plusieurs pics présents dans l'annotation manuelle ne sont pas captés par le modèle.

Ainsi, pour la **Dominance**, les prédictions sont assez fidèles à l'annotation manuelle sur la majorité des segments audio. La principale limite apparaît en **endgame**, où la Dominance perçue devient plus variable. Le modèle ne reflète pas cette variabilité et reste centré autour d'une valeur moyenne proche de 4.

Pour conclure sur les résultats du modèle, les scores prédits restent globalement proches des valeurs perçues par l'annotateur. Les prédictions sont souvent centrées autour de la moyenne, ce qui indique que le modèle représente correctement les tendances générales du modèle PAD. Cependant, lorsque les annotations manuelles présentent des variations plus marquées, avec plusieurs pics, le modèle ne capte pas toujours ces changements. Cette limite peut poser problème pour identifier des états comme le stress ou l'énervement, qui sont importants dans une logique de préparation mentale.

5.2.2 Comparaison différentielle

Nous avons ensuite cherché à quantifier plus précisément les écarts entre les scores **PAD** annotés manuellement et ceux prédits par le modèle. Pour cela, nous avons calculé, pour chaque segment audio, la différence entre le score manuel et le score prédit par le modèle, pour les trois dimensions Plaisir, Activation et Dominance. La valeur absolue de cet écart a ensuite été

Sensitivity: C1-Internal

conservée, puis ramenée à sa partie entière. Cette approche permet d'évaluer l'amplitude des différences entre les deux annotations, indépendamment du sens de l'écart.

Pour le score de **Plaisir**, le modèle présente un écart nul avec l'annotation manuelle dans **66 %** des cas. Dans **30 %** des segments, l'écart est de **1 point**.

Les écarts plus importants restent limités, avec seulement **4 %** des segments présentant un écart inférieur à **2 points**.

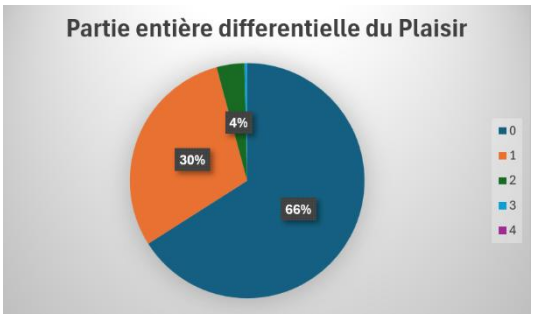


Figure 24 : Quantité de différences significatives du Plaisir

Pour le score d'**Activation**, le modèle présente un écart nul avec l'annotation manuelle dans **73 %** des cas. Dans **23 %** des segments, l'écart est de **1 point**.

Les écarts plus importants restent limités, avec seulement **4 %** des segments présentant un écart de **2 points**.

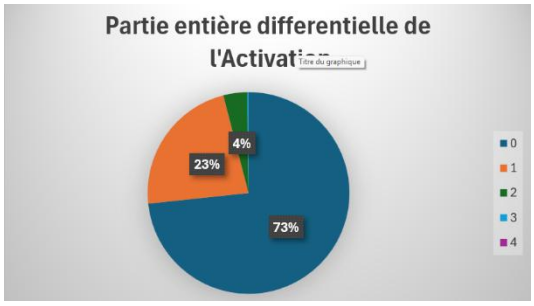


Figure 25 : Quantité de différences significatives de l'Activation

Pour le score de **Dominance**, **75 %** des segments présentent un écart de **0 point** entre le modèle et l'annotation manuelle. **18 %** des segments ont un écart de **1 point**, et **5 %** présentent un écart de **2 points**.

Des écarts plus importants restent rares, avec environ **1 %** des segments atteignant un écart de **3 à 4 points**. Ces résultats montrent que le modèle reste globalement proche de l'annotation manuelle pour la **Dominance**, même si quelques erreurs plus marquées apparaissent ponctuellement.

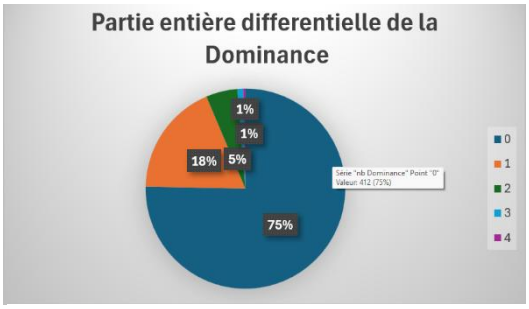


Figure 26 : Quantité de différences significatives de Dominance

Globalement, le modèle présente un écart nul avec l'annotation manuelle pour plus de 2/3 des scores. Les valeurs prédites sont donc très proches des valeurs annotées manuellement, ce qui permet d'être confiant pour la suite du projet. Environ 20 % des scores présentent un écart de **1 point**. Cet écart reste limité, notamment au regard de la subjectivité de l'annotation manuelle et du fait que le modèle a été entraîné sur un *dataset* différent. Le score de **Plaisir** obtient la moins bonne performance. Cela peut s'expliquer par la difficulté du modèle à interpréter et percevoir cette dimension. À l'inverse, le score de **Dominance** présente la meilleure performance globale, mais aussi quelques écarts importants. Ces écarts peuvent être liés à la difficulté de l'annotateur à percevoir précisément les nuances de ce score. Enfin, le score d'**Activation** reste également proche de l'annotation manuelle. Cela peut s'expliquer par des features plus directement liées à cette dimension, et donc plus simples à interpréter pour le modèle.

Sensitivity: C1-Internal

5.3 Features interprétables

Dans un premier temps, nous allons reprendre l'ensemble des *features* interprétables sélectionnées afin de comparer les joueurs entre eux. L'objectif est d'identifier, pour chaque feature, les joueurs qui se différencient le plus. Ensuite, nous analyserons les *features* qui nous semblent les plus pertinentes, en observant leur évolution au cours du match pour chaque joueur. Nous étudierons également les tendances générales entre les différentes phases de la partie. Enfin, nous comparerons notre analyse avec l'annotation manuelle afin d'évaluer s'il existe une corrélation.

5.3.1 Résultats Factuels

Nous avons décidé de représenter les données sous forme de **violin plots** afin de visualiser plusieurs informations à la fois : la moyenne des données, leur dispersion, ainsi que leur répartition volumique.

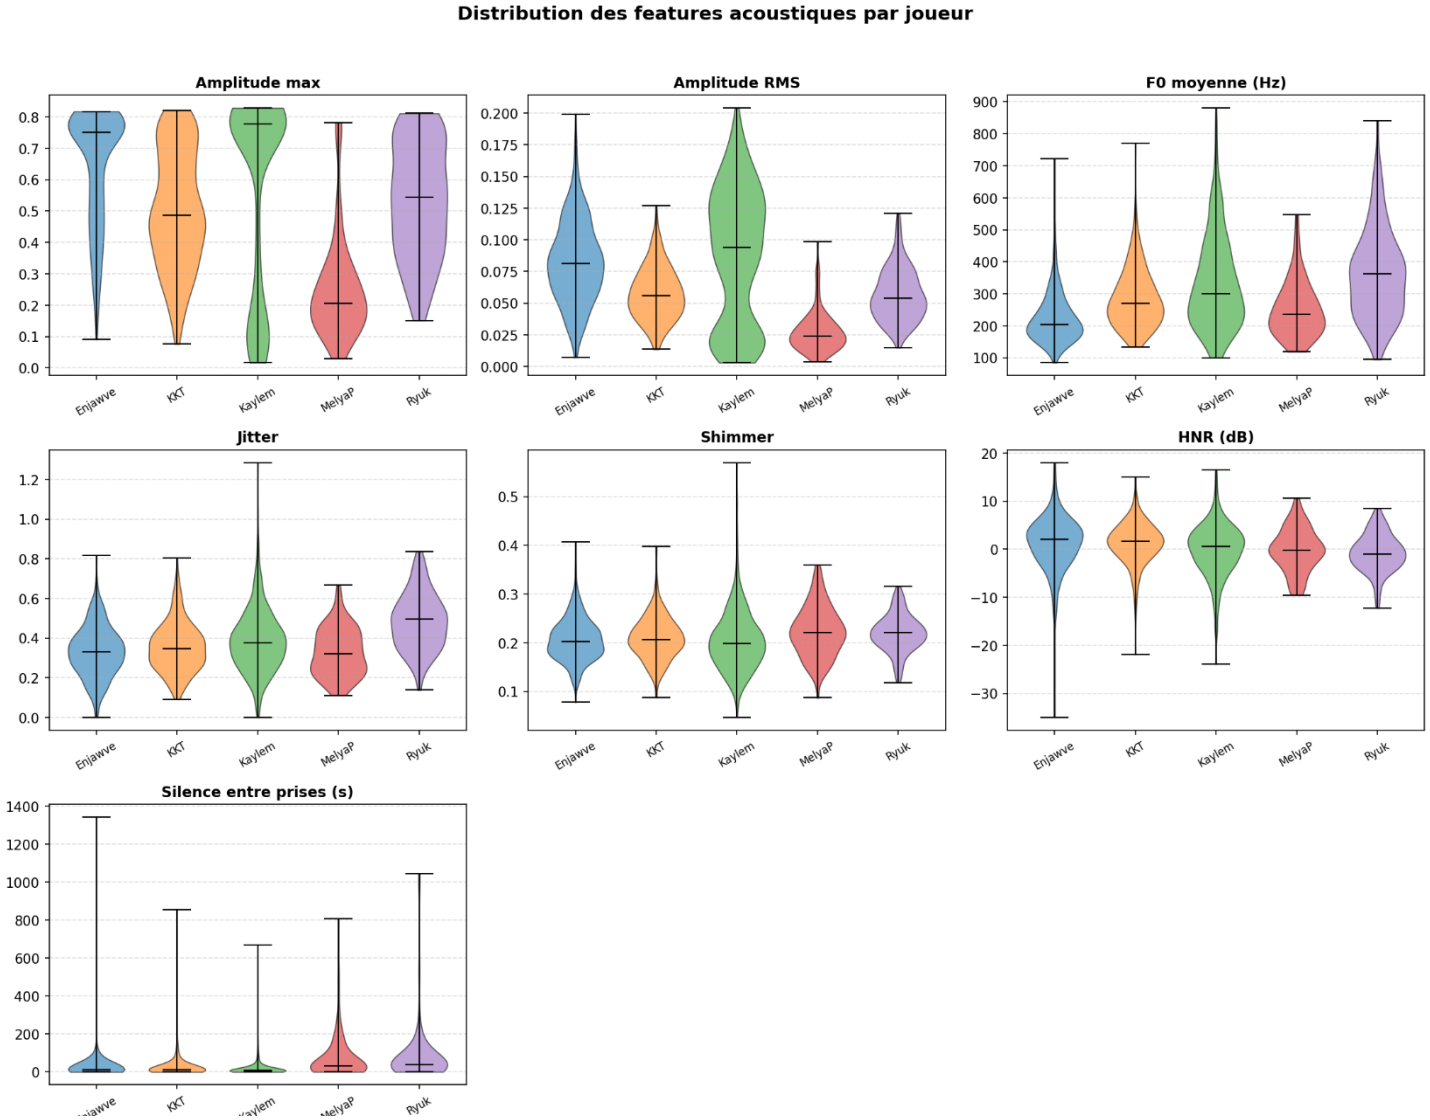


Figure 27 : Distribution des features acoustiques par joueur

Sensitivity: C1-Internal

Amplitude max : Nous pouvons remarquer que les moyennes diffèrent selon les joueurs. Pour Enjawe et Kaylem, les moyennes sont assez élevées, autour de 0.75. De plus, les données sont relativement regroupées autour de cette moyenne, même si certaines valeurs extrêmement basses se situent en dessous de 0.1. À l'inverse, pour KKT et Ryuk, les moyennes sont plus faibles, autour de 0.5, avec une répartition des données plus disparate. Enfin, MelyaP présente la moyenne la plus faible, autour de 0.2. La majorité des données reste proche de cette moyenne, mais quelques valeurs extrêmement hautes apparaissent autour de 0.8.

Amplitude RMS : Nous pouvons remarquer que les moyennes diffèrent selon les joueurs. Pour Kaylem, la moyenne se situe autour de 0.9, avec une répartition assez disparate. On observe également une légère sous-concentration autour de 0.02. Pour les autres joueurs, la répartition est plus uniforme et semble suivre une forme proche d'une distribution gaussienne. Les moyennes sont décroissantes : Enjawe se situe autour de 0.08, KKT et Ryuk autour de 0.055, tandis que MelyaP présente la moyenne la plus faible, autour de 0.025.

F0 moyenne : Pour la fréquence moyenne, les joueurs présentent tous une répartition des données assez uniforme, avec une forme proche d'une bouteille. Les moyennes décroissent de manière linéaire entre les joueurs. Ryuk présente la moyenne la plus élevée, autour de 360 Hz, suivi de Kaylem avec 300 Hz, KKT avec 270 Hz, MelyaP avec 240 Hz, puis Enjawe avec 200 Hz.

Jitter : Pour le Jitter, nous remarquons que la plupart des moyennes sont proches, autour de 0.3, à l'exception de Ryuk, qui présente une moyenne plus élevée, autour de 0.5. Les répartitions sont globalement assez similaires entre les joueurs, sauf pour MelyaP, dont la distribution se distingue davantage. De plus, Kaylem est le seul joueur à présenter des valeurs extrêmement hautes, supérieures à 1.2.

Shimmer : Pour le Shimmer, toutes les moyennes se situent autour de 0.2. Les répartitions présentent toutes une forme plus ou moins gaussienne, ce qui indique une distribution assez similaire entre les joueurs. De plus, Kaylem est le seul joueur à présenter des valeurs extrêmes proches de 0.6.

HNR : Pour le HNR, les moyennes se situent toutes autour de 0 et les répartitions suivent globalement une forme gaussienne. Trois joueurs présentent cependant des valeurs extrêmement basses : Enjawe avec une valeur minimale autour de -37, KKT autour de -22, et Kaylem autour de -24.

Silence entre prises : Pour le temps entre les prises de parole, la plupart des moyennes sont proches de 0 s, avec des répartitions ayant toutes une forme de bouteille. Seuls MelyaP et Ryuk présentent des temps assez élevés entre les prises de parole, avec une moyenne autour de 50 s. Cela semble logique, car ils prennent moins souvent la parole. Ainsi, si leurs interventions sont réparties tout au long du match, le temps entre chaque prise de parole est naturellement plus long. On observe également quelques valeurs extrêmes, mais elles ne nous intéressent pas particulièrement dans cette analyse.

Sensitivity: C1-Internal

Donc, nous allons retenir plus particulièrement les *features* liées à **l'amplitude RMS**, à **la fréquence moyenne**, au **Jitter** ainsi qu'à **la durée entre les segments audios des joueurs**. Ces *features* semblent être celles qui présentent le plus de différences entre les joueurs, et sont donc les plus pertinentes pour la suite de l'analyse.

5.3.2 Comparaison avec l'évolution du match

Nous allons donc analyser l'évolution de ces *features* tout au long de la partie pour chaque joueur : l'amplitude RMS, la fréquence moyenne, le Jitter et la durée entre les segments audios. L'objectif est d'observer comment ces *features* varient au cours du match, et d'identifier d'éventuelles différences de comportement entre les joueurs.

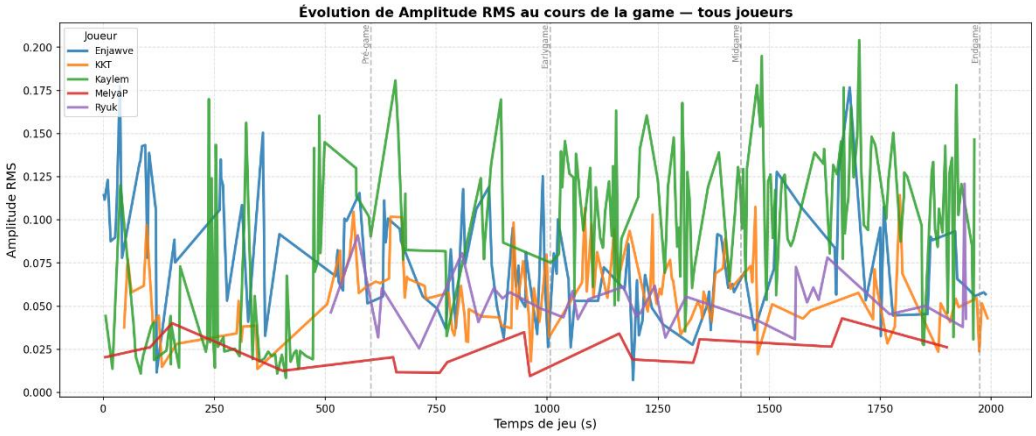


Figure 28 : RMS au cours du match

Nous pouvons remarquer que **Kaylem** est le joueur avec l'**amplitude moyenne** la plus élevée, avec régulièrement des pics au-dessus de **0.150**. **Enjawe** présente également des hausses d'amplitude régulières, surtout lors de la **pré-game**. À l'inverse, **MelyaP** est le joueur avec l'amplitude la plus faible tout au long du match. Pour les autres joueurs, aucun changement significatif n'est observé. En comparant ces résultats avec le déroulement des différentes phases, on remarque que durant la **pré-game**, les joueurs venaient de se retrouver. Ils étaient donc globalement joyeux et parlaient plus fort, ce qui peut expliquer les amplitudes plus élevées.

Ensuite, durant l'**early game** et la **midgame**, les joueurs se sont exprimés moins fortement. Cela peut s'expliquer par une phase de concentration plus importante, mais aussi par le fait qu'ils étaient en train de perdre le match.

Enfin, durant l'**endgame**, les joueurs semblent d'abord avoir eu un regain d'énergie pour tenter de revenir dans le match. Puis, l'énervement lié à la défaite finale peut expliquer l'augmentation de l'amplitude moyenne en fin de match.

Sensitivity: C1-Internal

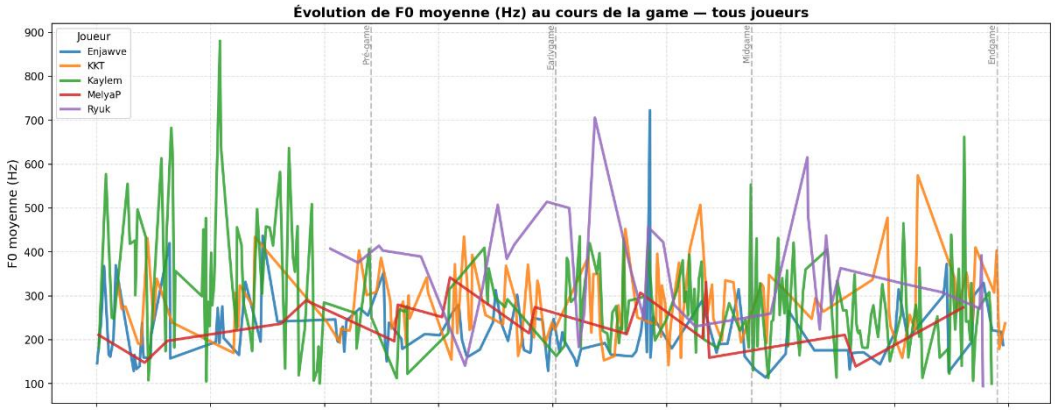


Figure 29 : Fréquence au cours du match

Nous remarquons que, lors de la **pré-game**, **Kaylem** présente régulièrement des pics de fréquence très élevés, dépassant les **500 Hz**. Ces observations peuvent s'expliquer par le contexte des différentes phases du match. Lors de la **pré-game**, les joueurs étaient globalement joyeux, ce qui a pu entraîner des rires et des prises de parole plus enjouées. Cela explique probablement les pics fréquentiels observés.

Ensuite, durant l'**early game** et la **midgame**, les joueurs ont globalement des fréquences plutôt constantes. **Ryuk** se distingue cependant par plusieurs hausses de fréquence dépassant également les **500 Hz**. De plus, **Enjawe** présente un pic important aux alentours de **1200 s**.

Durant l'**endgame**, **Ryuk**, **Kaylem** et **KKT** montrent quelques hausses de fréquence, mais celles-ci restent peu significatives. En fin de match, l'énervement lié à la défaite peut également expliquer certaines hausses ponctuelles de fréquence.

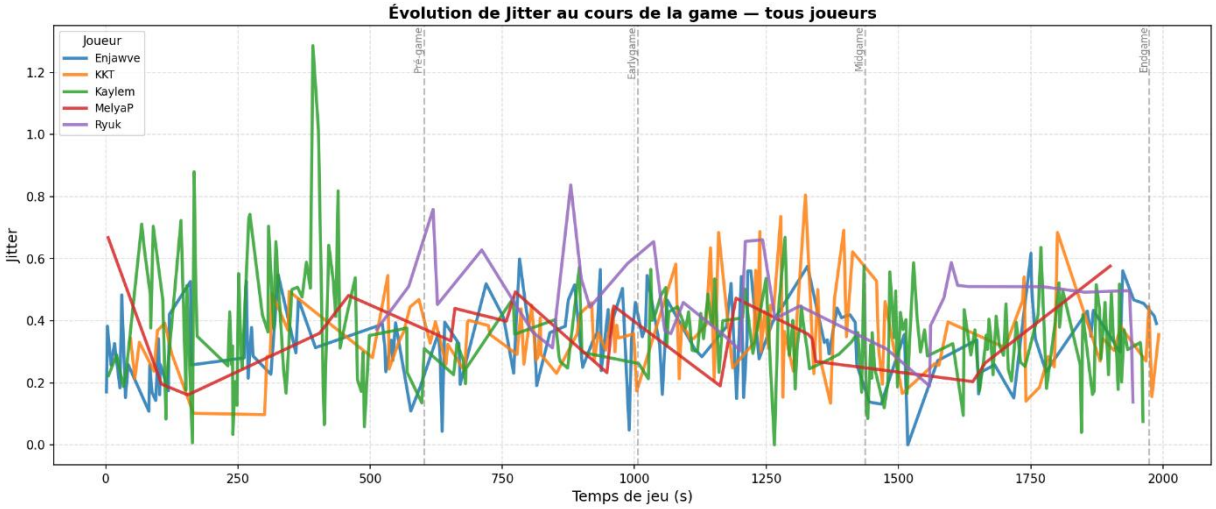


Figure 30 : Jitter au cours du match

Lors de la **pré-game**, **Kaylem** présente la plus forte variation fréquentielle dans la voix, avec des valeurs dépassant **0.6**. Durant l'**early game**, c'est **Ryuk** qui montre le plus de variations, également au-dessus de **0.6**. Ensuite, en **midgame**, **KKT** présente à son tour les variations les plus importantes, avec des valeurs dépassant aussi **0.6**. En fin de partie, ces variations diminuent et deviennent moins marquées.

Sensitivity: C1-Internal

Il n'y a pas forcément d'explication claire concernant ces changements brusques, ni sur le fait que certains joueurs présentent plus de **Jitter** à certains moments précis du match. Cependant, nous pouvons être surpris de constater qu'en fin de partie, malgré l'énervement, les variations de fréquence ne sont ni très fréquentes ni particulièrement importantes.

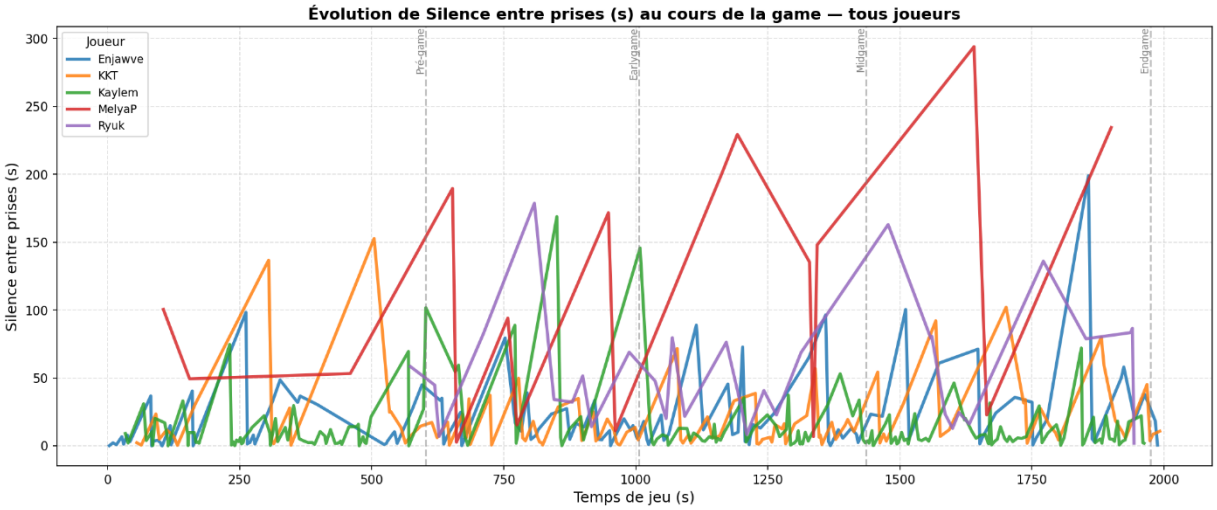


Figure 31 : Durée entre les segments audios au cours du match

Pour l'évolution de la **durée entre les segments audio**, on observe que les intervalles les plus longs concernent **MelyaP**, avec un maximum proche de **300 s**. Ce résultat est cohérent, car il s'agit du joueur avec le plus faible nombre de segments. Durant la **pré-game**, **KKT** présente aussi plusieurs blancs importants entre ses interventions. En **early game**, ces intervalles concernent surtout **Ryuk**, **Kaylem** et **MelyaP**. Cette phase demande davantage de concentration, avec encore peu d'actions en jeu, ce qui peut limiter la prise de parole. En **midgame**, à l'exception de **MelyaP**, les joueurs communiquent plus régulièrement. Quelques blancs restent visibles chez **Enjawve**. En **endgame**, la communication reste active sur une grande partie de la phase. En revanche, à la toute fin, la plupart des joueurs ne parlent presque plus, probablement en raison de la frustration liée à la défaite. Seuls **Kaylem** et **KKT** continuent de communiquer pour tenter de remobiliser l'équipe.

Globalement, **MelyaP** et **Ryuk** présentent les blancs les plus importants, tandis que **Kaylem** et **Enjawve** communiquent plus régulièrement. La communication apparaît donc déséquilibrée entre les joueurs. Même si certains rôles *in-game* favorisent naturellement une prise de parole plus fréquente, les écarts observés suggèrent un problème de communication au sein de l'équipe.

Pour conclure, ces *features* sont intéressantes car elles permettent de capturer certains aspects des émotions durant le match. Les joueurs s'expriment différemment selon les phases de jeu, ce qui apporte du contexte pour mieux comprendre leur état émotionnel.

Bien sûr, ces features ne suffisent pas à déduire une émotion précise à elles seules. Cependant, elles sont complémentaires au score prédit par le modèle et permettent d'avoir une vision plus globale de l'état du joueur à un instant donné.

Sensitivity: C1-Internal

6. Conclusion

Ce projet a permis d'explorer, dans le domaine de la SER, une problématique originale : comment est-il possible de capter les émotions, à postériori, de joueurs professionnels de League of Legends au cours d'un match à partir de leur communication vocale dans une optique de préparation mentale ? Contrairement aux corpus académiques classiques, le contexte eSport impose des contraintes fortes : signal bruité, locuteurs non natifs, segments courts, vocabulaire technique et absence de données annotées spécifiques au domaine.

Pour répondre à cette problématique, nous avons construit une démarche en plusieurs étapes. Un protocole de labélisation fondé sur le modèle PAD (Plaisir, Activation, Dominance) a été mis en place et appliqué à une première partie de Lille eSport (543 segments audio annotés), permettant d'obtenir une première base de comparaison. En parallèle, deux familles de features ont été extraites : des features interprétables (prosodiques, spectrales, de qualité vocale) destinées à l'analyse et à la visualisation, et des embeddings issus du modèle Wav2Vec2-Large, utilisés en entrée d'un modèle de régression pré-entraîné pour prédire automatiquement les scores PAD. Les prédictions du modèle ont ensuite été comparées aux annotations manuelles afin d'évaluer sa capacité à généraliser à notre contexte.

Les résultats obtenus sur cette première partie sont encourageants. L'analyse des scores PAD annotés manuellement fait apparaître une évolution cohérente avec le déroulement de la partie, avec une dégradation progressive du Plaisir et de l'Activation en fin de partie, en lien avec la défaite de l'équipe. La comparaison avec les prédictions automatiques montre un accord satisfaisant : le modèle produit un écart nul avec l'annotation manuelle pour plus de deux tiers des segments, notamment sur les dimensions d'Activation et de Dominance, alors même qu'il n'a jamais été entraîné sur des données eSport. Enfin, l'exploration des features interprétables met en évidence des profils vocaux différenciés selon les joueurs, ouvrant une première piste pour caractériser individuellement l'implication ou le stress ressenti en cours de partie.

Toutefois, ces résultats reposent sur une seule partie annotée par un unique labéliseur, ce qui ne permet pas encore d'évaluer la fiabilité inter-annotateurs, ni la stabilité des tendances observées sur un échantillon plus large de parties et de joueurs. La qualité de la transcription automatique (environ 70 % d'erreurs) et la part de segments inexploitables limitent également l'analyse du contenu verbal. Par ailleurs, le modèle utilisé reste un modèle généraliste, non fine-tuné sur des données eSport, ce qui explique les écarts observés en milieu et fin de partie, phases pourtant les plus critiques pour la préparation mentale des joueurs.

Ce travail constitue ainsi une première brique méthodologique plutôt qu'une solution aboutie. Plusieurs pistes se dégagent pour la suite : élargir la campagne d'annotation à plusieurs parties et plusieurs annotateurs afin de fiabiliser le protocole et de constituer un véritable dataset d'entraînement spécifique à l'eSport ; envisager un fine-tuning du modèle sur ces données annotées ; explorer le clustering non supervisé des features interprétables pour identifier des patterns émotionnels récurrents ; et, à plus long terme, enrichir l'approche par une dimension multimodale (voix, jeu, image) afin de gagner en robustesse et en précision. Ces perspectives permettraient de rapprocher progressivement cet outil d'une utilisation opérationnelle par Lille eSport, dans une logique de préparation mentale et de suivi individualisé des joueurs.

Sensitivity: C1-Internal

7. Ressources humaines

Durant ce projet, nous souhaitons remercier **Amdjed BELAREF**, ingénieur d'études et doctorant au sein d'ALTEN, pour son aide durant la phase de recherche et d'étude de l'état de l'art. Son regard critique sur le protocole de labélisation a permis de mieux le structurer en vue de la campagne d'annotation. Son expertise, issue notamment de ses travaux sur l'étude multimodale des émotions en situation de stress sur la route, a également été précieuse. Nous le remercions pour son écoute, sa disponibilité et sa bienveillance.

Nous remercions également **Omar BOUFOUS**, pilote d'innovation et ingénieur d'études, ainsi que **Youdas**, stagiaire ingénieur de fin d'études, pour leur travail réalisé en amont du projet sur la détection des voix des joueurs. Leur contribution a permis de mettre en place un premier traitement des audios et d'automatiser cette étape, afin d'obtenir un premier pipeline d'analyse et de traitement de la donnée.

Nous souhaitons aussi remercier **Grégoire BIGANZOLI**, stagiaire ingénieur de fin d'études, et **Fabrice DAVY**, ingénieur d'études et consultant ALTEN, pour leurs suggestions et leurs avis sur les pistes explorées, ainsi que sur la manière de traiter la problématique.

Nous remercions également **Malika CHARRAD**, professeure et cheffe du département **Data & IA Program** à l'EFREI Paris, pour son aide et ses idées autour du clustering non supervisé appliqué aux features. Ces pistes ont permis d'envisager l'identification de patterns distincts, utiles pour la reconnaissance de certaines émotions et pour l'entraînement futur d'un modèle capable de les détecter sur de nouveaux segments audios.

Enfin, nous souhaitons remercier nos pilotes, **Sébastien RICCIARDI**, ingénieur d'études et pilote, ainsi que **Manuel CARVALHO**, ingénieur application et pilote, pour leur accompagnement, leur suivi et leur compréhension face à la complexité de ce projet et de ce domaine de recherche en constante évolution.

Merci à chacun d'entre eux. Sans leur aide, ce projet n'aurait pas pu atteindre son niveau actuel.

Sensitivity: C1-Internal

Bibliographie

[1] L.-W. Chen et A. Rudnicky, « Exploring Wav2vec 2.0 fine-tuning for improved speech emotion recognition », 21 février 2023, *arXiv*: arXiv:2110.06309. doi: 10.48550/arXiv.2110.06309.
[2] P. Ekman et W. V. Friesen, « Constants across cultures in the face and emotion », *Journal of Personality and Social Psychology*, vol. 17, nº 2, p. 124-129, 1971, doi: 10.1037/h0030377.
[3] P. Ekman, W. V. Friesen, M. O'Sullivan, A. Chan, et I. Diacoyanni-Tarlatzis, « Universals and Cultural Differences in the Judgments of Facial Expressions of Emotion ».
[4] D. A. Sauter, F. Eisner, P. Ekman, et S. K. Scott, « Cross-cultural recognition of basic emotions through nonverbal emotional vocalizations », *Proc. Natl. Acad. Sci. U.S.A.*, vol. 107, nº 6, p. 2408-2412, févr. 2010, doi: 10.1073/pnas.0908239106.
[5] P. Ekman, « An argument for basic emotions », *Cognition and Emotion*, vol. 6, nº 3-4, p. 169-200, mai 1992, doi: 10.1080/02699939208411068.
[6] R. Plutchik, « A GENERAL PSYCHOEVOLUTIONARY THEORY OF EMOTION », in *Theories of Emotion*, Elsevier, 1980, p. 3-33. doi: 10.1016/B978-0-12-558701-3.50007-7.
[7] A. Mondal et S. S. Gokhale, « Mining Emotions on Plutchik's Wheel », in *2020 Seventh International Conference on Social Networks Analysis, Management and Security (SNAMS)*, déc. 2020, p. 1-6. doi: 10.1109/SNAMS52053.2020.9336534.
[8] J. A. Russell et A. Mehrabian, « Evidence for a three-factor theory of emotions », *Journal of Research in Personality*, vol. 11, nº 3, p. 273-294, sept. 1977, doi: 10.1016/0092-6566(77)90037-X.
[9] J. A. Russell, « A circumplex model of affect », *Journal of Personality and Social Psychology*, vol. 39, nº 6, p. 1161-1178, 1980, doi: 10.1037/h0077714.
[10] C. Kerbrat-Orecchioni, « Chapitre 2. Quelle place pour les émotions dans la linguistique du XXe siècle ? Remarques et aperçus ».
[11] C. Plantin, « Une méthode d'approche de l'émotion dans le discours et les interactions », *SHS Web Conf.*, vol. 81, p. 01001, 2020, doi: 10.1051/shsconf/20208101001.
[12] A. Belaref, S. Sadok, K. M. Ibrahim, et Z. Noumir, « Can AI Decode the Circumplex Model of Affect? A Data-Driven Study ».
[13] A. Belaref, S. Sadok, Z. Noumir, et R. Seguier, « Data-Driven Decoding of Russell's Circumplex Model of Affect », *IEEE TRANSACTIONS ON AFFECTIVE COMPUTING*.
[14] I. Bakker, T. Van Der Voordt, P. Vink, et J. De Boon, « Pleasure, Arousal, Dominance: Mehrabian and Russell revisited », *Curr Psychol*, vol. 33, nº 3, p. 405-421, sept. 2014, doi: 10.1007/s12144-014-9219-4.
[15] G. H. Mohmad Dar et R. Delhibabu, « Speech Databases, Speech Features, and Classifiers in Speech Emotion Recognition: A Review », *IEEE Access*, vol. 12, p. 151122-151152, 2024, doi: 10.1109/ACCESS.2024.3476960.
[16] S. R. Livingstone et F. A. Russo, « The Ryerson Audio-Visual Database of Emotional Speech and Song (RAVDESS): A dynamic, multimodal set of facial and vocal expressions in North American English », *PLoS ONE*, vol. 13, nº 5, p. e0196391, mai 2018, doi: 10.1371/journal.pone.0196391.
[17] M. K. Pichora-Fuller et K. Dupuis, « Toronto emotional speech set (TESS) ». Borealis, 2020. doi: 10.5683/SP2/E8H2MF.
[18] C. Busso *et al.*, « The MSP-Podcast Corpus », 11 septembre 2025, *arXiv*: arXiv:2509.09791. doi: 10.48550/arXiv.2509.09791.
[19] B. Logan et C. Ma, « Mel Frequency Cepstral Coefficients for Music Modeling ».
[20] P. Yadav et V. K. Jain, « MFCC AND LPCC ANALYSIS OF SPEECH SIGNAL FOR DIFFERENT LANGUAGES », vol. 4, nº 12, 2017.

Sensitivity: C1-Internal

[21] H. Gupta et D. Gupta, « LPC and LPCC method of feature extraction in Speech Recognition System », in *2016 6th International Conference - Cloud System and Big Data Engineering (Confluence)*, Noida, India: IEEE, janv. 2016, p. 498-502. doi: 10.1109/CONFLUENCE.2016.7508171.
[22] Y. Atif, « Audio-to-Image Encoding for Improved Voice Characteristic Detection Using Deep Convolutional Neural Networks », 10 mars 2025. doi: 10.36227/techrxiv.174163928.83517889/v1.
[23] Z. Dair, R. Donovan, et R. O'Reilly, « Linguistic and Gender Variation in Speech Emotion Recognition using Spectral Features », 26 octobre 2022, *arXiv*: arXiv:2112.09596. doi: 10.48550/arXiv.2112.09596.
[24] S. Wu, T. H. Falk, et W.-Y. Chan, « Automatic speech emotion recognition using modulation spectral features », *Speech Communication*, vol. 53, nº 5, p. 768-785, mai 2011, doi: 10.1016/j.specom.2010.08.013.
[25] P. Sandhya, V. Spoorthy, S. G. Koolagudi, et N. V. Sobhana, « Spectral Features for Emotional Speaker Recognition », in *2020 Third International Conference on Advances in Electronics, Computers and Communications (ICAECC)*, Bengaluru, India: IEEE, déc. 2020, p. 1-6. doi: 10.1109/ICAECC50550.2020.9339502.
[26] J. Fernandes, F. Teixeira, V. Guedes, A. Junior, et J. P. Teixeira, « Harmonic to Noise Ratio Measurement - Selection of Window and Length », *Procedia Computer Science*, vol. 138, p. 280-285, 2018, doi: 10.1016/j.procs.2018.10.040.
[27] M. Farrús, J. Hernando, et P. Ejarque, « Jitter and shimmer measurements for speaker recognition », in *Interspeech 2007*, ISCA, août 2007, p. 778-781. doi: 10.21437/Interspeech.2007-147.
[28] A. Jacob, « Speech emotion recognition based on minimal voice quality features », in *2016 International Conference on Communication and Signal Processing (ICCSP)*, Melmaruvathur, Tamilnadu, India: IEEE, avr. 2016, p. 0886-0890. doi: 10.1109/ICCSP.2016.7754275.
[29] A. de Cheveigne et H. Kawahara, « YIN, a fundamental frequency estimator for speech and musica) », *J. Acoust. Soc. Am.*, vol. 111, nº 4, 2002.
[30] F. Eyben, F. Weninger, F. Gross, et B. Schuller, « Recent developments in openSMILE, the munich open-source multimedia feature extractor », in *Proceedings of the 21st ACM international conference on Multimedia*, Barcelona Spain: ACM, oct. 2013, p. 835-838. doi: 10.1145/2502081.2502224.
[31] F. Eyben *et al.*, « The Geneva Minimalistic Acoustic Parameter Set (GeMAPS) for Voice Research and Affective Computing », *IEEE Trans. Affective Comput.*, vol. 7, nº 2, p. 190-202, avr. 2016, doi: 10.1109/TAFFC.2015.2457417.
[32] A. Baevski, H. Zhou, A. Mohamed, et M. Auli, « wav2vec 2.0: A Framework for Self-Supervised Learning of Speech Representations », 22 octobre 2020, *arXiv*: arXiv:2006.11477. doi: 10.48550/arXiv.2006.11477.
[33] C. Doğdu, T. Kessler, D. Schneider, M. Shadaydeh, et S. R. Schweinberger, « A Comparison of Machine Learning Algorithms and Feature Sets for Automatic Vocal Emotion Recognition in Speech », *Sensors*, vol. 22, nº 19, p. 7561, oct. 2022, doi: 10.3390/s22197561.
[34] Md. S. Khan, N. Salsabil, Md. G. R. Alam, M. A. A. Dewan, et Md. Z. Uddin, « CNN-XGBoost fusion-based affective state recognition using EEG spectrogram image analysis », *Sci Rep*, vol. 12, nº 1, p. 14122, août 2022, doi: 10.1038/s41598-022-18257-x.
[35] M. Neumann et N. T. Vu, « Attentive Convolutional Neural Network based Speech Emotion Recognition: A Study on the Impact of Input Features, Signal Length, and Acted Speech », 2 juin 2017, *arXiv*: arXiv:1706.00612. doi: 10.48550/arXiv.1706.00612.

Sensitivity: C1-Internal

[36] C. Sun, H. Li, et L. Ma, « Speech emotion recognition based on improved masking EMD and convolutional recurrent neural network », *Front. Psychol.*, vol. 13, p. 1075624, janv. 2023, doi: 10.3389/fpsyg.2022.1075624.
[37] S. Abramov *et al.*, « Analysis of Video Game Players' Emotions and Team Performance: An Esports Tournament Case Study », *IEEE J. Biomed. Health Inform.*, vol. 26, n° 8, p. 3597-3606, août 2022, doi: 10.1109/JBHI.2021.3119202.
[38] N. A. Beres, M. Klarkowski, et R. L. Mandryk, « Playing with Emotions: A Systematic Review Examining Emotions and Emotion Regulation in Esports Performance », *Proc. ACM Hum.-Comput. Interact.*, vol. 7, n° CHI PLAY, p. 558-587, sept. 2023, doi: 10.1145/3611041.

Sensitivity: C1-Internal

Annexe

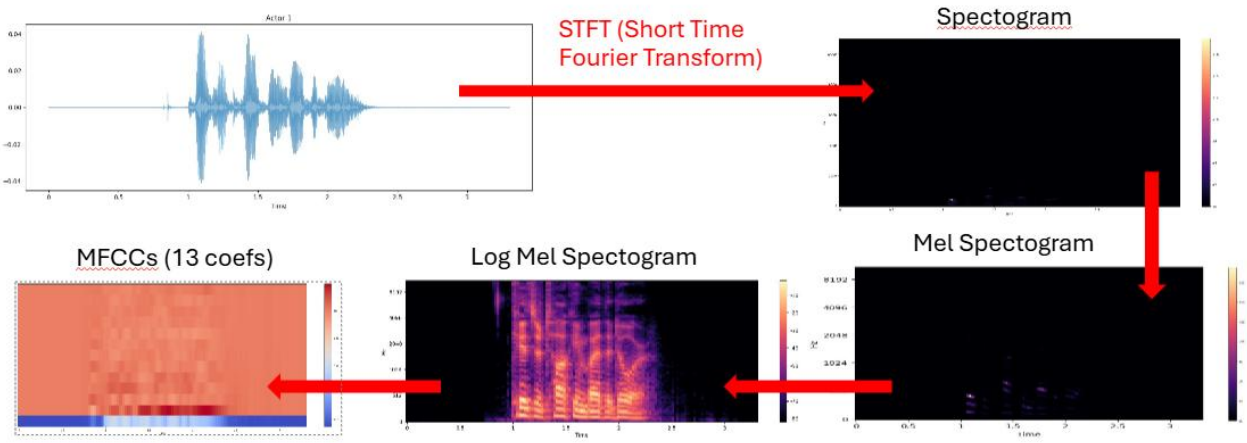


Figure 32 : Construction des MFCCs

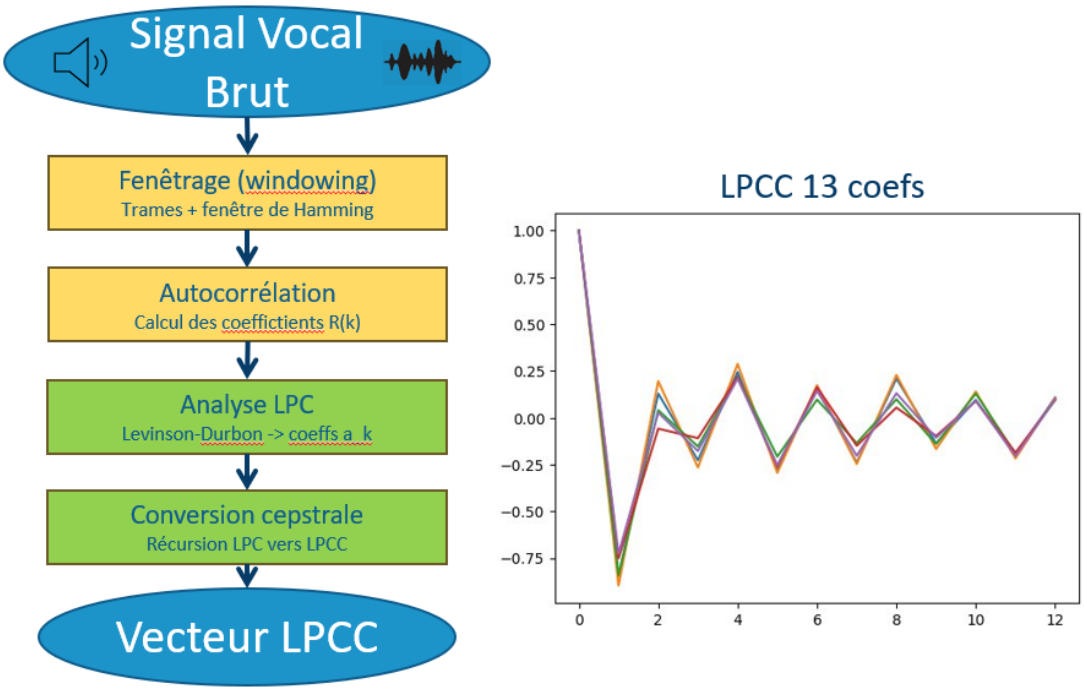


Figure 33 : Construction des LPCCs

Sensitivity: C1-Internal