CONFIDENTIEL

Rapport de stage

Projet de Fin d'Études

Esports TWIN : VoiceCom Analysis

Speech Emotion Recognition



Étudiant : Arthur BERNEL

Pilotes : Sébastien RICCIARDI & Manuel MEIRELES CARVALHO

Tuteur entreprise : Paul VIDOR

Tuteur académique : Abdeslam BENZINOU

09/03/2026 - 11/09/2026

Remerciements

Durant ce projet, je souhaite remercier Amdjed BELAREF, ingénieur d'études et doctorant au sein d'ALTEN, pour son aide durant la phase de recherche et d'étude de l'état de l'art. Son regard critique sur le protocole de labélisation a permis de mieux le structurer en vue de la campagne d'annotation. Son expertise, issue notamment de ses travaux sur l'étude multimodale des émotions en situation de stress sur la route, a également été précieuse. je le remercie pour son écoute, sa disponibilité et sa bienveillance.

Je remercie également Omar BOUFOUS, pilote d'innovation et ingénieur d'études, ainsi que Youdas, stagiaire ingénieur de fin d'études, pour leur travail réalisé en amont du projet sur la détection des voix des joueurs. Leur contribution a permis de mettre en place un premier traitement des audios et d'automatiser cette étape, afin d'obtenir un premier pipeline d'analyse et de traitement de la donnée.

Je souhaite aussi remercier Grégoire BIGANZOLI, stagiaire ingénieur de fin d'études, et Fabrice DAVY, ingénieur d'études et consultant ALTEN, pour leurs suggestions et leurs avis sur les pistes explorées.

Je remercie également Malika CHARRAD, professeure et cheffe du département Data & IA Program à l'EFREI Paris, pour son aide et ses idées autour du clustering non supervisé appliqué aux features. Ces pistes ont permis d'envisager l'identification de patterns distincts, utiles pour la reconnaissance de certaines émotions et pour l'entraînement futur d'un modèle capable de les détecter sur de nouveaux segments audios.

Enfin, je souhaite remercier mes pilotes, Sébastien RICCIARDI, ingénieur d'études et pilote, ainsi que Manuel CARVALHO, ingénieur application et pilote, pour leur accompagnement et leur compréhension face à la complexité de ce projet et de ce domaine de recherche en constante évolution.

Merci à chacun d'entre eux. Sans leur aide, ce projet n'aurait pas pu atteindre son niveau actuel.

Résumé

Lors de mon stage de fin d'études de six mois au sein de la DIN de Toulouse, j'ai travaillé sur le traitement audio dans le cadre d'un projet de reconnaissance automatique des émotions appliqué à une équipe eSport évoluant sur *League of Legends*. L'objectif principal consistait à analyser, a posteriori, l'état émotionnel des joueurs à différents moments d'un match. Les résultats de cette analyse devaient ensuite servir de support à un accompagnement psychologique et mental réalisé par un coach spécialisé. Plus largement, l'ambition du projet était de collecter des données objectives issues des parties jouées afin d'identifier des pistes d'amélioration des performances individuelles et collectives de l'équipe.

Le stage s'est articulé autour de trois grandes phases. La première phase a été consacrée à un état de l'art portant sur la reconnaissance des émotions dans la parole (*Speech Emotion Recognition* ou SER). Cette étape avait pour objectif de comprendre les approches existantes, les jeux de données disponibles et les méthodes les plus prometteuses dans ce domaine. La deuxième phase a porté sur l'expérimentation de différents jeux de données, techniques d'extraction de caractéristiques (*features*) et modèles d'apprentissage automatique. L'objectif était de développer et d'entraîner un modèle capable d'identifier automatiquement les émotions afin de l'appliquer ensuite aux données réelles du projet. Enfin, la troisième phase a consisté à appliquer les méthodes les plus performantes aux données collectées auprès de l'équipe eSport afin d'évaluer la faisabilité et la pertinence des approches étudiées dans un contexte réel.

En pratique, le déroulement du projet n'a pas suivi une progression strictement linéaire. Les trois phases se sont régulièrement alimentées mutuellement. Dès la phase d'état de l'art, plusieurs expérimentations préliminaires ont été menées afin d'orienter les travaux futurs. Par ailleurs, les phases d'expérimentation et d'application aux données réelles ont nécessité de nombreux allers-retours. En effet, certaines méthodes jugées concluantes sur les jeux de données de référence se révélaient plus difficiles à transposer aux données réelles, ce qui imposait de réadapter les approches, d'affiner les paramètres ou de revoir certains choix méthodologiques.

De plus, j'ai testé plusieurs approches alternatives de clustering non supervisé. L'objectif était d'identifier les relations pouvant exister entre les données et de mettre en évidence d'éventuels clusters qui pourraient ensuite être associés à des émotions. Cependant, cette partie reposait principalement sur l'extraction de caractéristiques (features). Elle n'a donc pas pu être appliquée directement aux données réelles et a été réalisée sur un dataset existant, correctement enregistré et annoté.

Abstract

During my six-month final-year internship at the DIN in Toulouse, I worked on audio processing as part of an automatic emotion recognition project applied to an eSports team competing in *League of Legends*. The main objective was to analyze players' emotional states retrospectively at different moments during a match. The results of this analysis were intended to support the psychological and mental coaching provided by a specialized coach. More broadly, the project's ambition was to collect objective data from played matches in order to identify opportunities for improving both individual and team performance.

The internship was structured around three main phases. The first phase consisted of a literature review on Speech Emotion Recognition (SER). The aim of this stage was to gain an understanding of existing approaches, available datasets, and the most promising methods in this field. The second phase focused on experimenting with different datasets, feature extraction techniques, and machine learning models. The objective was to develop and train a model capable of automatically identifying emotions and subsequently apply it to the project's real-world data. Finally, the third phase involved applying the most effective methods to the data collected from the eSports team in order to assess the feasibility and relevance of the studied approaches in a real-world setting.

In practice, the project did not follow a strictly linear progression. The three phases continuously informed and influenced one another. Preliminary experiments were conducted as early as the literature review stage in order to guide future work. In addition, the experimentation and real-data application phases required numerous iterations. Indeed, some methods that produced promising results on benchmark datasets proved more difficult to transfer to real-world data, making it necessary to adapt the approaches, refine the parameters, and reconsider certain methodological choices.

Additionally, I explored several alternative unsupervised clustering approaches. The objective was to identify potential relationships within the data and uncover clusters that could subsequently be associated with emotional states. However, this work relied primarily on feature extraction and therefore could not be applied directly to the project's real-world data. Instead, the experiments were conducted on an existing dataset that was properly recorded and annotated.

Table des matières

1 Remerciements **1**

2 Résumé **2**

3 Abstract **3**

4 Liste des sigles **7**

5 Glossaire **8**

6 Introduction **9**

7 Présentation de l'entreprise **10**
1 Domaine d'activités 10
2 Démarche RSE–RNE d'ALTEN 10
3 Analyse de la pertinence de la stratégie RSE 14

8 Gestion du travail **15**

9 Travail réalisé **16**
4 Contexte technique et objectif technique 16
5 Synthèse critique de l'état de l'art 18
6 Problématique scientifique 26
7 Démarche et travaux réalisés 26
8 Analyse des résultats et interprétations 38
9 Nouvelle approche envisagée 52
10 Conclusion 57

10 Perspectives futures **59**

11 Analyse éthico-technique **60**
11 Solution 60
12 Analyse et évaluation 61
13 Justification et recommandations 61

12 Bilan personnel **62**

13 Bibliographie **63**

14 Annexes **66**

Table des figures

1 Roue de Plutchik . . . 19
2 Cône de Plutchik . . . 19
3 Circumplex Model of Affect . . . 20
4 Circumplex Model of Affect . . . 21
5 Grille PAD - Émotions . . . 27
6 Interface d'annotation . . . 28
7 Pipeline d'extraction des features Wav2Vec2 . . . 33
8 Couche 1 Conv1D . . . 34
9 Couche 2 Conv1D . . . 34
10 Détail d'une couche Transformer . . . 35
11 Pipeline de la tête de régression PAD . . . 36
12 Résultats de la transcription sur le 1er match . . . 39
13 Évolution du Plaisir - 1er match . . . 40
14 Évolution de l'Activation - 1er match . . . 40
15 Évolution de la Dominance - 1er match . . . 41
16 Émotions en pré-game . . . 42
17 Émotions en early game . . . 42
18 Émotions en midgame . . . 43
19 Émotions en endgame . . . 44
20 Évolution du Plaisir entre l'annotation manuelle et automatique - 1ère game . . . 45
21 Évolution de l'Activation entre l'annotation manuelle et automatique - 1ère game 45
22 Évolution de la Dominance entre l'annotation manuelle et automatique - 1ère game . . . 46
23 Distribution des features acoustiques par joueur . . . 48
24 Évolution de l'amplitude RMS au cours du match . . . 50
25 Évolution de la fréquence fondamentale au cours du match . . . 51
26 Évolution du Jitter au cours du match . . . 51
27 Durée entre les segments audio au cours du match . . . 52
28 Transformation de rescaling . . . 56
29 Matrice finale de comparaison . . . 57

30 Diagramme de Gantt . . . 66
31 Méthode K-Means avec Wav2vec2 . . . 66
32 Méthode Agglomerative avec Wav2vec2 . . . 67
33 Méthode Biclustering avec Wav2vec2 . . . 67
34 Méthode SOM avec Wav2vec2 . . . 67
35 Méthode K-Means avec eGempas . . . 67
36 Méthode Agglomerative avec eGempas . . . 67
37 Méthode Biclustering avec eGempas . . . 67
38 Méthode SOM avec eGempas . . . 68

Liste des tableaux

1 Matrice SWOT — Développement durable et RSE (1/2) . . . 10
2 Matrice SWOT — Développement durable et RSE (2/2) . . . 11
3 Risques sociétaux et mesures RSE proposées (1/2) . . . 12
4 Risques sociétaux et mesures RSE proposées (2/2a) . . . 13
5 Risques sociétaux et mesures RSE proposées (2/2b) . . . 13
6 Risques environnementaux et économiques et mesures RSE proposées . . . 14

7 Choix des 3 datasets expérimentaux . . . 23
8 Description des features acoustiques extraites . . . 31
9 Comparaison des scores PAD entre annotation manuelle et prédiction du modèle 47
10 Comparaison des méthodes de clustering avec Wav2Vec2 . . . 54
11 Comparaison des méthodes de clustering avec eGeMAPS . . . 55

12 Analyse éthico-technique comparative entre analyse des émotions avec l'IA ou sans l'IA . . . 61

Liste des sigles

ALTEN Alten est une multinationale française d'ingénierie et de conseil en technologies, leader mondial des services en ingénierie et IT.
CDP Carbon Disclosure Project
CFD Computational Fluid Dynamics (mécanique des fluides numérique)
CNN Convolutional Neural Network (réseau de neurones convolutif)
CSE Comité Social et Économique
CSRD Corporate Sustainability Reporting Directive
CSV Comma-Separated Values (format de fichier tabulaire)
DBSCAN Density-Based Spatial Clustering of Applications with Noise
DIN Direction de l'Innovation (entité d'ALTEN)
eGeMAPS extended Geneva Minimalistic Acoustic Parameter Set
EPI Équipement de Protection Individuelle
GELU Gaussian Error Linear Unit (fonction d'activation)
HNR Harmonic-to-Noise Ratio (rapport harmonique sur bruit)
IA Intelligence Artificielle
ISO International Organization for Standardization
LFL Ligue française de League of Legends
LoL League of Legends
LPC Linear Predictive Coding (codage prédictif linéaire)
LPCC Linear Predictive Cepstral Coefficients
MASE Manuel d'Amélioration Sécurité des Entreprises
MFCC Mel-Frequency Cepstral Coefficients (coefficients cepstraux à l'échelle Mel)
ODD Objectifs de Développement Durable
PAD Pleasure, Arousal, Dominance (Plaisir, Activation, Dominance)
PCA Principal Component Analysis (analyse en composantes principales)
PDI Pôle Documentaire en Ingénierie
PKL Pickle (format de sérialisation d'objets Python)
RAVDESS Ryerson Audio-Visual Database of Emotional Speech and Song
RGPD Règlement Général sur la Protection des Données
RMS Root Mean Square (valeur efficace)
RNE Responsabilité Numérique des Entreprises
RSE Responsabilité Sociétale des Entreprises
SBTi Science Based Targets initiative
SER Speech Emotion Recognition (reconnaissance des émotions dans la parole)
SOM Self-Organizing Map (carte auto-organisatrice)
SVM Support Vector Machine (machine à vecteurs de support)
TESS Toronto Emotional Speech Set
UMAP Uniform Manifold Approximation and Projection
VSS Violences Sexistes et Sexuelles
XGBoost eXtreme Gradient Boosting

Glossaire

Annotateur (ou labéliseur) Personne chargée d'attribuer manuellement les scores émotionnels (ici, les scores PAD) à des segments audio, selon un protocole de labellisation défini.

Backbone Partie centrale d'un modèle de deep learning (ici Wav2Vec2), responsable de l'extraction des représentations profondes du signal, par opposition à la « tête » (head) qui réalise la tâche finale (classification ou régression).

Clustering Méthode d'apprentissage non supervisé consistant à regrouper automatiquement des données similaires en catégories (clusters), sans étiquette préalable.

Dropout Technique de régularisation utilisée pendant l'entraînement d'un réseau de neurones, consistant à désactiver aléatoirement certains neurones afin de limiter le surapprentissage.

Early game / Midgame / Endgame Phases successives d'une partie de *League of Legends* : début de partie (early game), milieu de partie (midgame) et fin de partie (endgame), caractérisées par des dynamiques de jeu différentes.

Embedding Représentation vectorielle dense d'une donnée (ici, un segment audio), produite par un modèle de deep learning et exploitable pour des tâches de classification ou de comparaison.

Feature Caractéristique ou descripteur extrait d'un signal (ici audio), utilisé comme donnée d'entrée pour un modèle d'apprentissage automatique.

Fine-tuning Ré-entraînement partiel d'un modèle pré-entraîné sur un nouveau jeu de données, afin de l'adapter à une tâche ou un contexte spécifique.

Jitter Variation cycle-à-cycle de la période fondamentale du signal vocal, indicateur d'instabilité de la voix.

Mean pooling Opération consistant à calculer la moyenne d'une séquence de vecteurs (ici, une séquence temporelle de représentations) afin d'obtenir un vecteur unique de taille fixe.

Pipeline Enchaînement structuré d'étapes de traitement automatisées appliquées à une donnée, du prétraitement jusqu'au résultat final.

Rescaling Transformation mathématique permettant de ramener des valeurs d'une échelle donnée vers une autre échelle, afin de les rendre comparables.

Scrim Match d'entraînement organisé entre équipes eSport en dehors des compétitions officielles.

Segment audio Extrait sonore de courte durée, isolé à partir d'un enregistrement plus long, constituant l'unité de base d'annotation et d'analyse dans ce projet.

Shimmer Variation cycle-à-cycle de l'amplitude du signal vocal, indicateur d'instabilité de la voix.

Tilt Terme familier du jeu vidéo compétitif désignant un état de frustration ou d'énervement d'un joueur, souvent consécutif à des échecs répétés, pouvant affecter ses performances.

Toplaner Rôle dans *League of Legends* désignant le joueur positionné sur la voie du haut (top lane) de la carte.

Transformer Architecture de réseau de neurones reposant sur un mécanisme d'attention, permettant de capturer des dépendances contextuelles entre les éléments d'une séquence, quelle que soit leur distance.

Introduction

Le monde de l'eSport s'est fortement démocratisé au cours des dernières années. Les tournois majeurs de certains jeux sont devenus des phénomènes de société n'ayant rien à envier aux sports conventionnels, que ce soit en popularité ou en visibilité. Parmi ces compétitions prestigieuses, nous pouvons citer l'ELEAGUE, tournoi majeur de CS GO (Counter Strike Global Offensive), ayant regroupé 1,4 million de visionnages pour une somme de 1 million d'euros à gagner en 2017, ou encore le 7e championnat du monde de Fortnite, qui a été visionné par 2,5 millions de téléspectateurs, avec à la clé, 30 millions d'euros.

Mais un jeu reste maître dans le domaine de l'eSport : LoL. Culminant à 7 millions de spectateurs pour son championnat du monde promettant des récompenses de plusieurs millions, il est la tête de proue du domaine. C'est avec cet essor de popularité que l'eSport a également connu un essor de professionnalisation. En son centre, des coachs et entraîneurs, ayant un besoin perpétuel de données pertinentes. Que ce soit pour l'entraînement, la mise en place de stratégies, le développement de structures, les données se sont révélées un élément clé pour travailler. Ces informations essentielles sont le plus souvent des données techniques de la partie en elle-même, c'est-à-dire des données sur le jeu et les performances de chaque joueur dans le jeu, mais sont rarement des données sur les joueurs eux-mêmes. Pourtant, à l'instar de nombreux jeux professionnels, la préparation des joueurs avant la compétition est primordiale pour leur permettre de faire face au stress, à la panique ou encore à l'exaltation. Pour pouvoir préparer au mieux les joueurs, les communications vocales sont des données essentielles pour comprendre le ressenti des joueurs dans le match et mieux comprendre leurs émotions. Cependant, le travail d'analyse des communications des matchs est fastidieux, car il demande beaucoup de temps et de concentration pour une analyse manuelle. De plus, l'analyse des émotions est subjective et varie selon chacun, et elle est très peu développée dans le milieu de l'eSport. C'est pourquoi nous nous demandons s'il serait possible d'automatiser l'analyse vocale des parties de LoL afin d'en saisir les émotions des joueurs durant les parties.

Avec pour ambition de promouvoir la marque ALTEN, l'entreprise s'est associée à l'équipe eSport de Lille, Lille eSport. Créée en 2021, cette équipe française joue dans l'ancienne division 2 de LFL (ligue française de LoL), la Nexus Ligue. Cette ligue regroupe 8 équipes et dispute des matchs tous les week-ends durant chaque saison. Les objectifs de Lille eSport sont clairs : monter en première ligue de la LFL. Pour ce faire, ils ont fait appel à ALTEN afin d'apporter une expertise technique dans la récupération et l'analyse des données des différentes parties. L'idée est simple : ils veulent avoir un outil pratique qui leur permet de voir concrètement et facilement les erreurs et défauts des parties afin de s'améliorer durablement.

Présentation de l'entreprise

1 Domaine d'activités

ALTEN est une entreprise française de conseil en ingénierie et en technologies fondée en 1988. Présente dans plus de 30 pays, elle accompagne ses clients dans leurs projets de recherche et développement, d'ingénierie et de transformation numérique. Le groupe intervient dans de nombreux secteurs industriels tels que l'aéronautique, l'automobile, l'énergie, les télécommunications, la défense ou encore les sciences de la vie. En 2025, ALTEN comptait plus de 57 000 collaborateurs à travers le monde et réalisait un chiffre d'affaires supérieur à 4 milliards d'euros.

Mon stage a été effectué au sein de la DIN d'ALTEN, qui regroupe les différentes entités ALTEN Labs dédiées aux activités de recherche et d'innovation. J'ai intégré l'équipe ALTEN Labs Sport Science de Toulouse, dont les travaux visent à améliorer la performance sportive grâce au développement de solutions technologiques innovantes. Les projets menés couvrent différents domaines du sport et s'appuient notamment sur l'analyse de données, le développement de capteurs ou l'optimisation d'outils d'aide à la performance. C'est dans ce contexte que s'inscrit mon projet de stage, consacré à la reconnaissance automatique des émotions dans les communications vocales d'une équipe eSport évoluant sur *League of Legends*, avec pour objectif d'apporter des indicateurs objectifs à l'analyse et à l'amélioration des performances des joueurs.

2 Démarche RSE–RNE d'ALTEN

Table 1 – Matrice SWOT — Développement durable et RSE (1/2)

	Positif	**Négatif**
Interne	**Forces** — Score EcoVadis 87/100 (2026) (Score RSE entre toutes les entreprises) — Score sur l'index d'égalité femmes-hommes : 89/100 — Note A- au CDP (Carbon Disclosure Project) — Adhésion au Pacte Mondial des Nations Unies (2010) donc une grande implication internationale — 100 nationalités représentées au sein du groupe, donc une grande diversité — Adhésion aux Women's Empowerment Principles de l'ONU — CSE proposant carte restauration et avantages loisirs (cinéma, piscine...)	**Faiblesses** — Répartition hommes/femmes parmi les cadres dirigeants très déséquilibrée : 84% / 16% — Répartition hommes/femmes dans les instances dirigeantes déséquilibrée : 81% / 19% — Objectif de 30% de femmes cadres dirigeantes non encore atteint (écart à combler d'ici 2030) — Tri sélectif non généralisé (80% des surfaces seulement) — Dématérialisation incomplète (38% des factures encore au format papier) — Forte dépendance au stockage des données et aux capacités de calcul coûteuses (type CFD en mécanique des fluides), donc forte empreinte carbone dans le digital

Table 2 – Matrice SWOT — Développement durable et RSE (2/2)

	Positif	Négatif
Interne	**Forces** — E-learning sur les comportements en entreprise (VSS, organisation du travail...) — Tech-Talks pour approfondir les connaissances métiers — Formations dans divers domaines (IA, bases de données...) — Amélioration continue via la démarche MASE (Sécurité Santé Environnement) — Existence d'un code anti-corruption — Protection des données des employés — Amélioration de la performance énergétique des bâtiments — Promotion de la mobilité durable (vélo, bus...) — Sites certifiés ISO 14001 (système de management environnemental) — E-learning sur les éco-gestes — Accompagnement des clients dans la réduction de leur empreinte carbone — Énergie 100% renouvelable pour les bâtiments à forte puissance souscrite (>36kV) — 80% des surfaces couvertes par le tri sélectif — 62% des factures dématérialisées — 31% des projets R&D orientés innovation environnementale — Participation à la rédaction de la norme ISO 56001 (management de l'innovation)	
Externe	**Opportunités** — Participation à la rédaction de normes ISO (ex. ISO 56001) — Contribution à la réduction du CO_2 des grandes entreprises clientes — Collaboration avec de grandes instances internationales (Nations Unies)	**Menaces** — Dépendance au marché mondial — Dépendance aux évolutions technologiques (IA, stockage des données...) — Augmentation des coûts de déplacement entre consultants

Table 3 – Risques sociétaux et mesures RSE proposées (1/2)

Risques identifiés	Mesures/actions RSE proposées	Niveau de nécessité	Niveau de facilité	Échéance
Obsolescence des savoir-faire face aux évolutions technologiques	Proposer des formations continues (e-learning et Tech-Talks) afin de découvrir ou d'approfondir les compétences de chacun	Important	Moyen	Long terme
Perte d'attractivité sociale	Proposer des avantages concrets aux employés via le CSE, les tickets restaurant ou les aides aux déplacements	Moyen	Facile	Court terme
Techniques managériales inadaptées	Identifier les manières efficaces de diriger des équipes et former les managers afin de concilier gains de productivité et bien-être des employés	Moyen	Moyen	Court terme
Inégalités entre les sexes	Créer des collectifs pour aider les femmes à s'investir et être davantage représentées dans l'entreprise (Women's Empowerment Principles)	Important	Moyen	Court terme
Diversité culturelle	Augmenter l'inclusivité des personnes (parler en anglais durant les réunions) et la mixité culturelle (proposer des événements team building) car plus de 100 nationalités différentes	Important	Moyen	Court terme
Discrimination des personnes en situation de handicap	Augmenter la part des personnes en situation de handicap dans l'entreprise (actuellement 1%) et renforcer l'accessibilité des infrastructures	Important	Difficile	Court terme
Corruption	Obliger les dirigeants à être transparents sur tous les avantages et cadeaux perçus de la part d'autres entités ou tiers internes	Important	Facile	Court terme

Table 4 – Risques sociétaux et mesures RSE proposées (2/2a)

Risques identifiés	Mesures/actions RSE proposées	Niveau de nécessité	Niveau de facilité	Échéance
Lobbying non éthique	S'investir davantage dans un lobbying transparent et équitable	Important	Difficile	Long terme
Structure hiérarchique mal définie	Clarifier le rôle, les responsabilités et les missions de chacun à l'aide d'un organigramme interne	Important	Facile	Court terme
Discrimination interne	Sensibiliser davantage aux personnes vulnérables et aux comportements inappropriés dans l'entreprise (e-learning, formations, signalisation, personne de confiance, affichage, limitation des espaces confinés)	Important	Facile	Court terme
Espaces de travail inadaptés à la productivité	Créer des espaces de travail agréables, à température ambiante adaptée, calmes, et qui limitent la pression et l'intimidation hiérarchique	Important	Facile	Court terme
Espaces de détente non adaptés	Créer suffisamment d'espaces de repos pour limiter la fatigue chronique et physique, avec des espaces adaptés à la restauration et au calme	Moyen	Facile	Court terme
Protestation syndicale	Créer des moments d'écoute et d'échange avec les employés afin de trouver un compromis entre gains de productivité et attentes sociales	Important	Moyen	Court terme

Table 5 – Risques sociétaux et mesures RSE proposées (2/2b)

Risques identifiés	Mesures/actions RSE proposées	Niveau de nécessité	Niveau de facilité	Échéance
Désengagement vis-à-vis des territoires locaux	S'investir davantage dans les villes (écoles, associations, infrastructures, etc.) de chaque pôle de l'entreprise pour bénéficier à l'écosystème local	Important	Difficile	Long terme
Sécurité des employés sur le lieu de travail	Augmenter le nombre de formations préventives sur les risques liés au métier de chacun et adapter les équipements aux tâches prévues avec des EPI adéquats	Important	Facile	Moyen terme

Table 6 – Risques environnementaux et économiques et mesures RSE proposées

Risques identifiés	Mesures/actions RSE proposées	Niveau de nécessité	Niveau de facilité	Échéance
Impact environnemental au sein des infrastructures d'ALTEN	Dispositifs anti-gaspillage (éclairage automatique, tri sélectif, robinets automatiques) et utilisation d'énergie renouvelable pour les infrastructures	Important	Moyen	Long terme
Impact environnemental auprès des partenaires extérieurs	Proposer des solutions durables et des innovations actives via des projets R&D	Important	Facile	Court terme
Cybersécurité des données	Sensibiliser les employés à la cybersécurité avec des formations régulières	Important	Moyen	Court terme
Stabilité économique extérieure	S'impliquer dans les décisions mondiales relatives aux enjeux économiques et dans les entreprises partenaires	Important	Difficile	Moyen terme
Diversité économique de l'entreprise	Éviter la dépendance à un domaine particulier et proposer des solutions transverses (IT, mécanique, automatisme, électronique, etc.)	Important	Moyen	Long terme
Sécurité de l'emploi	Proposer davantage de partenariats avec des écoles et universités	Important	Facile	Long terme

3 Analyse de la pertinence de la stratégie RSE

La stratégie RSE d'ALTEN, structurée autour de l'humain, de l'environnement et de l'innovation durable, présente une gouvernance solide et des engagements reconnus (SBTi, Global Compact, EcoVadis). Elle reste néanmoins perfectible sur plusieurs points essentiels. Le principal défi concerne le Scope 3, qui représente la majeure partie des émissions carbone d'une société de conseil (déplacements, sous-traitance, achats) et sur lequel le groupe conserve une marge de manœuvre limitée. La mixité aux postes à responsabilité demeure également un chantier prioritaire, l'objectif de 30% de femmes cadres dirigeantes n'étant pas encore atteint. Enfin, si l'innovation durable constitue un axe différenciant, l'impact réel des projets menés pour les clients reste difficile à mesurer, alors que cette évaluation devient un enjeu central pour les entreprises de conseil technologique.

Au regard des enjeux actuels : accélération réglementaire (CSRD), attentes croissantes des parties prenantes et nécessité de résultats mesurables plus que d'intentions affichées, la démarche RSE d'ALTEN apparaît globalement pertinente et bien structurée, mais elle doit désormais évoluer vers une logique de résultats concrets et de maîtrise des impacts indirects pour rester à la hauteur des attentes du secteur.

Gestion du travail

Durant mon stage, j'ai bénéficié d'une importante autonomie, tant sur le plan organisationnel que technique. En effet, ce stage constituant les prémices d'un projet plus large d'analyse de données eSport, je devais proposer un plan solide afin d'obtenir de premiers résultats sur un cas particulier de données (les données audio).

Pour la partie bibliographique, j'ai effectué mes recherches à l'aide de Google Scholar, ainsi que des accès fournis par le PDI pour certains sites web. De plus, pour assimiler les concepts les plus complexes, je me suis appuyé sur YouTube et sur des forums afin d'obtenir des explications moins techniques et plus explicites. Pour extraire mes jeux de données ainsi que certains modèles, je me suis tourné vers les plateformes HuggingFace et Kaggle, sur lesquelles amateurs et professionnels partagent des données, résultats et expérimentations menées dans différents domaines.

Pour développer mon projet, j'ai principalement travaillé sous Visual Studio Code comme environnement de développement, en Python, afin d'obtenir rapidement des résultats et de bénéficier d'un accès facile à un grand nombre de librairies existantes. Chacun des sous-projets s'articulait autour de plusieurs fichiers Python, avec un fichier principal (main) pour chacun d'eux. Pour la pipeline des différentes techniques de SER (Speech Emotion Recognition), je suis parti de fichiers au format .wav, classés par locuteur et associés au time code de la partie. J'ai ensuite extrait les features (manuellement ou à l'aide de techniques tierces) au format .pkl grâce à Pickle, une méthode de sérialisation de données binaires, légère et directement exploitable en Python car native au langage. Enfin, les résultats sont le plus souvent des graphiques exportés au format image (.png), tandis que les résultats numériques sont directement sauvegardés au format CSV.

Concernant la gestion de mon projet, une réunion quotidienne (Daily) était organisée afin d'échanger sur les tâches réalisées la veille et sur celles prévues pour la journée. Une réunion hebdomadaire avait également lieu avec les autres membres du projet, rattachés à Paris, qui travaillaient sur la partie préliminaire des données. Il m'arrivait aussi d'organiser des réunions extérieures au projet, qui m'apportaient une aide précieuse dans la manière d'aborder le sujet ou de m'orienter vers des solutions existantes. Enfin, pour gagner du temps sur le cadrage et l'organisation du projet, j'ai utilisé Microsoft Copilot et Mistral AI, mis à disposition par l'entreprise et adaptés à mes besoins.

Pour l'organisation du projet, j'ai de mon côté créé un diagramme de Gantt (cf. figure 30) à l'aide de TeamGantt, outil que j'avais déjà utilisé lors d'un précédent stage. Pour le suivi global des tâches, j'ai utilisé Azure DevOps, à partir de listes de tâches établies lors des réunions. Pour la sauvegarde des avancées techniques, j'ai également utilisé Azure DevOps, via un dépôt (repository) dédié.

Ce rapport a été rédigé avec LaTeX.

Travail réalisé

4 Contexte technique et objectif technique

4.1 Contexte technique

Cette analyse des émotions par la voix s'inscrit dans le domaine scientifique SER (Speech Emotion Recognition) et se base sur les éléments prosodiques de la voix (timbre, hauteur, intensité, etc). Mais, pour pouvoir être plus précis dans la reconnaissance des émotions, une approche multimodale serait la solution la plus pertinente. Cependant, seule l'analyse prosodique est prise en compte dans l'état actuel des travaux.

4.2 Difficulté et objectif technique

4.2.1 Détection des émotions dans un enviornnement vocal bruité

Contexte :
Les modèles SER traditionnels sont généralement entrainés sur des données contrôlées (RAVDESS par exemple), ces jeux de données sont réalisés par des acteurs qui jouent des émotions précises avec de l'entrainement et avec une grande précision dans l'intonation de la voix. Contrairement à notre jeu de données, ou nous pouvons retrouver du bruit in-game, des bruits parasites extérieurs (clavier, souris, microphones), des différences de qualité audio (si un joueur est plus ou moins loin du micro) ou encore des chevauchements de plusieurs locuteurs malgré le prétraitement réalisé. De plus les joueurs ne sont pas des acteurs et vivent réellement les émotions qu'ils traduisent.

Difficulté :
Pour notre cas d'étude, les indices émotionnels sont souvent faibles comparés au bruit présent dans le signal. Par exemple, un joueur frustré et un joueur neutre peuvent présenter des caractéristiques acoustiques similaires lorsque la communication est parasitée. Donc la difficulté sera de bien choisir les audios et les méthodes d'encodage pour avoir une bonne précision.

Objectif :
Obtenir une précision supérieure à 70% sur plusieurs classes émotionnelles malgré la dégradation du signal.

4.2.2 Absence de base de données émotionnelles spécifique à l'eSport

Contexte :
Malgré certaines bases de données conséquentes et non jouées par des acteurs, le cas spécifiques au jeu vidéo et plus précisément à League of Legends rajoute une difficulté supplémentaire. Car les données existantes dans le domaine sont généralement des données issues de contextes plus ou moins généraux pour pouvoir capter le plus de nuance possible et adaptable à plusieurs cas de figure. Les locuteurs sont en plus, généralement tous issues de la même culture, s'exprimant dans la même langue et ne rencontrent donc aucunes difficultés à se comprendre. Alors que notre jeu de données est complexe, avec des termes techniques et très spécifiques à LoL. De plus, les joueurs sont issus de culture différentes (occidentale et orientale) et doivent s'exprimer en anglais, qui n'est pas leur langue maternelle.

Difficulté :
Les émotions exprimées dans l'eSport diffèrent fortement des émotions des corpus académiques. Pour cela, créer un dataset d'entrainement est la solution la plus performante à notre cas. Donc, la difficulté est de créer un protocole de labellisation précis et flexible tout en aillant le plus de fiabilité possible vis-à-vis de la complexité du contexte et au vu des données utilisées.

Objectif :
Construire un système d'annotation performant et adapté à notre jeu de données afin de créer un dataset utile à l'entrainement et à l'évaluation du modèle.

4.2.3 Modèle émotionnel

Contexte :
Certaine étude existe pour essayer de classer les émotions et les différentier entre elles afin de pouvoir les identifier plus facilement. Car, différentier émotion et ressenti est déjà une question complexe que les psychologues, philosophe ou encore les anthropologues cherchent à définir pour mieux appréhender les comportements humains. Dans le contexte de compétitions eSport, la reconnaissance d'une même émotion peut varier d'un joueur à l'autre, d'une situation à une autre et énormément de facteurs sont à prendre en compte, ce qui rend une classification des émotions très compliquée. De plus, la nuance des émotions dites « de bases » est beaucoup plus importante dans le milieu compétitif car une émotion simple comme la colère peut se décliner de plein de manière différente comme le tilt, la rage, l'agacement, etc...

Difficulté :
Les émotions exprimées ne pourront donc pas être catégoriser simplement par des mots figés dont même les définitions peuvent prêter à différentes interprétations. La difficulté est donc de trouver un modèle émotionnel exploitable dans notre cas qui permet de prendre en compte le plus possible d'émotion, sans avoir à faire de compromis entre choisir une émotion car aucune de convient, ou plusieurs à la fois car certaines émotions se mélangent entre elles.

Objectif :
Trouver un modèle émotionnel qui nous permet de mieux comprendre les émotions des joueurs et de pouvoir les classer clairement.

4.2.4 Exploitation temporelle de l'émotion

Contexte :
Les games de LoL durent en générale autour des 40min, ce qui laisse beaucoup d'état émotionnel évoluer au cours du temps. Chaque joueur évolue différemment dans la partie et réagit différemment aux événements de celle-ci. Cependant, nos données d'entrées se contentent seulement de prendre en compte quelques secondes isolées du match, perdant donc le contexte global du match et de son évolution. Ce qui peut conduire à mauvaise interprétation de certaine émotion dû aux évènements précédents non pris en compte.

Difficulté :
La difficulté est donc de prendre en compte tous les segments audios au cours du temps, et de garder en mémoire l'évolution de ceux-ci afin de mieux comprendre les suivant.

Objectif :
Adapter la manière d'annoter les données pour prendre en compte les données précédemment annotées pour que l'évolution de ceux-ci soit la plus cohérente possible.

5 Synthèse critique de l'état de l'art

L'état de l'art a été structuré selon trois axes afin de couvrir l'ensemble des verrous scientifiques et techniques liés au développement d'un système de reconnaissance automatique des émotions vocales dans un contexte eSportif. Ces axes portent respectivement sur les modèles théoriques de l'émotion, l'approche techniques de la SER et les travaux spécifiquement liés à l'eSport. Cette organisation vise à dépasser une analyse descriptive des solutions existantes en identifiant, pour chaque famille de travaux, leur contexte d'application, leurs objectifs, leur apport potentiel, ainsi que leurs limites pour mon projet. Elle permet ainsi de faire apparaître l'écart entre les conditions expérimentales généralement étudiées dans la littérature et les contraintes rencontrées dans un environnement réel de jeu compétitif : bruit, spontanéité de la parole, variabilité inter-joueurs, émotions mixtes, temporalité de la partie et manque de bases de données spécialisées.

5.1 Théorie des émotions

Dans notre étude, nous cherchons une solution technique à un problème en partie psychologique, ce qui ne peut pas être résolu simplement par une division binaire des émotions, comme on pourrait faire pour de la séparation des voix entre locuteurs (qui parle quand). Car nous voulons savoir comment caractériser ces émotions et comment les classer dans notre contexte eSports. En effet, définir une émotion n'est pas chose aisée, la simple définition d'une émotion ne peut pas nous donner la manière de la percevoir ou de l'identifier clairement. De plus, certaines émotions ne sont pas comprises de la même manière entre les individus et les cultures, ce qui pose un problème si l'on veut faire de l'identification avec un seul modèle. Enfin, les dénominations des émotions ne sont pas globales et intrinsèques, elles sont variables entre elles et peuvent même se croiser entre émotions, par exemple une même expérience peut être classée sous plusieurs émotions proches et leurs catégories peuvent se chevaucher. Ce qui pose une réelle question de savoir comment classer les émotions vis-à-vis des données audios réalistes que nous avons. Ce domaine d'étude s'inscrit davantage dans une démarche anthropologique et psychologique, qu'une étude technique d'ingénierie. C'est encore un domaine actif et toujours en évolution.

5.1.1 Ekman

Tout d'abord, une première étude menée par Paul Ekman dans les années 1970 [13] montre qu'il existe un nombre limité d'émotions fondamentales, universelles, reconnaissables par tous et associées à des expressions faciales spécifiques. Ces émotions incluent : la colère, la tristesse, la peur, le dégoût, la joie et la surprise, et sont considérées comme une base biologique innée [14], [34]. Par la suite, Paul Ekman (1992) [12] précise que ces émotions ont émergé au cours de l'évolution pour leur valeur adaptative, permettant une réponse rapide et efficace face à des situations vitales pour l'individu. Elles se caractérisent par une apparition rapide, une durée brève et un déclenchement souvent automatique, reposant sur des mécanismes d'évaluation largement non conscients. Chaque émotion se distingue également par des profils physiologiques et des contextes déclencheurs spécifiques, tout en partageant des propriétés communes qui les différencient d'autres états affectifs, tels que les humeurs ou les traits émotionnels. Ces catégories constituent ainsi une base théorique largement adoptée pour l'analyse émotionnelle, en particulier dans l'étude des liens entre cognition, émotion et comportement.

Forces :

— L'aspect universel des émotions primaires permet de s'assurer d'une certaine base émotionnelle entre cultures

— Base de nombreuses études scientifiques sur le sujet
— Le lien de causalité entre émotion et comportement est directement lié au contexte
— La définition d'un panel d'émotions primaires assez significatif

Limites :

— Ses études se limitent aux expressions faciales et ne concernent pas les émotions vocales
— Le manque de diversité d'émotions ne permet pas de couvrir l'ensemble des états émotionnels
— Un manque de classification entre ces émotions primaires pour ensuite les distinguer

5.1.2 Plutchik

Robert Plutchik (1980) [30] propose un modèle psycho-évolutionnaire dans lequel les émotions complexes émergent à partir de combinaisons d'émotions primaires organisées selon des relations d'opposition et de proximité. Représentées sous la forme d'une roue (cf. figure 1), ces émotions sont structurées en paires de pôles opposés (par exemple joie–tristesse, confiance–dégoût), ce qui confère au modèle une forte valeur explicative tant sur le plan théorique que méthodologique. Cette roue organise ainsi huit émotions primaires réparties en quatre paires antagonistes, chacune pouvant varier en intensité et se combiner avec les émotions voisines pour former des états affectifs plus complexes, appelés émotions secondaires ou dyades.

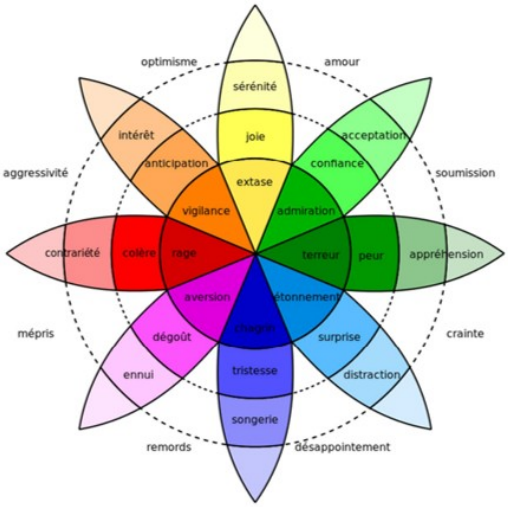


FIGURE 1 – Roue de Plutchik

De plus, cette roue peut être représentée sous la forme d'un cône en 3D (cf. figure 2), car chaque émotion possède une intensité propre. Par exemple, pour la colère, l'intensité la plus élevée correspond à la rage, tandis que l'intensité la plus faible correspond à l'agacement.

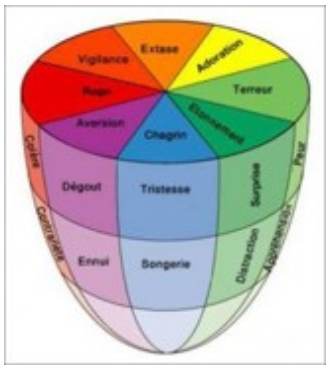


FIGURE 2 – Cône de Plutchik

Cette approche légitime conceptuellement la représentation des émotions secondaires comme des constructions dynamiques issues d'émotions primaires. Dans le domaine de l'analyse automatique des émotions, cette structuration a notamment été exploitée par Mondal et Gokhale (2020) [26], qui montrent que l'organisation en paires d'émotions opposées issue de la roue de Plutchik se prête naturellement à des problèmes de classification binaire, facilitant ainsi la détection émotionnelle dans les textes. Leurs résultats soulignent toutefois que, malgré leur opposition théorique, certaines paires émotionnelles sont inégalement discriminables en pratique, ce qui met en évidence la complexité cognitive et contextuelle des émotions secondaires.

Forces :

— La classification d'émotion par opposition permet de structurer les émotions entre elles à partir de leur parité

— L'intensité des émotions permet de graduer les émotions afin de découper les émotions primaires en familles d'émotion à partir d'un paramètre : l'intensité

— L'association des émotions primaires permet de créer des nouvelles émotions, émotions secondaires, qui élargit le panel d'émotion définit

— La construction dynamique des émotions, comme celui des couleurs, permet de créer de nouvelle émotion qui ne serait pas définit avec des dénominations existantes

Limites :

— Manque de clarté sur les éléments de comparaison pour des émotions secondaires

— Manque de flexibilité entre les émotions primaires, car une émotion ne se définit pas seulement à sa définition mais aussi par son contexte

— Cloisonnement des émotions entre elles, ce qui ne permet pas facilement de comprendre comment passer d'une émotion à une autre

5.1.3 Russell

Les modèles dimensionnels, tels que le modèle PAD développé par Albert Mehrabian et James A. Russell (1977) [32], décrivent les états émotionnels selon des axes continus, avec la Valence (plaisir/déplaisir), l'Activation (niveau d'excitation) et la Dominance (sentiment de contrôle).

En 1980, James A. Russell propose d'avoir une continuité dans le classement des émotions. Il va montrer qu'elles peuvent toutes se trouver dans un même espace à 2D (valence-arousal), il l'appelle le Circumplex Model of Affect [31] (cf. figure 3). Dans le modèle PAD, les émotions jouent un rôle médiateur entre les stimuli environnementaux et les comportements, orientant les réponses d'approche ou d'évitement. Ces cadres théoriques permettent ainsi de rendre compte des proximités et des transitions graduelles entre les états affectifs, plutôt que de frontières catégorielles strictes. Ils soutiennent également l'idée que les émotions se déploient selon des axes dynamiques, sensibles au contexte ainsi qu'aux variations cognitives et environnementales.

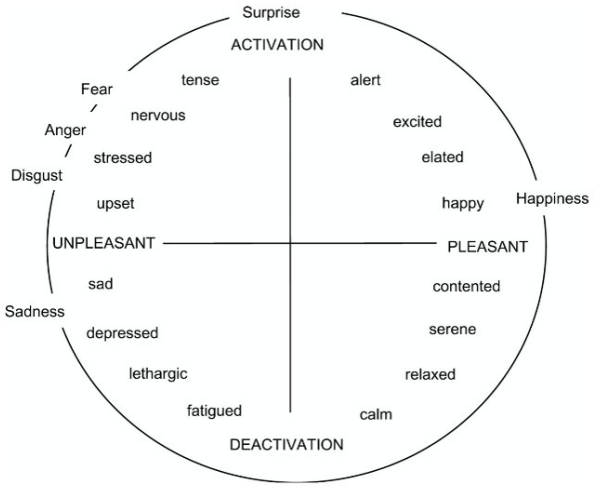


FIGURE 3 – Circumplex Model of Affect

Les travaux en linguistique pragmatique de Kerbrat-Orecchioni (2000) [21] soulignent que les termes émotionnels employés dans le discours ne reflètent pas nécessairement l'émotion réellement ressentie par le locuteur. Comme elle l'établit, les émotions procèdent à la fois des mots de la langue, de la manière de s'exprimer et de la réalité de la situation de communication. Le sens émotionnel d'un énoncé se construit ainsi au sein de l'interaction, en fonction du contexte et des intentions communicatives.

Dans la continuité de cette réflexion, Plantin (2020) [29], distingue les véritables termes d'émotion, qui nomment directement un état affectif, des mots à orientation émotionnelle, dont la dimension émotionnelle dépend surtout du contexte dans lequel ils sont utilisés. Cette

distinction est particulièrement visible dans le langage familier. Par exemple, le terme « dégoûté » est souvent employé pour exprimer une déception ou une frustration, sans pour autant renvoyer à l'émotion de dégoût au sens strict.
Plantin souligne également que les émotions ne sont pas de simples réactions automatiques à une situation. Elles peuvent être expliquées, justifiées ou discutées dans l'échange. Ainsi, les émotions sont envisagées comme des constructions cognitives et linguistiques dont le sens se construit et se négocie au cours des interactions.
Cette variabilité sémantique rend nécessaire une analyse contextuelle approfondie, prenant en compte non seulement le lexique, mais également les implicites, les dynamiques interactionnelles et l'ensemble des choix discursifs du locuteur. Elle justifie également le recours à un espace de représentation continu plutôt qu'à un ensemble de catégories discrètes.

À cet égard, les travaux de Belaref et al. [4], [5] apportent un éclairage décisif. Partant du constat que les modèles catégoriels, comme celui d'Ekman, offrent une granularité insuffisante pour rendre compte de la richesse des états affectifs, ils s'appuient sur le modèle circulaire de Russell, qui organise les émotions dans un espace continu selon deux axes : la valence (négatif à positif) et l'arousal (de calme à excité). Leurs résultats montrent qu'une approche multimodale permet de retrouver automatiquement cette structure circulaire, démontrant ainsi que l'organisation dimensionnelle des émotions est intrinsèquement encodée dans les espaces latents (cf. figure 4) appris, et non un simple artefact du processus d'annotation humaine.

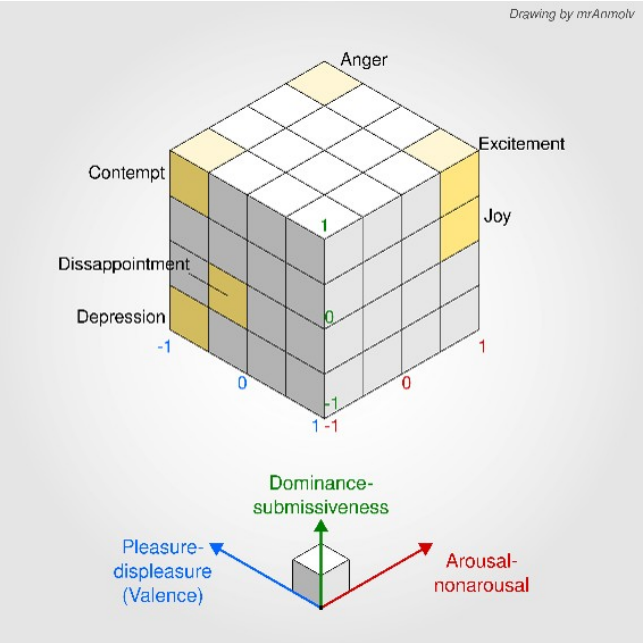


FIGURE 4 – Circumplex Model of Affect

Forces :

— Les émotions se différencient par un score à seulement 3 critères

— Le score PAD est un score interprétable par l'humain et applicable à l'ensemble des émotions afin de les catégoriser

— Ce score s'inscrit dans un espace latent qui permet de mieux appréhender la continuité des émotions entre elles et leur flexibilité vis-à-vis de l'interprétabilité.

— Ce modèle est exploitable dans un contexte technique car il limite le biais de subjectivité à 3 critères et permet d'utiliser des modèles mathématiques pour placer et reconnaitre des émotions.

Limites :

— Difficulté d'attribution du score, car même si les critères sont clairs, il peut être difficile de différencier des valeurs très proches.

— Malgré la limitation de la subjectivité à 3 critères, ce biais reste néanmoins présent et peut biaiser l'interprétabilité.

— Certains scores ne sont pas qualifiables dans le lexique émotionnel car certain mot n'existe tout simplement pas, donc difficulté d'explicabilité.

— Au contraire, un mot émotionnel peut être attribué à plusieurs score à la fois, dû à leur nombreuse définition, donc il ne suffit pas de répondre par des mots mais aussi par un contexte.

5.1.4 Conclusion

S'inscrivant dans notre perspective d'une annotation simple mais précise, nous retiendrons pour notre étude une approche fondée sur le modèle PAD (Plaisir–Activation–Dominance), qui étend le modèle de Russell en ajoutant une troisième dimension, la dominance, permettant de capturer des nuances supplémentaires telles que le sentiment de contrôle ou de soumission face à une situation [3]. Ce modèle tridimensionnel permettra d'attribuer à chaque échantillon audio trois scores compris entre -1 et 1, positionnant ainsi chaque donnée dans un espace latent émotionnel continu et interprétable.

5.2 Approches techniques de la reconnaissance vocale des émotions

5.2.1 Dataset

Il existe une multitude de dataset sur le sujet mais avec des manières différentes d'annotation, de création et d'enregistrement. Pour ce faire, nous avions besoin de classer les différents dataset existants avant de pouvoir réellement les exploiter. C'est pour cela, que nous nous sommes basés sur une liste référençant tous les dataset produit sur le sujet, depuis 1997, avec chacun leurs caractéristiques propres [25]. Nous avons choisi 3 dataset différents pour entrainer nos modèles afin de voir lesquels est le plus pertinent par rapport à notre jeu de données.

Table 7 – Choix des 3 datasets expérimentaux

Dataset	**RAVDESS**	**Toronto Emotional Speech Set Data (TESS)**	**MSP-Podcast**
Contenu	1440 fichiers audios issus de 24 acteurs nord-américain (12 hommes et 12 femmes) soit 60 fichiers par personne	2800 fichiers audios issus de 2 actrices anglophones différentes avec 200 mots prononcés pour chaque émotion	151 654 audios annotés à partir de podcast anglophone
Description	Dataset free access avec 8 émotions jouées (calme, joie, tristesse, colère, peur, surprise, dégout et neutre). Bonne qualité audio [23]	Dataset free access avec 7 émotions jouées (colère, peur, dégout, joie, neutre, tristesse et surprise). Bonne qualité audio [28]	Dataset free access issu de personne ne jouant pas les émotions et interagissant entre elles dans un contexte précis, annoté selon un protocole strict avec différent annotateur (enlevé le biais de subjectivité. Annoté sur 3 critère (PAD) de 1 à 7, puis déduction des émotions qui se rapprochent du score [7]
Forces	Large panel différent de personne, loctueur anglophone pour garder une similarité et annoté sur 8 émotions différentes et précises	Beaucoup de données à partir de mots différents, dataset anglophone pour garder une similarité et annoté de façon clair sur 7 émotions	Beaucoup de données à partir de mots différents et contextes variés, anglogphone pour garder la similarité, annotation clair sur 3 critères émotionnels et une grande quantité d'annotateur pour enlevé le biais de subjectivité.
Limites	Peu d'audio par locutueur, aucune hétérogénéité du dataset (même culture et langage), amplification des émotions car produites par des acteurs, peu d'émotions différentes jouées ne couvrant pas l'ensemble du spectre émotionnel	Aucune hétérogénéité des acteurs (2 femmes anglophone), amplification des émotions car jouées, ne comporte pas beaucoup de locuteur et le peu d'émotion jouées ne couvre pas l'ensemble du spectre émotionnel	Aucune hétérogénéité des locuteurs (anglophone) et contexte de podcast avec des sujets généraux mais différents du contexte eSport. La méthode d'annotation n'est pas évidente et n'exclue pas les doutes et divergence entre les annotateurs

5.2.2 Extraction des caractéristiques

Deux grandes approches coexistent dans la littérature SER pour transformer le signal vocal brut en une représentation exploitable par un modèle : l'extraction de features acoustiques, construites manuellement ou via des outils standardisés, et l'apprentissage de représentations profondes par des modèles auto-supervisés.

Les features manuelles reposent sur des grandeurs physiques directement interprétables. Elles peuvent être regroupées en trois familles complémentaires : des features temporelles (dynamique et énergie du signal), des features fréquentielles (répartition spectrale), et des features de qualité vocale (stabilité et régularité de la voix). Parmi les plus utilisées, les MFCC offrent une représentation compacte et standardisée de la forme globale du spectre vocal [24], [37], tandis que les LPC/LPCC, fondés sur un modèle physique de production de la parole, ap-

portent une information complémentaire liée aux formants [19]. D'autres descripteurs globaux énergétiques (RMS, enveloppe d'amplitude), spectraux (centroïde, bande passante, flatness, contraste, rolloff [1], [10], [36], [33]), ou de qualité vocale (HNR [18], jitter, shimmer [17], [20], F0 estimée par l'algorithme YIN [9]) permettent de couvrir un spectre plus large de dimensions acoustiques. Ces features restent toutefois fortement dépendantes du protocole d'extraction et des conditions d'enregistrement, ce qui limite leur robustesse sur des communications courtes, bruitées ou avec voix superposées. Pour dépasser cette limite tout en conservant l'interprétabilité, des outils standardisés comme OpenSMILE ont été développés [16]. L'ensemble eGeMAPS propose notamment 88 descripteurs sélectionnés pour leur pertinence perceptive et leur robustesse [15], ce qui en fait une référence largement utilisée comme baseline dans la littérature SER.

À l'opposé de ces approches manuelles, les modèles auto-supervisés comme Wav2Vec2-large apprennent directement une représentation du signal audio brut, sans définition a priori des descripteurs à extraire [8], [2]. Pré-entraînés sur de grandes quantités de parole non annotée, ces modèles capturent des informations acoustiques, prosodiques et contextuelles plus riches, au prix d'une perte d'interprétabilité et d'un coût computationnel plus élevé.

5.2.3 Méthode de classification des émotions

Plusieurs approches sont mobilisées dans la littérature pour prédire une émotion à partir des features extraites. Les méthodes classiques de machine learning, telles que les SVM ou le XGBoost, s'appuient sur des features acoustiques extraites manuellement ou via des outils standardisés comme eGeMAPS. Elles présentent l'avantage d'être efficaces avec peu de données annotées, peu coûteuses en calcul et facilement interprétables [11], [22], mais restent dépendantes de la qualité des features en amont et ne capturent pas les dépendances temporelles du signal vocal.
Les CNN (Convolutional Neural Network) appliqués sur ces mêmes features constituent une approche intermédiaire, capable d'apprendre des combinaisons non linéaires entre descripteurs, au prix d'une perte d'information temporelle fine et d'une dépendance plus forte au volume de données disponible [27], [35].

À l'inverse, les modèles de type Wav2Vec2 encodent directement le signal audio brut à l'aide de couches convolutives puis d'un Transformer, capturant le contexte global grâce au mécanisme d'attention, avant qu'une couche de classification légère ne prédise l'émotion [8], [2]. Cette approche permet de mieux généraliser à des émotions subtiles, au prix d'une interprétabilité plus faible et d'une dépendance forte au volume de données pour entraîner la tête de classification.

5.3 Emotion dans l'eSports

5.3.1 Reconnaissance des émotions appliquée à l'eSport

Abramov et al. ont mené une étude de cas sur un tournoi eSport (Team Fortress 2), en collectant des enregistrements audios et des logs de jeu réels afin d'entraîner un classifieur d'émotions à partir de la voix des joueurs. Ne disposant pas d'émotions annotées sur leurs propres données, les auteurs ont entraîné leur modèle sur un jeu de données public annoté (RAVDESS), puis l'ont appliqué à leur corpus eSport, atteignant une précision de 92,7 % sur une classification à six classes d'émotions. Les résultats montrent une corrélation forte entre la performance de l'équipe, la fréquence de communication entre joueurs et le ton émotionnel de leurs échanges, les équipes les plus performantes communiquant davantage et de façon plus positive [35].

Forces :

— Validation en conditions réelles de compétition, contrairement à la majorité des études de SER menées sur des corpus acted en laboratoire

— Mise en évidence d'un lien mesurable entre émotions vocales et performance d'équipe, ouvrant la voie à des applications concrètes pour le coaching eSport

Limites :

— Absence d'émotions réellement annotées sur le corpus eSport, le classifieur étant entraîné sur un jeu de données externe (RAVDESS) puis simplement appliqué aux données du tournoi

— Bruit ambiant important (clavier, souris, discussions parasites) nécessitant l'ajout artificiel de classes de bruit de fond pour rendre le modèle robuste

— Jeu de données d'entrainement (RAVDESS) limité et ne peut couvrir toutes les émotions si l'on veut réellement identifier les émotions des joueurs

5.3.2 Rôle des émotions sur la performance et leur régulation

La revue systématique de Beres et al. synthétise 32 études portant sur le rôle des émotions dans la performance en eSport, ainsi que sur les stratégies de régulation émotionnelle employées par les joueurs. Les auteurs montrent que les émotions positives sont globalement associées à une meilleure performance, tandis que les émotions négatives (colère, frustration, tilt) ont un effet plus ambigu, certaines études rapportant même un effet bénéfique de l'anxiété modérée sur la performance. Les joueurs eSport ont par ailleurs tendance à privilégier des stratégies d'évitement plutôt que des stratégies de régulation active, notamment en raison du rythme rapide des compétitions qui laisse peu de place à une gestion réfléchie des émotions [6].

Forces :

— Lien entre émotions et performance en eSport

— Mise en évidence du besoin d'interventions technologiques pour accompagner les joueurs dans la régulation de leurs émotions, ce qui légitime directement l'intérêt d'un outil de SER en contexte eSport

Limites :

— Grande diversité des méthodologies utilisées dans les études rendant difficile une comparaison directe des résultats

— Peu d'études expérimentales permettant d'établir un lien de causalité clair entre émotions et performance

6 Problématique scientifique

La reconnaissance vocale des émotions est un domaine de recherche toujours actif, marqué récemment par l'implémentation du deep learning comme technique d'encodage de l'information et de classification des émotions. Ce domaine ne se limite pas à un aspect technique : il s'appuie aussi sur des travaux d'ordre psychologique portant sur l'interprétation et la catégorisation des émotions. Dans ce cadre, plusieurs modèles ont été proposés pour couvrir un maximum d'émotions, sans pour autant constituer des vérités absolues, ces modèles reposant sur des cadres théoriques concurrents de la classification des émotions qui ne font pas consensus au sein de la communauté scientifique.

Dans l'eSport, dans quelle mesure est-il possible d'appliquer des modèles de SER afin d'interpréter, après leurs matchs, le ressenti de joueurs professionnels durant la partie, dans l'optique d'aider à leur préparation mentale ?

Les solutions actuelles dans ce domaine s'appuient sur :

- Des jeux de données non joués, plutôt spontanés, annotés par plusieurs annotateurs afin de réduire le biais de subjectivité ;
- Des modèles d'encodage de features ciblés sur le traitement audio, plus précisément sur des motifs temporels récurrents ;
- Des modèles de machine learning qui utilisent des approches différentes pour maximiser le gain ;
- Des représentations émotionnelles précises et suffisamment larges pour couvrir l'ensemble des émotions existantes.

Cependant, notre contexte eSport nous contraint sur :

- Un jeu de données spécifique au contexte eSport, spontané, capté en situation réelle et non annoté ;
- Des émotions non interprétables avec la seule voix ;
- Des indices vocaux inexploitables, car très courts et peu pertinents ;
- Une qualité vocale médiocre, avec des différences de volume, du bruit ambiant et des enregistrements parfois inaudibles.

7 Démarche et travaux réalisés

7.1 Protocole de labellisation

7.1.1 Objectif et choix méthodologique

L'absence de base de données émotionnelles adaptée au contexte spécifique de l'eSport (cf. section 5.2.1) a rendu nécessaire la constitution d'un dataset annoté à partir d'enregistrements audio réels, issus des communications vocales de l'équipe Lille eSports de LoL. Un protocole de labellisation a ainsi été conçu et mis en œuvre afin de produire des annotations émotionnelles fiables, reproductibles et exploitables pour l'entraînement de modèles de reconnaissance des émotions.

Le dataset est constitué d'extraits audio d'une durée minimale de 0,2 seconde, extraits de sessions de jeu réelles. Les échanges analysés se déroulent presque exclusivement en anglais, bien que les joueurs ne soient pas anglophones, ce qui constitue une contrainte supplémentaire prise en compte dans la sélection des annotateurs.

7.1.2 Fondement théorique : le modèle PAD

Contrairement à une annotation par catégories discrètes d'émotions (cf. section 5.1.1, section 5.1.2), le choix a été fait de s'appuyer sur le modèle dimensionnel PAD (Pleasure, Arousal, Dominance) proposé par Russell et Mehrabian, qui permet de représenter l'émotion dans un espace continu à trois dimensions plutôt que dans un ensemble figé de catégories. Cette approche graduelle offre l'avantage de produire des scores continus, quantifiables et comparables entre eux, plus adaptés à la variabilité et à la nuance des expressions émotionnelles observées en contexte compétitif.

Chaque extrait audio est ainsi évalué selon trois critères, sur une échelle de 1 à 7 :

- **Valence (Pleasure) :** caractère agréable ou désagréable de l'émotion perçue (1 = très négatif, 7 = très positif) ;
- **Activation (Arousal) :** niveau d'énergie ou d'éveil associé à l'état émotionnel (1 = très inactif, 7 = très actif) ;
- **Dominance :** sentiment de contrôle ou de soumission face à l'émotion ressentie (1 = très soumis, 7 = très dominant).

Une grille de correspondance a également été établie (cf. figure 5), associant des plages de scores PAD à des émotions discrètes suggérées (par exemple, joie/exaltation pour des scores élevés sur les trois dimensions, ou anxiété/stress pour une valence et une dominance faibles associées à une activation modérée à élevée). Cette grille constitue un outil d'aide à la décision pour l'annotateur, sans se substituer à son jugement : elle ne prétend pas couvrir l'ensemble des états émotionnels possibles, un nombre trop important de catégories proposées risquant au contraire de complexifier inutilement la tâche d'annotation.

#	Valence (V)		Activation (A)		Dominance (D)		Émotion discrète suggérée
	Min	Max	Min	Max	Min	Max	
1	5	7	5	7	5	7	Joie / Exaltation
2	5	7	5	7	1	4	Enthousiasme contraint
3	5	7	1	3	5	7	Sérénité / Satisfaction
4	5	7	1	3	1	4	Contentement passif
5	5	7	4	6	5	7	Confiance / Fierté
6	4	6	4	6	4	6	Concentration neutre
7	1	3	5	7	5	7	Colère / Mépris
8	1	3	5	7	1	4	Peur / Panique
9	1	3	1	3	5	7	Ennui / Lassitude
10	1	3	1	3	1	4	Tristesse / Résignation
11	1	3	4	6	5	7	Agacement / Frustration
12	1	3	4	6	1	4	Anxiété / Stress

FIGURE 5 – Grille PAD - Émotions

7.1.3 Phase de calibration des annotateurs

Afin de garantir la cohérence et la fiabilité des annotations, une phase de calibration préliminaire a été intégrée au protocole. Avant toute annotation du dataset réel, chaque annotateur est soumis à un test de positionnement sur des extraits déjà labellisés, disposant de scores PAD de référence issus de travaux existants, l'un portant sur des émotions jouées (volontairement exagérées), l'autre sur des extraits de podcast non joués. L'annotateur est considéré comme prêt lorsque ses scores s'écartent de moins d'un point (± 1) de la référence. S'il échoue, l'exercice est répété sans que la réponse attendue ne soit communiquée directement, l'objectif étant de développer une compréhension fine des critères plutôt que de mémoriser des réponses.

7.1.4 Procédure d'annotation

Une fois la phase de calibration validée, chaque annotateur procède à l'évaluation des extraits réels du dataset à l'aide d'une interface logicielle dédiée, spécifiquement développée pour cette campagne de labellisation (cf. figure 6). Cette interface centralise l'ensemble des éléments nécessaires à l'annotation, afin de limiter la charge cognitive de l'annotateur et de fiabiliser la procédure.

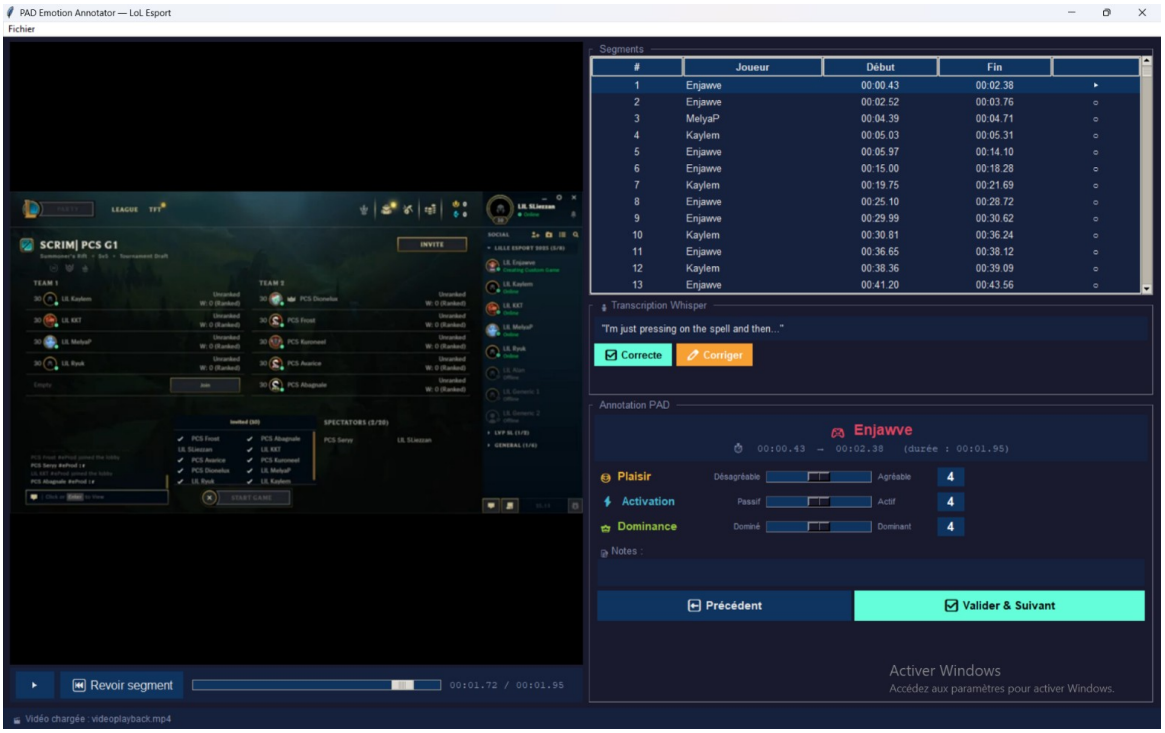


FIGURE 6 – Interface d'annotation

Organisation de l'interface

L'interface s'articule autour de quatre zones fonctionnelles principales :

- Zone de lecture audio/vidéo, dans laquelle le segment audio sélectionné est automatiquement chargé et peut être rejoué à volonté, permettant à l'annotateur d'écouter et de visionner le contenu autant de fois que nécessaire avant de statuer sur son évaluation ;
- Liste de navigation des segments audio, offrant une vue d'ensemble de la progression de la campagne d'annotation grâce à un code couleur distinguant les segments audio déjà annotés, le segment audio en cours de traitement et les segments audio restant à traiter ;
- Panneau de transcription automatique, affichant le texte généré par un modèle de reconnaissance vocale (Whisper) pour le segment audio considéré ;

- Panneau d'annotation PAD, composé de trois curseurs correspondant aux dimensions de valence, d'activation et de dominance (échelle de 1 à 7, cf. section 7.1), accompagné d'un champ de notes libres.

Déroulement de l'annotation d'un segment audio

Pour chaque segment audio, l'annotateur suit une séquence de traitement standardisée :

- Écoute du segment audio (avec possibilité de réécoute) ;
- Vérification de la transcription automatique proposée ;
- Attribution des trois scores PAD sur la base du ressenti et du profil vocal habituel du joueur identifié.

L'annotation est ensuite validée, ce qui déclenche le passage automatique au segment audio suivant et garantit l'enregistrement des données saisies.

Vérification et correction de la transcription automatique

Une attention particulière est portée à la qualité de la transcription générée automatiquement. Celle-ci n'étant pas fiable à 100 %, notamment en raison du bruit ambiant et des recouvrements de parole propres à un contexte de jeu compétitif, l'annotateur doit systématiquement comparer le texte proposé au contenu réellement énoncé par le joueur. Deux cas de figure se présentent :

- Si la transcription correspond fidèlement à ce qui a été dit, elle est validée telle quelle ;
- Sinon, l'annotateur procède à sa correction manuelle, en saisissant le texte exact prononcé.

Cette étape de correction ne relève pas d'un simple souci de qualité documentaire : elle répond à un objectif méthodologique à part entière. En effet, disposer d'une transcription textuelle fiable, alignée avec les scores émotionnels PAD attribués à chaque segment audio, permet de constituer un second jeu de données exploitable pour l'entraînement d'un modèle de reconnaissance des émotions fondé sur le texte. Cette double annotation ouvre ainsi la voie à une approche multimodale de la reconnaissance émotionnelle, où les prédictions issues du canal audio pourront être comparées, voire combinées, avec celles issues du canal linguistique. Les segments audio jugés inexploitables (audio inaudible, locuteur non identifiable) sont explicitement signalés par l'annotateur afin d'être exclus du corpus final.

7.1.5 Structuration et export des données annotées

À l'issue de chaque session d'annotation, les données produites sont exportées au format CSV, afin d'entraîner le modèle utilisé par la suite. Pour chaque segment audio traité, l'export regroupe l'ensemble des informations nécessaires à la reconstitution du contexte d'annotation ainsi qu'aux besoins d'entraînement des modèles de reconnaissance émotionnelle, à savoir :

- **Identification du segment audio :** nom du fichier audio source, numéro du segment audio, joueur identifié, timestamps de début et de fin, durée du segment audio ;
- **Scores émotionnels :** valeurs attribuées sur les trois dimensions du modèle PAD (valence, activation, dominance) ;
- **Annotations complémentaires :** notes libres éventuellement renseignées par l'annotateur, utiles pour documenter les cas ambigus ou justifier un choix de score particulier ;
- **Données textuelles :** transcription automatique brute issue de Whisper, statut de validation de cette transcription (validée, corrigée, non vérifiée), et transcription corrigée manuellement le cas échéant.

Gestion de la continuité des campagnes d'annotation

Une campagne d'annotation impliquant un grand nombre de segments audio et plusieurs annotateurs, le protocole prévoit un mécanisme de sauvegarde et de reprise de session, permettant à un annotateur d'interrompre puis de reprendre son travail sans perte de données ni doublon d'annotation. Le fichier exporté fait ainsi office à la fois de livrable final et de point de reprise intermédiaire.

7.1.6 Contrôle qualité et gestion de la subjectivité

Afin de limiter le biais de subjectivité inhérent à toute annotation manuelle d'émotions, le protocole prévoit le recours à un nombre élevé d'annotateurs (entre 20 et 50), permettant de diluer statistiquement les écarts individuels d'interprétation. Une moyenne et un écart-type sont ensuite calculés pour chaque segment audio à partir de l'ensemble des scores recueillis. Un écart-type jugé trop élevé traduit une absence de consensus entre annotateurs ; dans ce cas, le segment audio est classé dans une catégorie « émotion non reconnue » plutôt que de se voir attribuer un score peu fiable, préservant ainsi la qualité globale du dataset.

7.1.7 Limites et discussion

Cette méthodologie, fondée sur les travaux de Russell et Mehrabian, ne constitue pas la seule approche possible pour l'évaluation des émotions dans un signal vocal ; d'autres modèles, potentiellement plus fins, existent dans la littérature. Le choix du modèle PAD répond ici à un choix pratique entre rapidité de mise en œuvre, robustesse et facilité d'exploitation des données produites, plutôt qu'à une recherche de précision maximale. Par ailleurs, la fiabilité du protocole repose fortement sur la disponibilité d'annotateurs maîtrisant l'anglais et disposant d'une connaissance suffisante du contexte de jeu (LoL), condition nécessaire à une interprétation juste des réactions vocales observées.

7.2 Extraction des features

7.2.1 Features interprétables

Choix méthodologique

En complément des représentations profondes issues de modèles pré-entraînés (cf. section 5.2.2), le choix a été fait d'extraire, dans un premier temps, un ensemble de features acoustiques manuelles interprétables par segment audio, telles que : l'amplitude maximale, l'amplitude RMS, la fréquence fondamentale, le jitter, le shimmer, le HNR et le temps entre les prises de parole. Contrairement aux embeddings produits par des architectures de type Wav2Vec2, ces features reposent sur des grandeurs physiques, ce qui permet d'en interpréter le comportement des joueurs à partir de valeurs numériques et de disposer d'une base de référence, simple et explicable, avant l'introduction de représentations plus complexes.

Le choix des descripteurs retenus a été guidé par les contraintes spécifiques de notre dataset : communications courtes, bruitées, parfois compressées ou avec voix superposées. Plusieurs familles de features classiquement utilisées en SER : MFCC, LPC/LPCC, descripteurs spectraux tels que le centroïde, la bande passante, la flatness, le contraste ou le rolloff, ont ainsi été écartées à ce stade, car leur interprétation émotionnelle reste indirecte et leurs performances se dégradent fortement dans les conditions rencontrées dans notre corpus.

À l'inverse, les descripteurs retenus ont été choisis pour leur robustesse relative et leur lien plus direct avec des marqueurs émotionnels documentés : l'amplitude maximale et l'amplitude RMS pour capter les ruptures d'énergie ; la F0 moyenne, estimée par l'algorithme YIN pour sa faible marge d'erreur ; le jitter et le shimmer, qui peuvent à eux seuls constituer un jeu de features minimal et efficace pour la SER ; le HNR, qui caractérise la qualité de la production vocale ; ainsi qu'un descripteur contextuel de temps de silence inter-locution.

Un module d'extraction dédié, *AudioFeatureExtractor()*, a été développé afin de calculer, pour chaque segment audio du dataset, un ensemble de descripteurs acoustiques classiques ainsi qu'un descripteur contextuel propre à la structure temporelle des échanges en jeu.

Descripteurs extraits

Le tableau suivant présente les features calculées, leur signification et la méthode retenue pour leur estimation (avec les librairies NumPy et Librosa sous Python).

TABLE 8 – Description des features acoustiques extraites

Feature	Description	Formule
Amplitude maximale	Amplitude maximale du signal	$\text{max} = \max(\text{signal})$
Amplitude RMS	Amplitude moyenne du signal	$\text{rms} = \sqrt{\text{mean}(\text{signal})^2}$
F0 moyenne (Hz)	Fréquence fondamentale moyenne	$f_0 = \text{mean}\left(\int_{-\infty}^{+\infty} \text{signal} \cdot e^{-j2\pi ft}\, dt\right)$
Jitter	Variation cycle-à-cycle de la période fondamentale	$\text{jitter} = \text{mean}\left(\left\lvert \frac{\text{diff}\left(\frac{1}{f_0}\right)}{\text{mean}\left(\frac{1}{f_0}\right)} \right\rvert\right)$
Shimmer	Variation cycle-à-cycle de l'amplitude	$\text{shimmer} = \text{mean}\left(\left\lvert \frac{\text{diff}(\text{amp})}{\text{mean}(\text{amp})} \right\rvert\right)$
HNR (dB)	Rapport harmonique/bruit	$\text{hnr} = \frac{10\log_{10}(\text{energy}_{\text{noise}} + \varepsilon)}{\text{energy}_{\text{noise}} + \varepsilon}$
Temps de silence inter-locution	Durée de silence précédant la prise de parole d'un joueur par rapport à la précédente	Récupération du début de la durée d'un segment audio d'un joueur et comparaison avec la fin de la durée d'un autre segment audio du même joueur

Exploration visuelle des features

Afin d'explorer le comportement des features extraites à l'échelle du dataset, deux modes de visualisation ont été développés :

- Une visualisation par distribution inter-joueurs, représentant, pour une feature donnée, la dispersion des valeurs obtenues pour chaque joueur du dataset. Cette représentation vise

à identifier des profils vocaux individuels (par exemple une F0 moyenne ou une énergie RMS caractéristique d'un joueur) et à permettre une comparaison entre joueurs ;

- Une visualisation temporelle intra-partie, représentant l'évolution d'une feature donnée au fil du temps de jeu pour un joueur spécifique, chaque segment audio de parole étant positionné selon ses phases de début et de fin. Cette représentation vise à observer les variations d'une feature au cours d'une session de jeu et à repérer visuellement des phases susceptibles de correspondre à des pics d'intensité émotionnelle.

Ces deux outils de visualisation ont été conçus comme un moyen d'exploration et de contrôle qualité de l'extraction des features, en amont de l'analyse de la relation entre ces descripteurs et les scores PAD annotés.

7.2.2 Features d'entrée du modèle

Choix méthodologique

En complément des features interprétables, une seconde approche a été mise en œuvre afin d'extraire des représentations profondes du signal vocal. Deux options existaient à ce stade : s'appuyer sur un ensemble standardisé de descripteurs acoustiques comme eGeMAPS, extrait via OpenSMILE, ou exploiter directement les représentations apprises par un modèle auto-supervisé de type Wav2Vec2.

eGeMAPS présente l'avantage d'être un standard largement adopté dans la littérature SER, avec 88 descripteurs interprétables couvrant simultanément les dimensions prosodiques, énergétiques, spectrales et de qualité vocale [16], [15]. Cette standardisation facilite la comparaison entre travaux scientifiques et constitue une référence fréquemment utilisée comme baseline. Il reste cependant construit sur un ensemble de descripteurs définis manuellement, non optimisés pour une tâche spécifique, et ne peut pas capturer toute la richesse émotionnelle contenue dans des situations complexes ou fortement contextualisées, telles que nos communications de jeu.

Le choix s'est donc porté sur Wav2Vec2-large, un modèle auto-supervisé pré-entraîné sur de grandes quantités de parole non annotée [8], [2], capable d'apprendre directement une représentation du signal brut sans définition a priori des descripteurs à extraire. Cette approche permet de capturer des informations acoustiques, prosodiques et contextuelles plus riches que celles issues des features manuelles ou d'eGeMAPS, ce qui s'avère particulièrement utile pour des émotions subtiles comme le stress ou la concentration, difficiles à isoler avec un jeu de descripteurs fixé à l'avance. Cette richesse se fait toutefois au prix d'une interprétabilité plus faible et d'un coût computationnel significativement plus élevé, en entraînement comme en inférence, ce qui justifie de conserver en parallèle le jeu de features interprétables.

Ces représentations profondes ne correspondent à aucune grandeur physique ou perceptive directement identifiable : elles résultent de l'apprentissage auto-supervisé du modèle sur le dataset audio MSP-Podcast, et capturent des informations complexes du signal (prosodie, timbre, structure phonétique) difficilement accessibles par une extraction manuelle. Le modèle est utilisé ici en mode extracteur de features uniquement, sans sa tête de régression : seul le backbone Wav2Vec2Model est chargé, les poids du réseau pré-entraîné restent figés, et seule la représentation interne produite par le modèle est exploitée en sortie.

Modèle utilisé et pipeline d'extraction

L'extraction repose sur le checkpoint 'audeering/wav2vec2-large-robust-12-ft-emotion-msp-dim', disponible sur la plateforme HuggingFace. Ce modèle est issu d'un fine-tuning de Wav2Vec2-Large-Robust sur le dataset MSP-Podcast, un dataset anglophone annoté selon les dimensions du modèle PAD. Le réseau a par ailleurs été élagué de 24 à 12 couches de Transformers avant son fine-tuning, ce qui en fait une version allégée, plus rapide à exécuter, tout en conservant les capacités de représentation acquises lors du pré-entraînement. Le pipeline complet, depuis le segment audio brut jusqu'à l'embedding final, est résumé en figure 7.

Ce schéma synthétise les quatre grandes étapes du script d'extraction : un prétraitement du signal (conversion mono, rééchantillonnage à 16 kHz), une normalisation par le Wav2Vec2Processor (centrage/scaling de l'amplitude, mise en forme en tenseurs PyTorch), le passage dans le Wav2Vec2Model proprement dit (encodeur convolutif, projection dans l'espace latent, puis Transformer à 12 couches), et enfin un mean pooling temporel produisant un vecteur unique de 1024 dimensions par segment audio, sauvegardé au format .pkl. Deux composants sont utilisés conjointement pour extraire les représentations :

- **Wav2Vec2Processor**, qui normalise l'audio brut et le met sous une forme numérique standardisée, exploitable par le réseau de neurones. Ce composant ne réalise aucun apprentissage : il s'agit d'une étape de mise en forme des données ;
- **Wav2Vec2Model**, qui constitue le réseau de neurones à proprement parler. C'est lui qui, à partir du signal normalisé, produit la représentation profonde du segment audio.

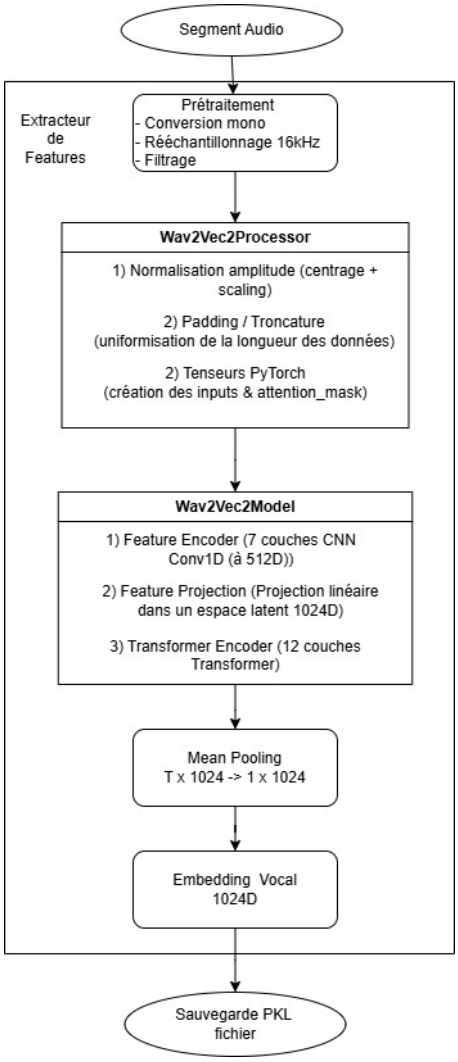


FIGURE 7 – Pipeline d'extraction des features Wav2Vec2

a) Le Feature Encoder : encodeur convolutif

Avant d'atteindre le Transformer, le signal audio normalisé traverse une succession de couches convolutives 1D (7 couches au total dans Wav2Vec2), dont le rôle est de transformer le signal brut, échantillonné à 16 kHz, en une séquence de représentations locales à 512 dimensions. Le principe des deux premières couches est détaillé en figure 8 et figure 9. Même si le nombre de kernels et de strides change par rapport à notre modèle réel.

Couche 1 Conv1D : 512 filtres, kernel 3, stride 2

Cette première couche applique 512 filtres convolutifs sur le signal d'entrée, chacun regardant une fenêtre de 3 échantillons consécutifs à la fois (kernel = 3), en avançant de 2 échantillons à chaque déplacement (stride = 2). Ce stride divise donc par 2 la longueur de la séquence à chaque couche, ce qui explique pourquoi, après les 7 couches convolutives, une séquence audio de plusieurs milliers d'échantillons est réduite à quelques centaines de "trames" temporelles. Chaque position de sortie $P_{(1/j)}$ résulte d'une combinaison linéaire pondérée des échantillons couverts par la fenêtre, suivie d'une activation GELU, qui introduit de la non-linéarité et permet au réseau d'apprendre des motifs acoustiques plus complexes qu'une simple moyenne pondérée.

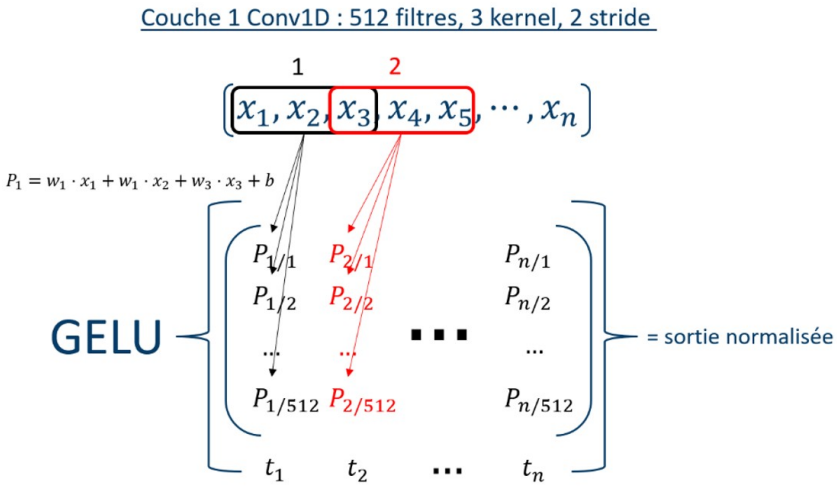


FIGURE 8 – Couche 1 Conv1D

Couche 2 Conv1D — 512 filtres, kernel 2, stride 2

La deuxième couche reprend le même principe, mais s'applique cette fois sur la sortie de la couche précédente (déjà en 512 dimensions), avec un kernel plus petit (2) puisque chaque position contient déjà une information agrégée sur plusieurs échantillons originaux. Cet empilement de couches convolutives permet au réseau de construire progressivement des représentations de plus en plus abstraites et de plus en plus larges en contexte temporel, sans perdre en résolution de traitement, chaque couche successive "voit" une portion plus large du signal original tout en manipulant une séquence plus courte.

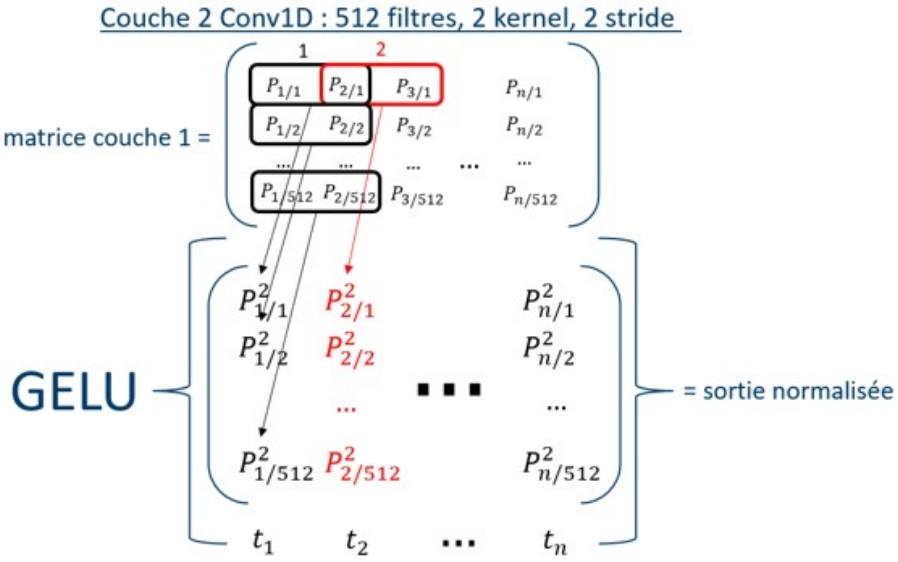


FIGURE 9 – Couche 2 Conv1D

b) Feature Projection

À l'issue des 7 couches, la sortie est projetée linéairement de 512 vers 1024 dimensions (Feature Projection), afin de correspondre à la dimension d'entrée attendue par le Transformer.

c) Le Transformer Encoder

La séquence de représentations en 1024 dimensions est ensuite propagée à travers 12 couches Transformer identiques dans leur structure. Le détail du fonctionnement interne d'une seule de ces couches est présenté en figure 10.

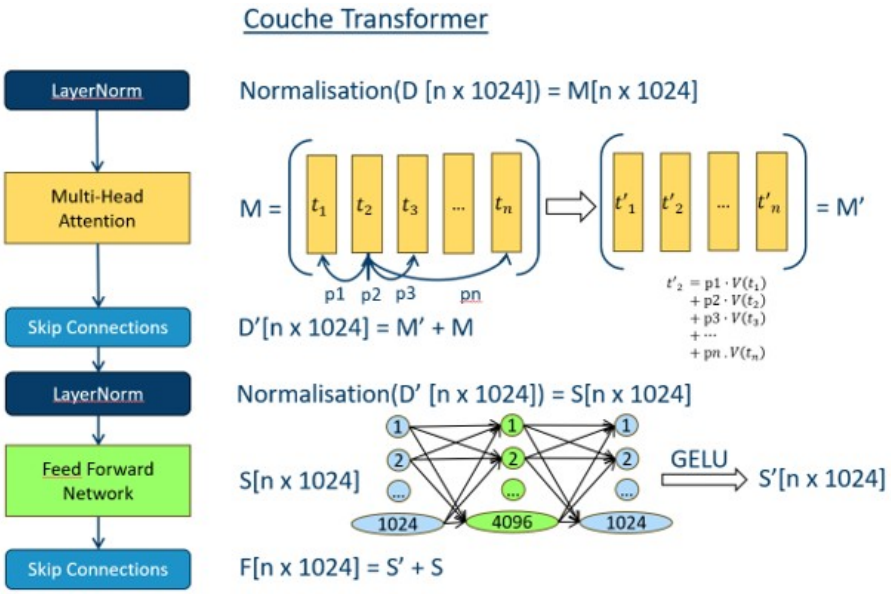


FIGURE 10 – Détail d'une couche Transformer

Chaque couche applique successivement : une normalisation (LayerNorm) du vecteur d'entrée D, un bloc de Multi-Head Attention qui recalcule chaque token t_i comme une combinaison pondérée de tous les tokens de la séquence (les poids p_1, p_2, ..., p_n traduisant l'importance relative de chaque position par rapport aux autres), une skip connection qui additionne cette sortie au vecteur D d'origine (évitant la perte d'information et facilitant la propagation du gradient), une seconde normalisation, un Feed Forward Network qui projette chaque position individuellement dans un espace intermédiaire à 4096 dimensions avant de revenir à 1024 (avec une activation GELU au passage), puis une seconde skip connection. C'est ce mécanisme d'attention, répété 12 fois, qui permet au modèle de construire une représentation contextuelle de chaque segment audio : contrairement aux couches convolutives qui ne voient qu'un voisinage local, l'attention permet à chaque position de la séquence d'intégrer directement l'information de n'importe quelle autre position, même distante.

La sortie du dernier état (*lasthiddenstate*) de cette pile de 12 couches constitue la représentation finale retenue, avant l'étape de mean pooling temporel décrite ci-dessous.

d) Mean pooling et embedding vocal

À la sortie du dernier état, une matrice temporelle de 1024 dimensions est transformée en un vecteur de 1024 dimensions. Pour ce faire, un mean pooling temporel est effectué afin de réduire le segment audio à un seul vecteur. Ensuite, le vecteur est placé dans un espace embedding afin d'être classé par rapport aux autres.

Sauvegarde et format de sortie

L'ensemble des vecteurs de features extraits est structuré sous forme de dictionnaire associant, pour chaque segment audio traité avec succès, son nom de fichier au vecteur de représentation correspondant (1024 dimensions). Ce dictionnaire est sérialisé et sauvegardé au format pickle (.pkl), choisi pour sa capacité à conserver la structure de tableaux NumPy, contrairement à un export classique (CSV). Les segments audio écartés ne sont volontairement pas inclus dans le dictionnaire final. Ce fichier .pkl constitue le second jeu de features d'entrée destiné à l'entraînement des modèles de reconnaissance émotionnelle (cf. section 5.2.3), en complément du jeu de features interprétables généré.

7.3 Modèle

7.3.1 Choix méthodologique

Pour prédire les scores PAD à partir des features déjà extraites, plusieurs approches ont été envisagées. Les méthodes classiques comme le SVM ou le XGBoost offrent une bonne interprétabilité et un coût computationnel faible, ce qui les rend efficaces avec peu de données annotées ; elles restent cependant fortement dépendantes de la qualité des features extraites manuellement et ne capturent pas les dépendances temporelles du signal vocal, ce qui limite leur pertinence pour des émotions qui évoluent au fil du match.

Le choix s'est donc porté sur Wav2Vec2, déjà mobilisé comme extracteur de représentations profondes, afin d'exploiter directement la richesse contextuelle apportée par son architecture encodeur convolutif + Transformer. Ce choix permet en outre de réutiliser le modèle 'audeering/wav2vec2-large-robust-12-ft-emotion-msp-dim' comme modèle de prédiction : ce modèle intègre nativement une tête de régression PAD, ce qui évite d'avoir à entraîner un classifieur supplémentaire à partir de zéro. Comme les embeddings sont déjà calculés et sauvegardés, seule cette tête de régression est appliquée, ce qui rend la prédiction quasi instantanée, sans avoir à repasser les fichiers audios dans le backbone Wav2Vec2 déjà exécuté une première fois. Cette approche présente en contrepartie les limites classiquement associées aux modèles profonds : une interprétabilité plus faible que les méthodes classiques, et une dépendance forte au volume de données disponible pour l'entraînement de la tête de classification.

7.3.2 Modèle utilisé

Le modèle 'audeering' est composé de deux blocs : le backbone Wav2Vec2, qui produit les embeddings, et une tête de régression qui convertit ces embeddings en trois scores. Elle a été fine-tunée sur MSP-Podcast, lui-même annoté selon le modèle PAD, ce qui la rend directement cohérente avec le modèle théorique retenu pour notre propre annotation. Le pipeline appliqué à chaque vecteur de features est détaillé en figure 11.

Le vecteur audio (1024 dimensions) issu de l'extraction traverse successivement : un premier dropout (désactivé en mode inférence, puisqu'il ne sert qu'à limiter le surapprentissage pendant l'entraînement), une couche dense (Dense Layer) qui reprojette le vecteur de 1024 vers 1024 dimensions, une activation tanh() qui écrase les valeurs dans l'intervalle [-1, +1] et introduit la non-linéarité nécessaire pour que cette seconde couche apporte une information différente de la première, un second dropout (également désactivé), et enfin une couche de sortie (Output Layer) qui réduit le vecteur de 1024 à 3 dimensions, les scores Arousal, Dominance et Valence. Ce résultat est ensuite exporté au format CSV. Concrètement, on récupère uniquement les poids de cette tête, et on l'applique à chaque vecteur de features déjà extrait, sans jamais recalculer les 1024 dimensions d'entrée.

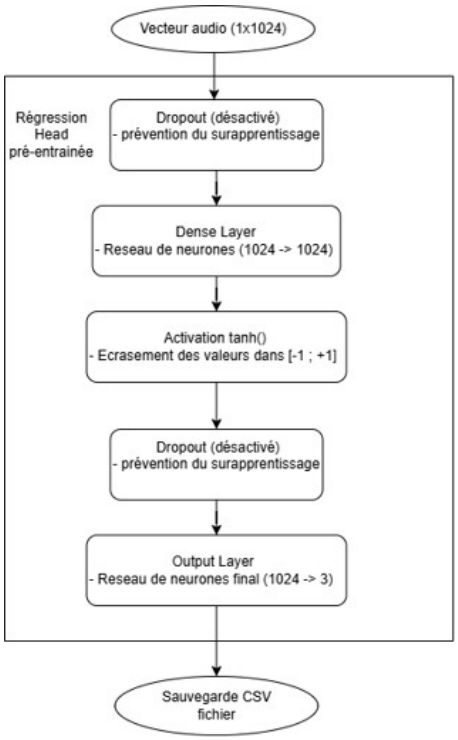


FIGURE 11 – Pipeline de la tête de régression PAD

7.3.3 Sauvegarde

Les prédictions obtenues pour chaque segment audio sont exportées dans un fichier CSV, associant à chaque nom de fichier audio ses trois scores PAD (arrondis à 4 décimales). Contrairement aux embeddings, le format CSV est ici suffisant, car les données de sortie sont de simples valeurs numériques. Ce fichier sert de base à la comparaison avec les scores attribués manuellement par les annotateurs.

7.3.4 Limites

- Le modèle sort des scores entre 0 et 1, alors que notre annotation manuelle utilise une échelle de 1 à 7 : une étape de rescaling sera nécessaire avant toute comparaison directe ;
- Le modèle n'a jamais été entraîné ni fine-tuné sur des données eSport : il reste entraîné sur un dataset de podcast anglophone ;
- La qualité de la prédiction PAD dépend entièrement de la qualité des embeddings extraits en amont ;
- Aucune réévaluation ni fine-tuning de la tête de régression n'a été réalisé à ce stade : elle est utilisée telle quelle, sans adaptation à notre propre distribution de scores.

7.4 Prédiction

7.4.1 Objectif de la comparaison

L'objectif de cette étape est de confronter les scores PAD prédits automatiquement par le modèle Wav2vec2-large-robust-12-ft-emotion-msp-dim aux scores PAD attribués manuellement par les annotateurs lors de la campagne de labellisation, afin d'évaluer dans quelle mesure un modèle pré-entraîné sur un dataset généraliste (podcast anglophone) est capable de généraliser à notre contexte spécifique de communications vocales en compétition eSport. Cette comparaison nécessite au préalable un rescaling des scores prédits (bornés entre 0 et 1) vers l'échelle utilisée lors de l'annotation manuelle (1 à 7), afin de rendre les deux jeux de données directement comparables. Pour comparer le score manuel avec le score prédit par le modèle, on superposera directement chacun des scores au cours du match. De plus, on calculera la différence entière et absolue entre nos scores pour voir si le modèle se rapproche de ce que l'annotateur a perçu.

7.4.2 Résultats attendus

Contexte

Le modèle utilisé a été fine-tuné sur MSP-Podcast, des podcasts spontanés dans un contexte conversationnel généraliste, en anglais, sans vocabulaire technique ni contrainte environnementale. Nos données présentent au contraire un niveau de bruit plus élevé, des locuteurs non-natifs anglophones, des segments audio plus courts et un contexte émotionnel spécifique (stress compétitif, tilt, exaltation liée aux mécaniques du jeu).

Attendu

Dans ce contexte, on peut anticiper une ressemblance modérée plutôt que forte entre les scores prédits et les scores annotés, avec des performances meilleures sur la dimension Activation (l'énergie vocale étant relativement bien capturée indépendamment du contexte culturel ou linguistique) que sur les dimensions Valence et Dominance, plus dépendantes du contenu et des codes culturels d'expression émotionnelle, davantage susceptibles d'être mal transférés d'un dataset à l'autre. On peut également s'attendre à des écarts plus marqués sur les segments audio les plus bruités ou les plus courts, cohérents avec les limites

déjà identifiées pour le backbone Wav2Vec2 et pour le contexte eSport en général (cf. section 6).

Objectif

Confirmer ou infirmer ces hypothèses à partir des données réellement recueillies, et identifier, dimension par dimension, les cas où le modèle généraliste reste exploitable en l'état et les cas où un fine-tuning sur des données eSports annotées serait nécessaire.

7.4.3 Meilleur scénario envisageable

Dans le meilleur des cas, le modèle pré-entraîné montrerait une corrélation suffisamment forte avec les annotations manuelles sur les trois dimensions du modèle PAD (une corrélation attendue plus forte sur l'Activation), pour être directement exploitable comme indicateur de tendance générale de l'état émotionnel d'un joueur au cours d'une partie, sans nécessiter de fine-tuning supplémentaire dans un premier temps.

Ce résultat permettrait de valider l'hypothèse selon laquelle des représentations profondes apprises sur un dataset généraliste gardent les traces suffisantes pour un cas d'usage aussi spécifique que l'eSport, et fournirait une base de comparaison solide pour évaluer, dans un second temps, l'apport réel d'un fine-tuning sur données annotées spécifiques à LoL.

À plus long terme, un tel résultat ouvrirait également la voie à l'exploitation des features interprétables en complément des embeddings Wav2Vec2, dans une logique de modèle hybride combinant richesse contextuelle et interprétabilité, afin de proposer à Lille eSport un outil à la fois performant et exploitable pour le coaching mental des joueurs.

8 Analyse des résultats et interprétations

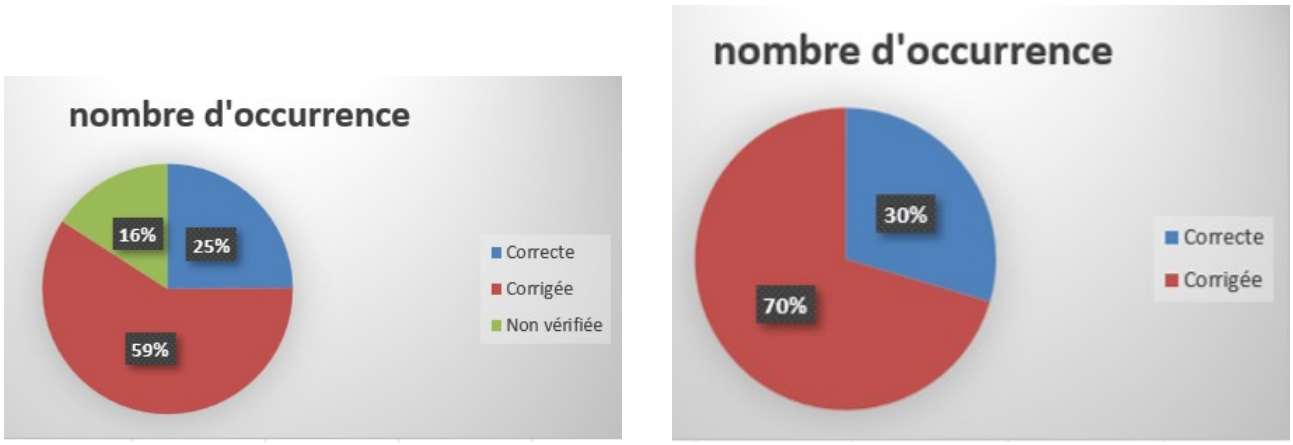
Pour l'analyse des résultats préliminaires, nous nous intéressons d'abord à l'annotation manuelle du dataset. À ce stade, l'annotation a été réalisée par un seul annotateur sur la première game de Lille eSport, avec 543 segments audio annotés. Cette annotation suit le protocole de labellisation présenté précédemment. Nous analyserons ensuite les prédictions du modèle Wav2Vec2-Large sur l'ensemble du dataset. Enfin, nous étudierons les features brutes et interprétables afin d'identifier d'éventuelles correspondances avec certains joueurs.

8.1 Résultat annotation manuelle

Pour l'analyse du protocole de labellisation, nous nous basons uniquement sur le premier match joué par l'équipe de Lille eSport, à partir de 543 segments audio. Cette annotation a été réalisée par un seul annotateur, faute de temps pour lancer une campagne d'annotation. Nous analyserons d'abord les transcriptions générées par Whisper sur le dataset. Nous étudierons ensuite la répartition des scores PAD. Des émotions seront aussi attribuées à partir de ces scores afin d'obtenir une première estimation de leur répartition dans une partie de LoL. Enfin, nous interpréterons ces résultats au regard du déroulement du match.

8.1.1 Résultat transcriptions

Dans un premier temps, nous avons réalisé une analyse globale de la transcription. L'objectif était d'évaluer la part de segments audio correctement transcrits par rapport aux segments audio mal transcrits. Certains segments audio ne sont pas transcriptibles, car leur contenu audio est inaudible.



(a) Résultat sur l'ensemble des données

(b) Résultat sur les données annotables

FIGURE 12 – Résultats de la transcription sur le 1er match

Les résultats montrent qu'une part importante des segments audio annotés n'est pas correctement transcrite, avec environ 70% d'erreurs sur les segments audio évalués (cf. figure 12b). Cela peut limiter la compréhension des communications par notre modèle. De plus, 16% des segments audio sont inexploitables, principalement en raison d'un contenu audio inaudible (cf. figure 12a). Cette part reste non négligeable dans le dataset.

Ce résultat doit toutefois être nuancé. Lors de la labellisation, nous avons observé que de nombreux segments audio étaient proches de la transcription attendue. Les erreurs semblent en partie liées au fait que Whisper est entraîné sur des données génériques, peu adaptées au vocabulaire spécifique de l'eSport et de LoL.

Ainsi, Whisper ne reconnaît pas toujours correctement le lexique utilisé par les joueurs. Malgré cela, les transcriptions restent exploitables pour obtenir une compréhension générale des segments audio. À terme, les segments audio déjà annotés pourraient servir à entraîner un modèle de transcription plus adapté, avec un dataset d'entraînement propre et spécifique.

8.1.2 Résultat PAD

Après l'annotation de la première game, nous avons tracé les trois scores PAD : Plaisir, Activation et Dominance. Ces scores sont représentés selon l'ordre des segments audio au cours du match. Pour l'analyse, la partie est découpée en quatre phases. La pré-game correspond aux segments 1 à 147 (de 1s à 602s). L'early game s'étend des segments 148 à 252 (de 611s à 1006s). Le midgame couvre les segments 253 à 398 (de 1007s à 1436s). Enfin, l'endgame correspond aux segments 399 jusqu'à la fin de la partie (de 1439s à 1974s).

Pour le score de Plaisir, les joueurs présentent un état plutôt positif durant la pré-game. À partir de l'early game puis du midgame, le score devient plus négatif. En moyenne, le score reste compris entre 3 et 5, ce qui correspond à un état globalement neutre, avec des émotions peu expressives. On observe toutefois deux pics de positivité vers l'endgame. Malgré ces variations, le score reste globalement faible sur cette phase.

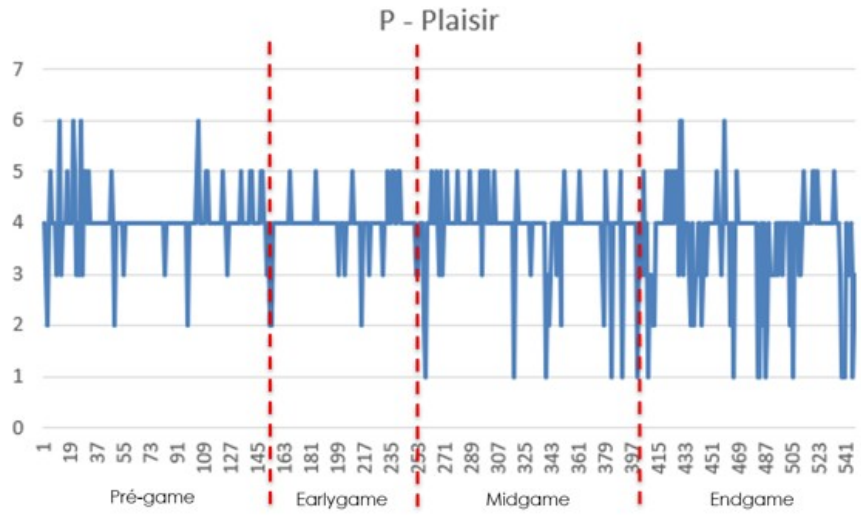


FIGURE 13 – Évolution du Plaisir - 1er match

Le score d'Activation reste plus neutre que le score de Plaisir. Il se situe plus souvent entre 3 et 5, ce qui indique une activation globalement modérée. Quelques pics élevés sont observés durant la pré-game, ainsi que certains scores plus faibles. En early game et en midgame, le score reste plutôt neutre, avec quelques baisses ponctuelles. Au début de l'endgame, certains pics deviennent plus positifs. En fin de game, on observe davantage de pics négatifs. Les scores les plus extrêmes indiquent donc une intensité plus forte, mais globalement orientée négativement.

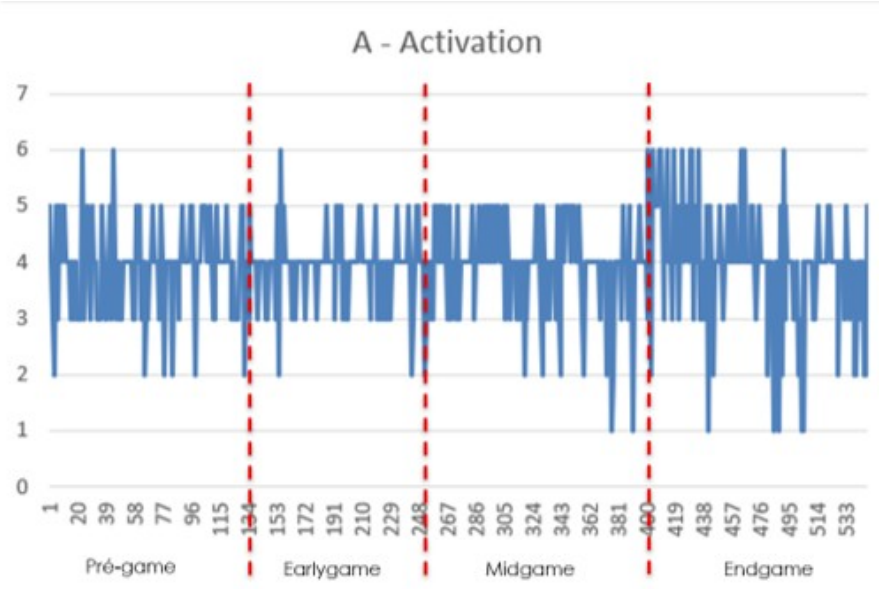


FIGURE 14 – Évolution de l'Activation - 1er match

Le score de Dominance reste majoritairement neutre, avec quelques pics ponctuels. En pré-game, les pics observés sont principalement négatifs. En midgame, les variations sont plus marquées, avec une majorité de pics négatifs et deux pics positifs. Au début de l'endgame, une courte période de pics positifs apparaît. Sur le reste de la fin de game, les valeurs redeviennent largement négatives.

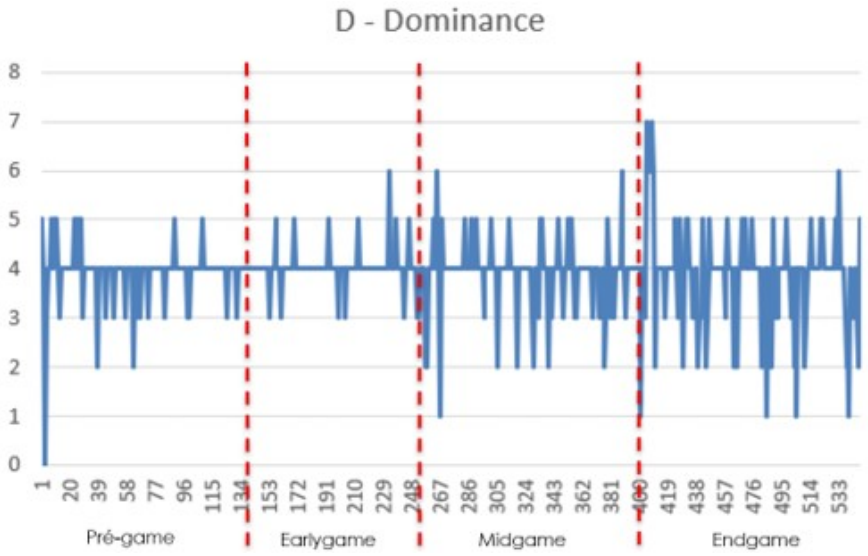


FIGURE 15 – Évolution de la Dominance - 1er match

En conclusion, une corrélation semble apparaître entre les scores PAD. En pré-game, le score de Plaisir est plutôt positif, avec une Activation moyenne mais légèrement positive, et une Dominance plutôt négative. En early game, les trois scores restent globalement neutres. En midgame, les scores de Plaisir, d'Activation et de Dominance deviennent plus négatifs. L'endgame présente davantage de pics. Au début de cette phase, les scores d'Activation et de Dominance sont fortement positifs, avec un Plaisir également plutôt positif. En fin de game, les trois scores deviennent nettement négatifs.

8.1.3 Attribution des émotions et interprétation

Après l'annotation de la première partie, nous pouvons associer des émotions aux segments audio. Pour cela, nous nous appuyons sur la figure 5 afin de limiter l'analyse à un nombre restreint d'émotions. L'objectif est de mieux comprendre les émotions ressenties par l'équipe au cours de la game, puis de mettre ces résultats en lien avec le déroulement de celle-ci.

Durant la pré-game (cf. figure 16), une grande partie des segments audio est associée à une émotion de concentration/neutre. Ce résultat est cohérent avec les scores PAD, majoritairement proches de 4 pour les trois dimensions. Dans la plupart des segments audio, les joueurs n'expriment pas d'émotion marquée. Cela explique la forte proportion de segments audio neutres, qui représente 63,9% des cas. L'émotion de contentement apparaît ensuite avec 24,5% des segments audio. Elle correspond à un score de Plaisir positif, associé à une Dominance plutôt faible. Les joueurs semblent donc dans un état positif, sans forte expressivité. Les émotions de tristesse/résignation (3,4%) et d'enthousiasme contraint (4,1%) sont moins présentes. Elles apparaissent surtout lors de pics sur les scores de Plaisir ou d'Activation. Ces résultats doivent être interprétés avec prudence, car de faibles variations dans l'annotation PAD peuvent modifier l'émotion attribuée.

En résumé, la pré-game montre une équipe plutôt concentrée et positive. Cette tendance peut être liée aux retrouvailles entre joueurs, ainsi qu'à la préparation de la game. Certains pics peuvent correspondre à des moments de rire ou de joie plus marqués.

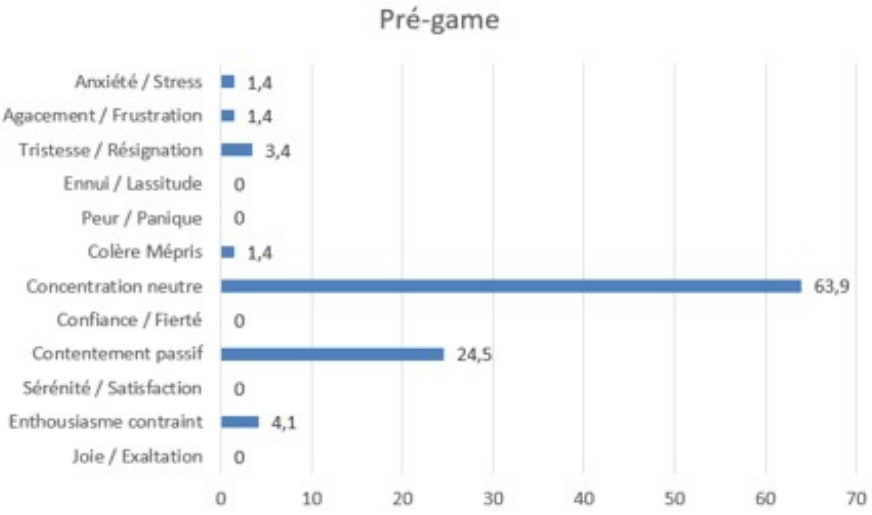


FIGURE 16 – Émotions en pré-game

Durant l'early game (cf. figure 17), une part encore plus importante des segments audio est associée à une émotion de concentration/neutre (72,4%). Les scores PAD restent globalement proches de 4 sur cette phase, ce qui indique l'absence d'émotion marquée. Ce résultat est cohérent avec le début de game, où les joueurs sont concentrés et expriment peu d'émotions dans leur voix. Les émotions de contentement passif (6,7%) et de tristesse/résignation (13,3%) sont aussi présentes. Elles semblent liées à de légères variations des scores PAD. Ces variations peuvent correspondre à des actions de gameplay plus ou moins réussies, générant des réactions vocales ponctuelles.

Globalement, l'early game est dominé par un état neutre et concentré. Malgré cela, certaines émotions apparaissent ponctuellement, comme lors de leur premier kill à 7 min 45, où le toplaner exprime de la joie.

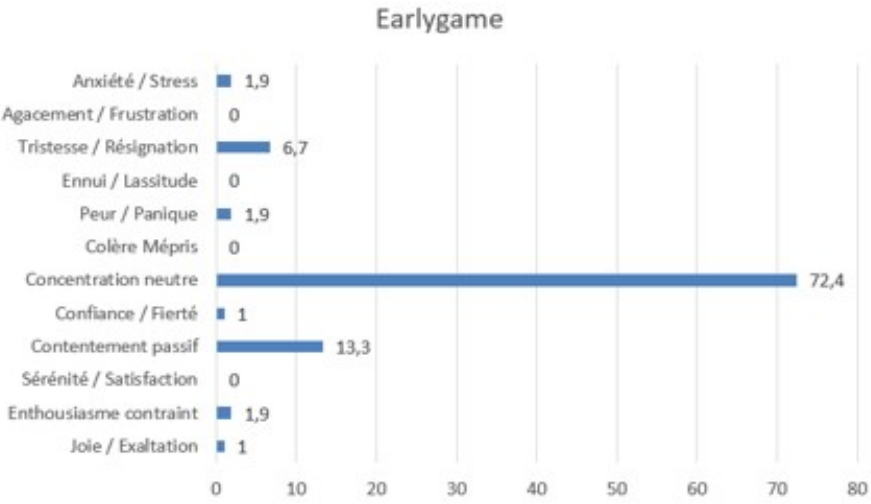


FIGURE 17 – Émotions en early game

Durant le midgame (cf. figure 18), l'émotion la plus représentée reste la concentration/neutre (68,5%). Cette tendance est cohérente avec des scores PAD encore proches d'un état moyen. On observe toutefois une légère baisse de cette émotion par rapport aux phases précédentes. Cette baisse peut être liée aux duels perdus face à l'équipe adverse, ce qui augmente la part de tristesse/résignation (8,2%). À ce stade de la game, aucune équipe ne

prend clairement le dessus, même si l'avantage semble être du côté adverse. D'autres émotions apparaissent aussi, comme l'enthousiasme contraint (3,4%), la joie/exaltation (2,1%) et le contentement passif (11,6%). Cependant, les scores PAD montrent en général un Plaisir et une Dominance plutôt négatifs, avec une Activation neutre. Cela met en évidence un décalage entre l'analyse directe des scores PAD et l'émotion déduite à partir du tableau utilisé. Ce décalage peut venir de la subjectivité de l'annotation, mais aussi de la métrique utilisée pour associer les scores PAD aux émotions. Cette méthode n'est donc pas toujours assez précise pour représenter finement l'état émotionnel des joueurs.

Malgré cette limite, l'analyse permet tout de même d'identifier une tendance globale : le midgame reste principalement marqué par un état de concentration/neutre, avec une présence secondaire de contentement passif.

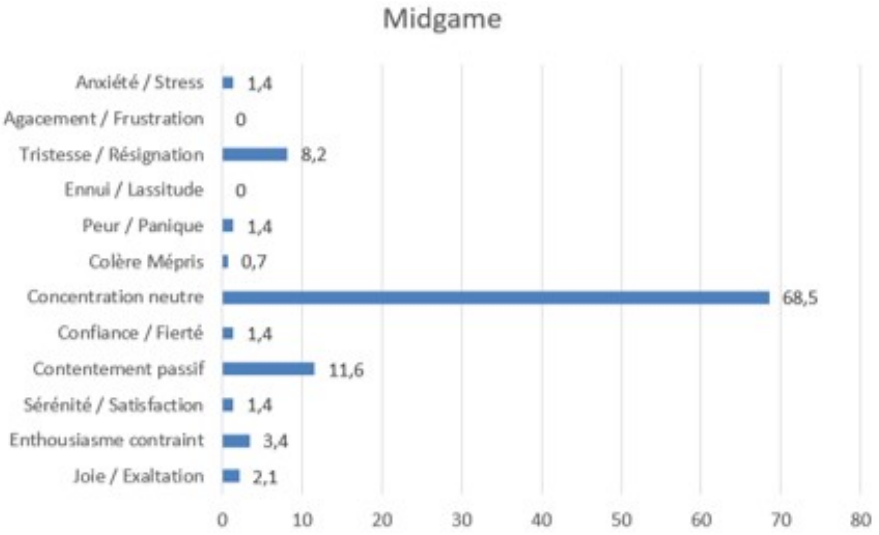


FIGURE 18 – Émotions en midgame

Durant l'endgame (cf. figure 19), plusieurs émotions se distinguent plus nettement. L'état concentration/neutre reste majoritaire (51,7%), mais sa part diminue par rapport aux phases précédentes. On observe aussi davantage de tristesse/résignation (12,4%), de peur/panique (6,9%) et d'anxiété/stress (5,5%). Cette évolution peut s'expliquer par la perte rapide de contrôle en fin de game, avec peu de possibilités de revenir. D'autres émotions restent présentes, comme le contentement passif (10,3%), l'enthousiasme contraint (3,4%) et la joie/exaltation (4,1%). Ces émotions peuvent être liées au début de l'endgame, où les joueurs tentent encore d'inverser la tendance. Cette tentative fonctionne partiellement, mais devient rapidement limitée par l'écart entre les deux équipes.

Globalement, l'endgame permet de capter une plus grande diversité d'émotions. Cela semble lié à la pression de fin de game et à un dénouement de plus en plus difficile à éviter. La méthode permet donc d'identifier les grandes tendances émotionnelles, même si elle reste limitée pour distinguer précisément les nuances entre émotions.

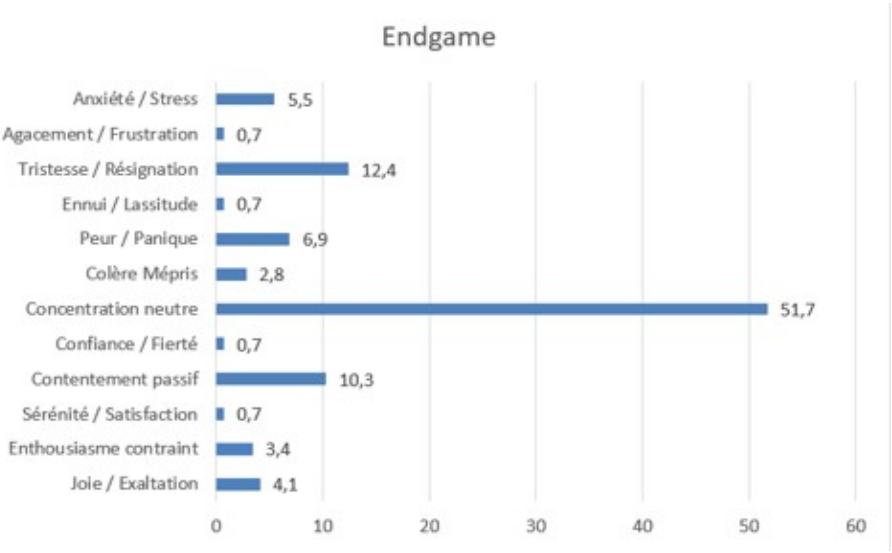


FIGURE 19 – Émotions en endgame

En conclusion, cette métrique fonctionne globalement bien pour obtenir une première interprétation des émotions. Elle présente toutefois certaines limites, liées notamment aux choix arbitraires effectués lors de l'association entre scores PAD et émotions. Cette méthode permet donc une lecture directe des tendances émotionnelles, mais ne couvre pas toutes les nuances que peuvent exprimer les joueurs.

8.2 Résultat annotation automatique

Tout d'abord, les scores PAD, initialement compris entre 0 et 1, ont été convertis sur une échelle de 1 à 7 afin de correspondre à notre annotation manuelle. Pour cela, nous avons appliqué une formule de mise à l'échelle : $6x + 1 = y$; $x \in [0, 1]$, $y \in [1, 7]$. Nous avons ensuite repris la même démarche d'analyse, en étudiant l'évolution des scores PAD selon l'ordre des segments audio au cours de la game. Enfin, nous analyserons l'écart entre les scores annotés manuellement et ceux prédits par le modèle.

8.2.1 Résultats PAD

Pour analyser les scores, nous allons les superposer afin d'évaluer la proximité entre les scores annotés manuellement et ceux prédits par le modèle. Les scores ne pourront pas être strictement identiques, car l'annotation manuelle utilise des valeurs entières, tandis que le modèle produit des valeurs décimales. L'analyse sera donc approximative. L'objectif est d'observer si l'enveloppe globale des scores prédits suit la même tendance que celle des scores annotés manuellement.

Pour le score de Plaisir (cf. figure 20), le modèle prédit majoritairement des valeurs proches de la moyenne, autour de 4. En pré-game, le modèle capte certains pics de Plaisir, même s'ils ne correspondent pas toujours aux mêmes segments audio que l'annotation manuelle. En early game, les scores sont très proches entre les deux approches. En midgame, le modèle détecte davantage de valeurs proches de 7, donc très positives, par rapport à notre annotation manuelle. Il identifie aussi quelques valeurs proches de 1, mais moins fréquemment que dans l'annotation manuelle. En endgame, le modèle prédit surtout des valeurs moyennes, autour de 4, alors que notre annotation manuelle tend davantage vers des valeurs proches de 1.

Les valeurs restent globalement proches en pré-game et early game, mais des écarts apparaissent sur certains pics en midgame et endgame : le modèle identifie des variations différentes de l'annotation manuelle, parfois même des pics là où celle-ci indiquait des valeurs moyennes. Le modèle semble donc plus fiable en début de partie que sur ses phases plus avancées.

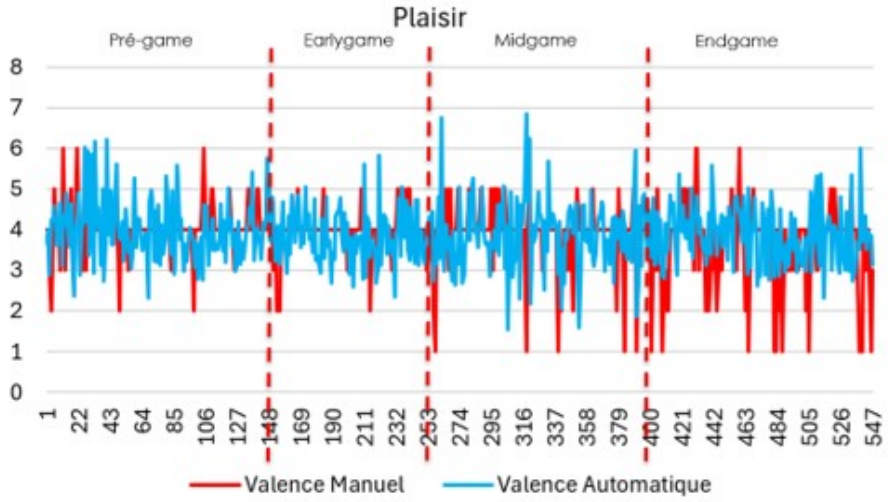


FIGURE 20 – Évolution du Plaisir entre l'annotation manuelle et automatique - 1ère game

Pour le score d'Activation (cf. figure 21), le modèle prédit principalement des valeurs entre 3 et 4, légèrement plus faibles que la moyenne de l'annotation manuelle (proche de 4). En pré-game, le modèle capte bien les petits pics positifs et négatifs. En early game, ses scores sont très proches de l'annotation, bien que légèrement sous-estimés du fait des valeurs décimales produites. En midgame, il identifie correctement les valeurs négatives mais peine à détecter les valeurs positives proches de 5. En endgame, le score reste stable autour de 3, sans capter les forts pics positifs ou négatifs observés dans l'annotation manuelle.

Globalement, les prédictions sont légèrement décalées vers des valeurs plus basses, avec des pics bien détectés en pré-game et early game mais beaucoup moins en midgame et endgame. Une baisse cohérente avec le contexte de fin de partie, où l'équipe perd progressivement.

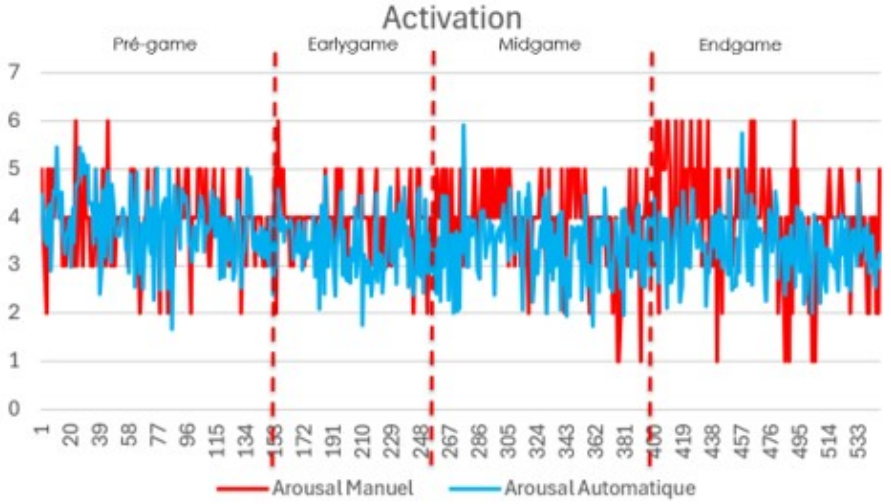


FIGURE 21 – Évolution de l'Activation entre l'annotation manuelle et automatique - 1ère game

Pour le score de Dominance (cf. figure 22), le modèle prédit majoritairement des valeurs proches de 4. Cela correspond globalement à ce qui est observé dans l'annotation manuelle. En pré-game, presque toutes les valeurs sont proches entre les deux approches. Le même constat peut être fait pour l'early game et le midgame, à l'exception de quelques pics significatifs. Dans l'ensemble, les scores restent très proches. En endgame, les écarts deviennent plus importants. Plusieurs pics présents dans l'annotation manuelle ne sont pas captés par le modèle.

Ainsi, pour la Dominance, les prédictions sont assez fidèles à l'annotation manuelle sur la majorité des segments audio. La principale limite apparaît en endgame, où la Dominance perçue devient plus variable. Le modèle ne reflète pas cette variabilité et reste centré autour d'une valeur moyenne proche de 4.

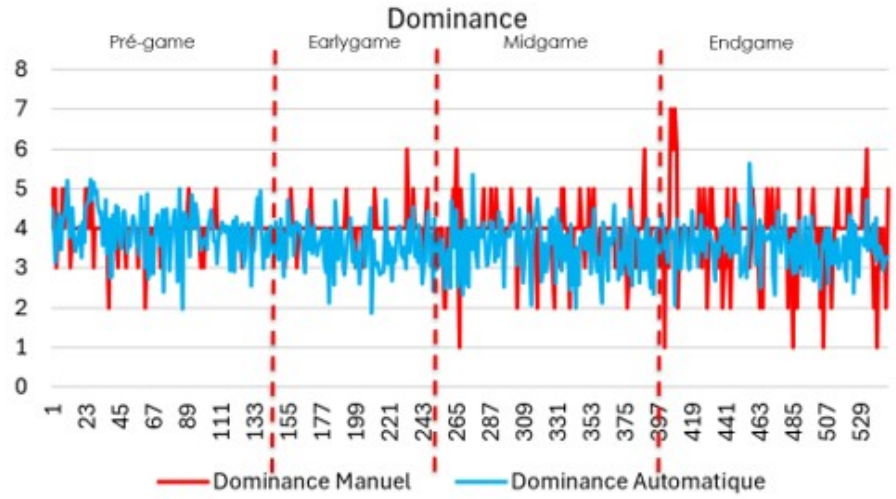


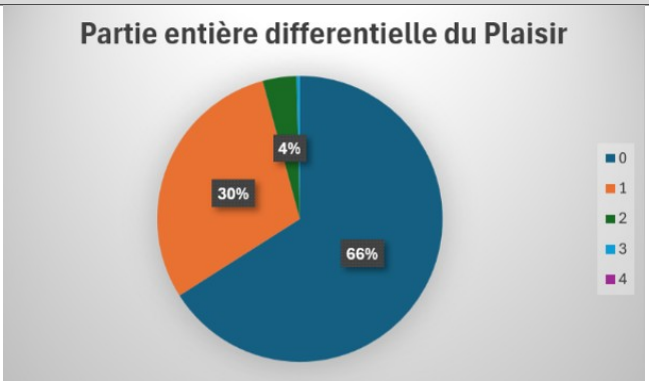
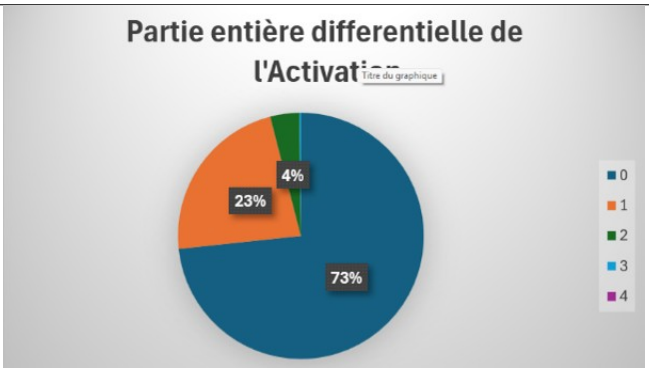
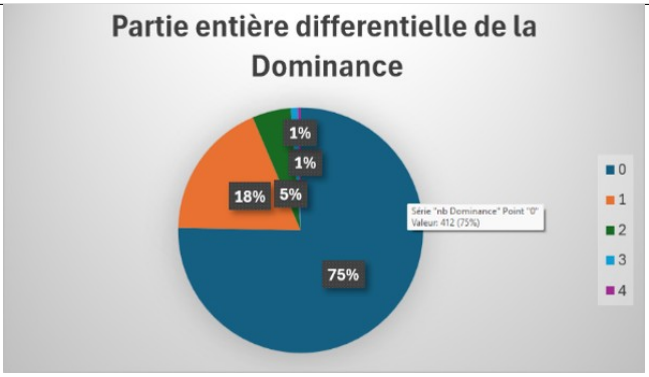
FIGURE 22 – Évolution de la Dominance entre l'annotation manuelle et automatique - 1ère game

Pour conclure sur les résultats du modèle, les scores prédits restent globalement proches des valeurs perçues par l'annotateur. Les prédictions sont souvent centrées autour de la moyenne, ce qui indique que le modèle représente correctement les tendances générales du modèle PAD. Cependant, lorsque les annotations manuelles présentent des variations plus marquées, avec plusieurs pics, le modèle ne capte pas toujours ces changements. Cette limite peut poser problème pour identifier des états comme le stress ou l'énervement, qui sont importants dans une logique de préparation mentale.

8.2.2 Comparaison différentielle

Nous avons ensuite cherché à quantifier plus précisément les écarts entre les scores PAD annotés manuellement et ceux prédits par le modèle. Pour cela, nous avons calculé, pour chaque segment audio, la différence entre le score manuel et le score prédit par le modèle, pour les trois dimensions Plaisir, Activation et Dominance. La valeur absolue de cet écart a ensuite été conservée, puis ramenée à sa partie entière. Cette approche permet d'évaluer l'amplitude des différences entre les deux annotations, indépendamment du sens de l'écart.

TABLE 9 – Comparaison des scores PAD entre annotation manuelle et prédiction du modèle

Score	Écarts	Figure
Plaisir (Valence)	Le modèle présente un écart nul avec l'annotation manuelle dans 66% des cas. Dans 30% des segments audio, l'écart est de 1 point. Les écarts plus importants restent limités, avec seulement 4% des segments audio présentant un écart supérieur à 2 points.	
Activation	Le modèle présente un écart nul avec l'annotation manuelle dans 73% des cas. Dans 23% des segments audio, l'écart est de 1 point. Les écarts plus importants restent limités, avec seulement 4% des segments audio présentant un écart de 2 points.	
Dominance	75% des segments audio présentent un écart de 0 point entre le modèle et l'annotation manuelle. 18% des segments audio ont un écart de 1 point, et 5% présentent un écart de 2 points. Des écarts plus importants restent rares, avec environ 1% des segments audio atteignant un écart de 3 à 4 points.	

Globalement (cf. 9), le modèle présente un écart nul avec l'annotation manuelle pour plus de 2/3 des scores. Les valeurs prédites sont donc très proches des valeurs annotées manuellement, ce qui permet d'être confiant pour la suite du projet. Environ 20% des scores présentent un écart de 1 point. Cet écart reste limité, notamment au regard de la subjectivité de l'annotation manuelle et du fait que le modèle a été entraîné sur un dataset différent. Le score de Plaisir obtient la moins bonne performance. Cela peut s'expliquer par la difficulté du modèle à interpréter et percevoir cette dimension. À l'inverse, le score de Dominance présente la meilleure performance globale, mais aussi quelques écarts importants. Ces écarts peuvent être liés à la difficulté de l'annotateur à percevoir précisément les nuances de ce score. Enfin, le score d'Acti-

vation reste également proche de l'annotation manuelle. Cela peut s'expliquer par des features plus directement liées à cette dimension, et donc plus simples à interpréter pour le modèle.

8.3 Features interprétables

Dans un premier temps, nous allons reprendre l'ensemble des features interprétables sélectionnées afin de comparer les joueurs entre eux. L'objectif est d'identifier, pour chaque feature, les joueurs qui se différencient le plus. Ensuite, nous analyserons les features qui nous semblent les plus pertinentes, en observant leur évolution au cours du match pour chaque joueur. Nous étudierons également les tendances générales entre les différentes phases de la partie. Enfin, nous comparerons notre analyse avec l'annotation manuelle afin d'évaluer s'il existe une corrélation.

8.3.1 Résultats factuels

Nous avons décidé de représenter les données sous forme de violin plots afin de visualiser plusieurs informations à la fois : la moyenne des données, leur dispersion, ainsi que leur répartition volumique (cf. figure 23).

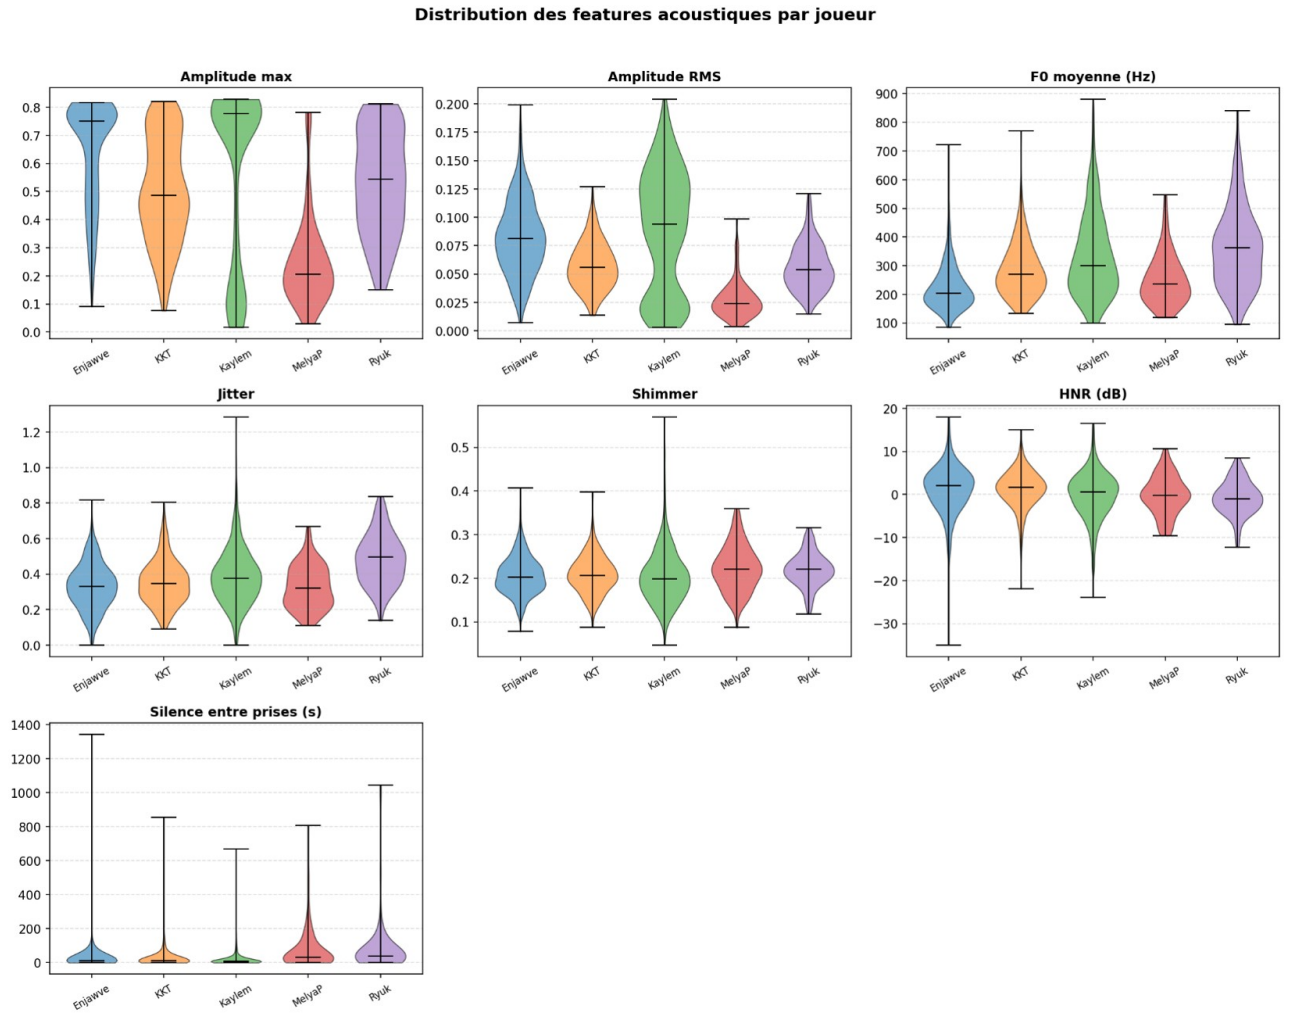


FIGURE 23 – Distribution des features acoustiques par joueur

Amplitude max : Nous pouvons remarquer que les moyennes diffèrent selon les joueurs. Pour Enjawe et Kaylem, les moyennes sont assez élevées, autour de 0,75. De plus, les données sont relativement regroupées autour de cette moyenne, même si certaines valeurs extrêmement basses se situent en dessous de 0,1. À l'inverse, pour KKT et Ryuk, les moyennes sont plus faibles, autour de 0,5, avec une répartition des données plus disparate. Enfin, MelyaP présente la moyenne la plus faible, autour de 0,2. La majorité des données reste proche de cette moyenne, mais quelques valeurs extrêmement hautes apparaissent autour de 0,8.

Amplitude RMS : Nous pouvons remarquer que les moyennes diffèrent selon les joueurs. Pour Kaylem, la moyenne se situe autour de 0,09, avec une répartition assez disparate. On observe également une légère sous-concentration autour de 0,02. Pour les autres joueurs, la répartition est plus uniforme et semble suivre une forme proche d'une distribution gaussienne. Les moyennes sont décroissantes : Enjawe se situe autour de 0,08, KKT et Ryuk autour de 0,055, tandis que MelyaP présente la moyenne la plus faible, autour de 0,025.

Fréquence moyenne : Pour la fréquence moyenne, les joueurs présentent tous une répartition des données assez uniforme, avec une forme proche d'une bouteille. Les moyennes décroissent de manière linéaire entre les joueurs. Ryuk présente la moyenne la plus élevée, autour de 360 Hz, suivi de Kaylem avec 300 Hz, KKT avec 270 Hz, MelyaP avec 240 Hz, puis Enjawe avec 200 Hz.

Jitter : Pour le Jitter, nous remarquons que la plupart des moyennes sont proches, autour de 0,3, à l'exception de Ryuk, qui présente une moyenne plus élevée, autour de 0,5. Les répartitions sont globalement assez similaires entre les joueurs, sauf pour MelyaP, dont la distribution se distingue davantage. De plus, Kaylem est le seul joueur à présenter des valeurs extrêmement hautes, supérieures à 1,2.

Shimmer : Pour le Shimmer, toutes les moyennes se situent autour de 0,2. Les répartitions présentent toutes une forme plus ou moins gaussienne, ce qui indique une distribution assez similaire entre les joueurs. De plus, Kaylem est le seul joueur à présenter des valeurs extrêmes proches de 0,6.

HNR : Pour le HNR, les moyennes se situent toutes autour de 0, et les répartitions suivent globalement une forme gaussienne. Trois joueurs présentent cependant des valeurs extrêmement basses : Enjawe avec une valeur minimale autour de -37, KKT autour de -22, et Kaylem autour de -24.

Temps entre les prises de parole : Pour le temps entre les prises de parole, la plupart des moyennes sont proches de 0 s, avec des répartitions ayant toutes une forme de bouteille. Seuls MelyaP et Ryuk présentent des temps assez élevés entre les prises de parole, avec une moyenne autour de 50 s. Cela semble logique, car ils prennent moins souvent la parole. Ainsi, si leurs interventions sont réparties tout au long du match, le temps entre chaque prise de parole est naturellement plus long. On observe également quelques valeurs extrêmes, mais elles ne nous intéressent pas particulièrement dans cette analyse.

Donc, nous allons retenir plus particulièrement les features liées à l'amplitude RMS, à la fréquence moyenne, au Jitter, ainsi qu'à la durée entre les segments audio des joueurs. Ces features semblent être celles qui présentent le plus de différences entre les joueurs, et sont donc les plus pertinentes pour la suite de l'analyse.

8.3.2 Comparaison avec l'évolution du match

Nous allons donc analyser l'évolution de ces features tout au long de la partie pour chaque joueur : l'amplitude RMS, la fréquence moyenne, le Jitter et la durée entre les segments audio. L'objectif est d'observer comment ces features varient au cours du match, et d'identifier d'éventuelles différences de comportement entre les joueurs.

Nous pouvons remarquer (cf. figure 24) que Kaylem est le joueur avec l'amplitude moyenne la plus élevée, avec régulièrement des pics au-dessus de 0,150. Enjawe présente également des hausses d'amplitude régulières, surtout lors de la pré-game. À l'inverse, MelyaP est le joueur avec l'amplitude la plus faible tout au long du match. Pour les autres joueurs, aucun changement significatif n'est observé. En comparant ces résultats avec le déroulement des différentes phases, on remarque que durant la pré-game, les joueurs venaient de se retrouver. Ils étaient donc globalement joyeux et parlaient plus fort, ce qui peut expliquer les amplitudes plus élevées.

Ensuite, durant l'early game et la midgame, les joueurs se sont exprimés moins fortement. Cela peut s'expliquer par une phase de concentration plus importante, mais aussi par le fait qu'ils étaient en train de perdre le match.

Enfin, durant l'endgame, les joueurs semblent d'abord avoir eu un regain d'énergie pour tenter de revenir dans le match. Puis, l'énervement lié à la défaite finale peut expliquer l'augmentation de l'amplitude moyenne en fin de match.

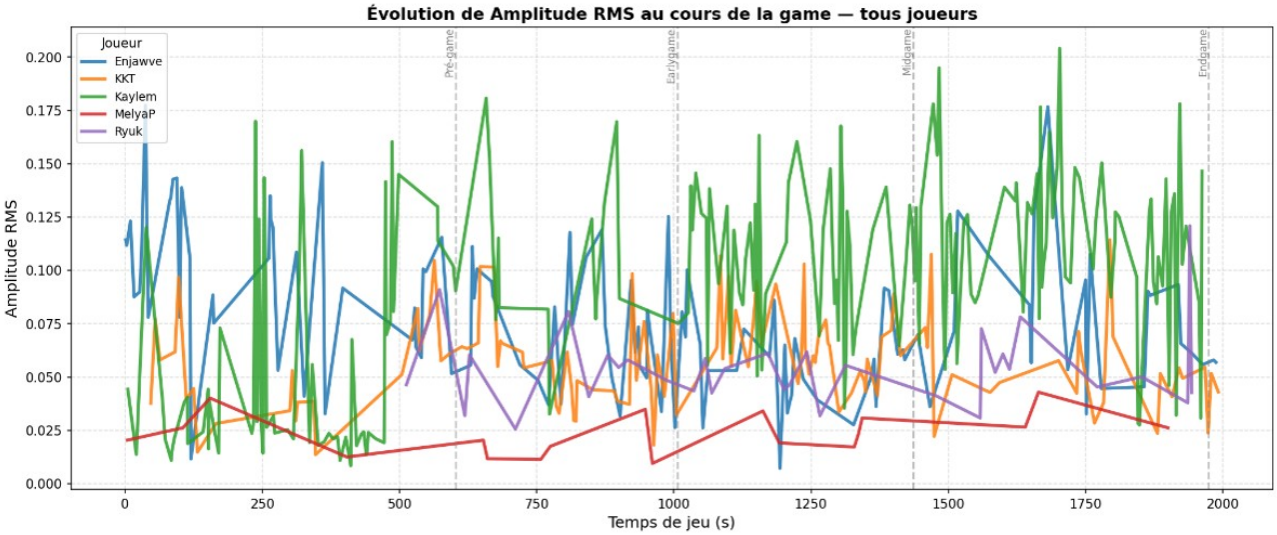


FIGURE 24 – Évolution de l'amplitude RMS au cours du match

Nous remarquons que, lors de la pré-game (cf. figure 25), Kaylem présente régulièrement des pics de fréquence très élevés, dépassant les 500 Hz. Ces observations peuvent s'expliquer par le contexte des différentes phases du match. Lors de la pré-game, les joueurs étaient globalement joyeux, ce qui a pu entraîner des rires et des prises de parole plus enjouées. Cela explique probablement les pics fréquentiels observés.

Ensuite, durant l'early game et la midgame, les joueurs ont globalement des fréquences plutôt constantes. Ryuk se distingue cependant par plusieurs hausses de fréquence dépassant également les 500 Hz. De plus, Enjawe présente un pic important aux alentours de 1200 s.

Durant l'endgame, Ryuk, Kaylem et KKT montrent quelques hausses de fréquence, mais celles-ci restent peu significatives. En fin de match, l'énervement lié à la défaite peut également expliquer certaines hausses ponctuelles de fréquence.

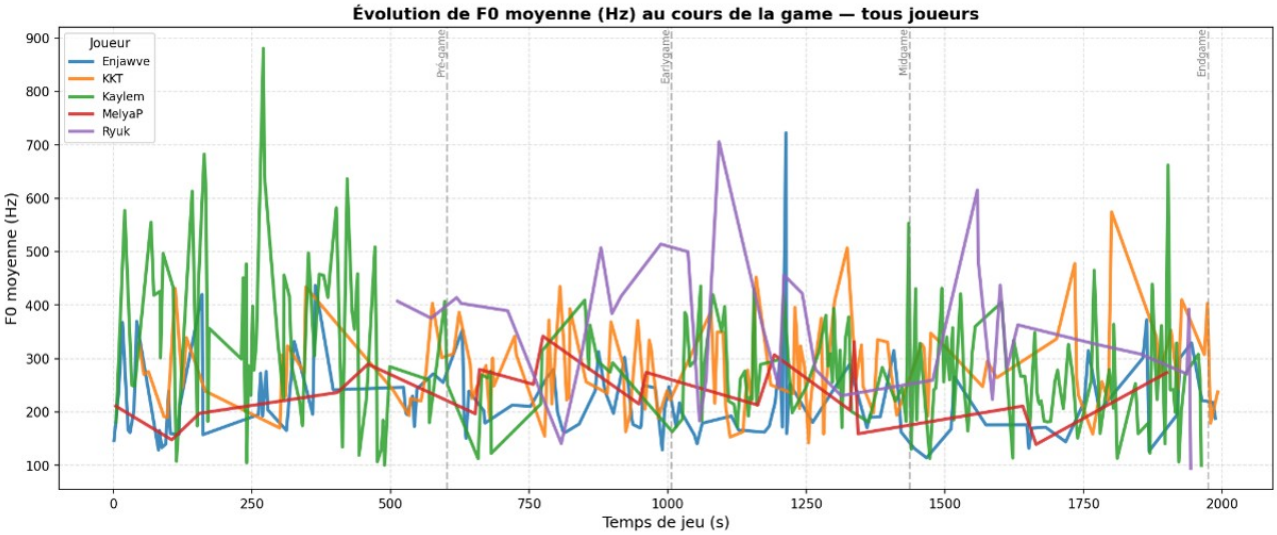


FIGURE 25 – Évolution de la fréquence fondamentale au cours du match

Lors de la pré-game (cf. figure 26), Kaylem présente la plus forte variation fréquentielle dans la voix, avec des valeurs dépassant 0,6. Durant l'early game, c'est Ryuk qui montre le plus de variations, également au-dessus de 0,6. Ensuite, en midgame, KKT présente à son tour les variations les plus importantes, avec des valeurs dépassant aussi 0,6. En fin de partie, ces variations diminuent et deviennent moins marquées.

Il n'y a pas forcément d'explication claire concernant ces changements brusques, ni sur le fait que certains joueurs présentent plus de Jitter à certains moments précis du match. Cependant, nous pouvons être surpris de constater qu'en fin de partie, malgré l'énervement, les variations de fréquence ne sont ni très fréquentes ni particulièrement importantes.

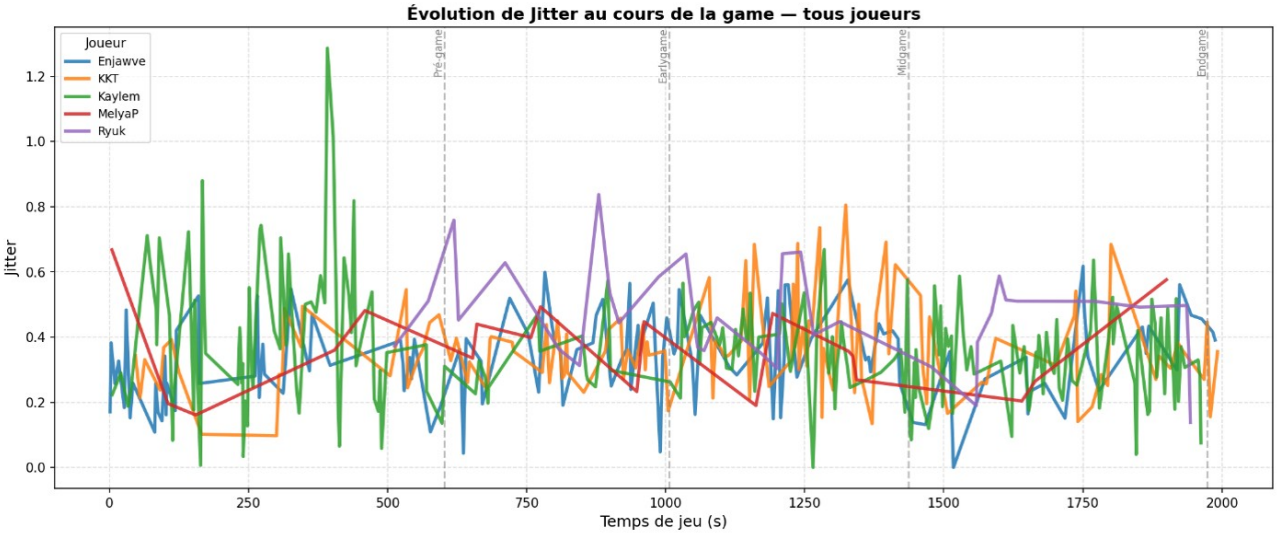


FIGURE 26 – Évolution du Jitter au cours du match

Pour l'évolution de la durée entre les segments audio (cf. figure 27), on observe que les intervalles les plus longs concernent MelyaP, avec un maximum proche de 300 s. Ce résultat est cohérent, car il s'agit du joueur avec le plus faible nombre de segments audio. Durant la pré-game, KKT présente aussi plusieurs blancs importants entre ses interventions. En early game, ces intervalles concernent surtout Ryuk, Kaylem et MelyaP. Cette phase demande davantage de concentration, avec encore peu d'actions en jeu, ce qui peut limiter la prise de parole. En midgame, à l'exception de MelyaP, les joueurs communiquent plus régulièrement. Quelques blancs restent visibles chez Enjawe. En endgame, la communication reste active sur une grande partie de la phase. En revanche, à la toute fin, la plupart des joueurs ne parlent presque plus, probablement en raison de la frustration liée à la défaite. Seuls Kaylem et KKT continuent de communiquer pour tenter de remobiliser l'équipe.

Globalement, MelyaP et Ryuk présentent les blancs les plus importants, tandis que Kaylem et Enjawe communiquent plus régulièrement. La communication apparaît donc déséquilibrée entre les joueurs. Même si certains rôles dans le match favorisent naturellement une prise de parole plus fréquente, les écarts observés suggèrent un problème de communication au sein de l'équipe.

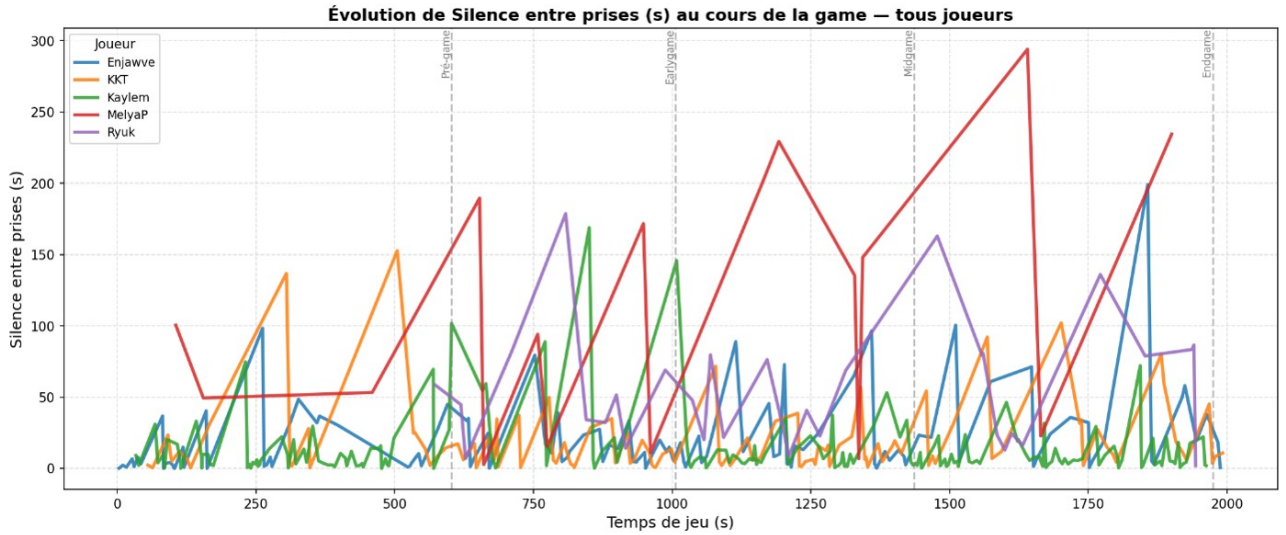


FIGURE 27 – Durée entre les segments audio au cours du match

Pour conclure, ces features sont intéressantes, car elles permettent de capturer certains aspects des émotions durant le match. Les joueurs s'expriment différemment selon les phases de jeu, ce qui apporte du contexte pour mieux comprendre leur état émotionnel.

Bien sûr, ces features ne suffisent pas à déduire une émotion précise à elles seules. Cependant, elles sont complémentaires au score prédit par le modèle et permettent d'avoir une vision plus globale de l'état du joueur à un instant donné.

9 Nouvelle approche envisagée

9.1 Contexte et objectif

Jusqu'à présent, nous avions cherché une solution de clustering supervisé, en combinant différentes méthodes d'extraction de features et de machine learning. Nous avons également exploré une seconde approche : le clustering non supervisé. L'idée est de projeter les données

dans un espace à n dimensions afin d'y repérer d'éventuels clusters et d'en proposer une interprétation. Ces méthodes sont plus hasardeuses, car elles supposent de disposer au préalable d'une bonne interprétation de chaque dimension des données, avant de pouvoir en déduire des patterns explicatifs.

Dans un premier temps, nous avons tenté une approche directe, c'est-à-dire essayer de clusteriser les 88 features eGeMAPS à l'aide des méthodes K-means, SNOW, SOM, DBSCAN, Biclustering et Agglomerative. Nous avons évalué ces différentes méthodes à l'aide des métriques suivantes : elbow method, silhouette score, indice de Davies-Bouldin, indice de Calinski-Harabasz, matrice de confusion du bruit, matrice de confusion des clusters et dendrogramme. Nous avons enfin projeté nos données en 2D grâce aux méthodes PCA et UMAP, afin de vérifier si des clusters s'en dégageaient réellement. Malheureusement, sur l'ensemble de nos données, nous ne parvenions qu'à séparer les locuteurs entre eux : les données n'étant pas suffisamment « propres », les clusters obtenus n'étaient pas nets et les scores des métriques restaient très bas. Nous avons alors tenté de traiter les locuteurs séparément, sans pour autant parvenir à un clustering satisfaisant. Nous avons ensuite essayé de clusteriser à partir des 1024 features Wav2Vec2, mais une fois de plus sans obtenir de clustering propre. Nous sommes néanmoins parvenus, sur l'ensemble de nos données, à isoler les personnes riant entre elles.

Dans un second temps, nous nous sommes tournés vers un jeu de données mieux labellisé et aux enregistrements plus propres : le corpus TESS. Nous avons de nouveau comparé les différentes méthodes de clustering, mais n'avons conservé que celles qui nous semblaient les plus performantes : Agglomerative, Biclustering, K-means et SOM. Nous avons par ailleurs testé deux types d'extraction de features, eGeMAPS et Wav2Vec2, et procédé à une comparaison détaillée entre les deux.

Ce travail s'inscrit ainsi dans une démarche de reconnaissance des émotions à partir de données audio issues du corpus TESS. L'objectif est d'évaluer les méthodes de clustering non supervisé retenues, appliquées à deux jeux de représentations des données (des embeddings Wav2Vec2 et des descripteurs eGeMAPS), afin de déterminer quelle combinaison méthode/jeu de données permet de regrouper le plus efficacement les enregistrements par émotion. Quatre algorithmes de clustering ont été testés pour chacun des deux jeux de données : K-means, la classification ascendante hiérarchique (Agglomerative), le Biclustering, ainsi que les cartes auto-organisatrices (SOM).

9.2 Métriques d'évaluation

Pour comparer objectivement les résultats de clustering, trois métriques ont été définies :

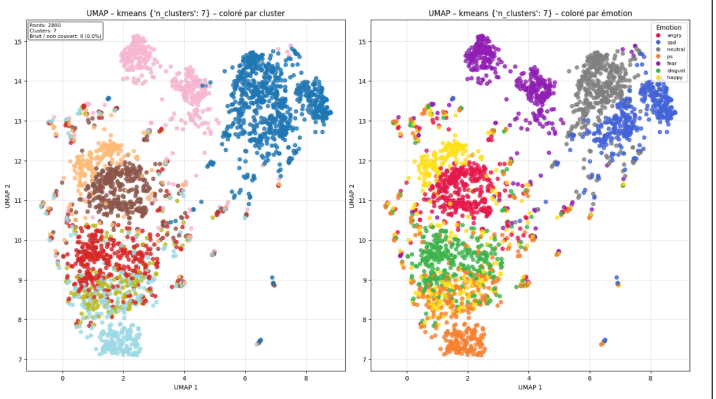
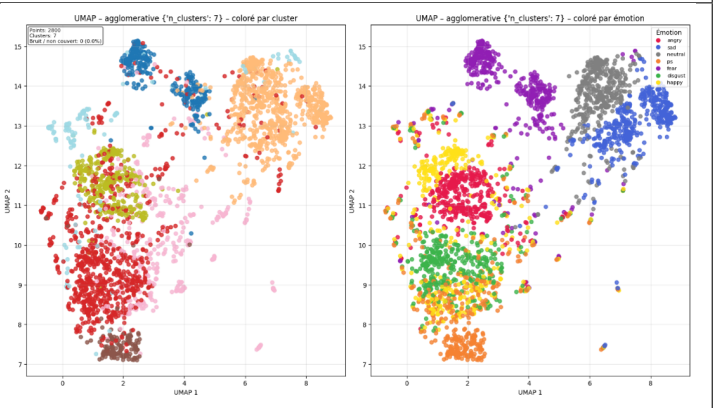
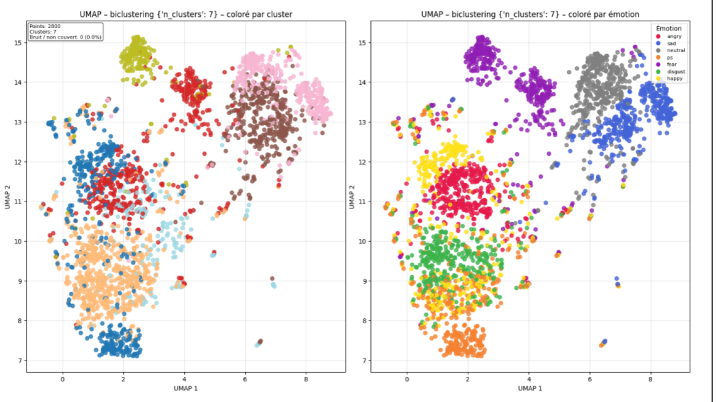
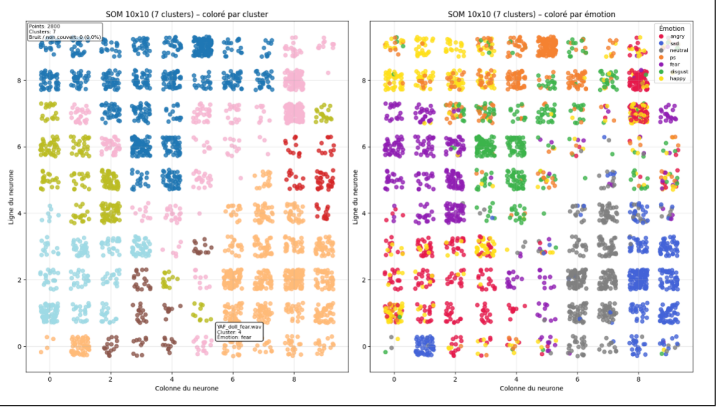
- **La métrique dénombrable** correspond à un tableau récapitulatif indiquant, pour chaque cluster, le nombre d'émotions qui lui sont associées par la méthode.
- **La métrique de précision** indique, pour une émotion donnée, la proportion de ses occurrences totales retrouvée dans chaque cluster (lecture verticale du tableau).
- **La métrique de rappel** (recall) indique, pour un cluster donné, la proportion des données qui appartiennent à une émotion donnée par rapport à l'ensemble des données de ce cluster (lecture horizontale du tableau).

Un bon clustering se traduit par des valeurs de précision et de rappel élevées et concentrées sur un nombre restreint de clusters par émotion.

9.3 Résultats par jeu de données

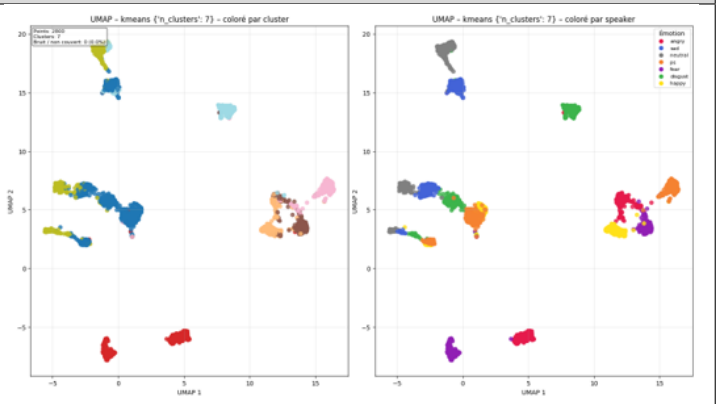
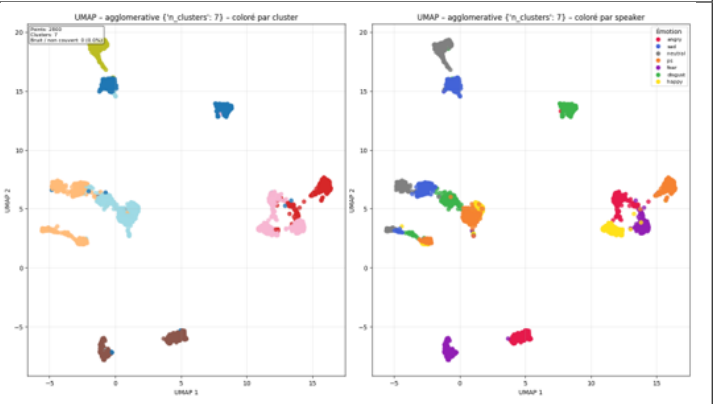
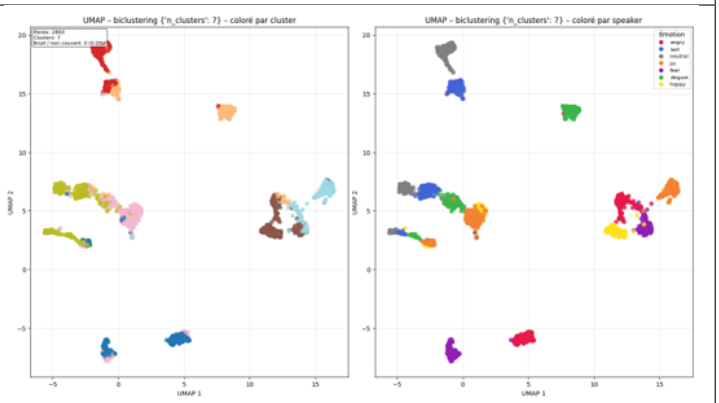
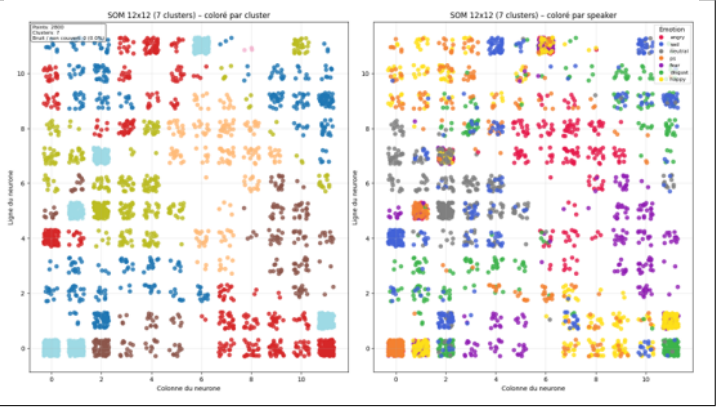
9.3.1 TESS Wav2Vec2

Table 10 – Comparaison des méthodes de clustering avec Wav2Vec2

Méthode	Description	Représentation
K-Means	Association clusters/émotions globalement satisfaisante, à l'exception de Sad et Neutral, regroupées dans un même cluster, et de Happy, répartie équitablement entre deux clusters. (cf. figure 31)	
Agglomerative	Résultats plus dispersés : seules Fear et Pleasant Surprise sont bien isolées, la plupart des autres émotions étant réparties sur trois clusters ou plus. (cf. figure 32)	
Biclustering - SpectralCo-Clustering	Chaque émotion est systématiquement associée à une paire de clusters, sans qu'aucun cluster ne capture une émotion de façon dominante ; la projection UMAP suggère une corrélation avec la présence de deux locuteurs distincts dans le corpus. (cf. figure 33)	
SOM	Bonne isolation de l'émotion Fear, mais les autres émotions restent mélangées entre plusieurs clusters, notamment Sad/Neutral d'une part et Happy/Angry d'autre part. (cf. figure 34)	

9.3.2 TESS eGeMAPS

TABLE 11 – Comparaison des méthodes de clustering avec eGeMAPS

Méthode	Description	Représentation
K-Means	K-means offre les meilleurs résultats du jeu eGeMAPS : l'émotion Neutral y est particulièrement bien isolée (rappel de 66% sur son cluster dédié), et les émotions Pleasant Surprise et Disgust sont également bien captées par des clusters spécifiques. (cf. figure 35)	
Agglomerative	Agglomerative répartit chaque émotion sur deux clusters, avec une confusion notable entre Angry et Fear. (cf. figure 36)	
Biclustering - SpectralCo-Clustering	Biclustering donne les résultats les moins concluants : aucune émotion ni aucun cluster ne se dégage clairement, ce qui indique que cette méthode n'est pas adaptée à ce jeu de données. (cf. figure 37)	
SOM	La méthode SOM isole correctement l'émotion Neutral, les autres émotions restant réparties sur au moins deux clusters. (cf. figure 38)	

9.4 Métrique de comparaison globale

Afin de comparer objectivement l'ensemble des combinaisons méthode/jeu de données à l'aide d'un score unique, une métrique de synthèse a été construite. La moyenne arithmétique des pourcentages de précision et de rappel étant par construction toujours égale à 1, et la moyenne géométrique s'annulant dès qu'une valeur nulle apparaît, une transformation spécifique a été définie pour inverser et redistribuer l'échelle des valeurs (0% devenant 1, 100% devenant 0), tout en pénalisant davantage les distributions dispersées que les distributions concentrées. Cette fonction a été calibrée de sorte que l'écart entre des scores de 80% et 100% soit nettement plus marqué que celui entre 0% et 20%, ces deux derniers cas étant tout aussi inacceptables d'un point de vue opérationnel. Les valeurs transformées sont ensuite agrégées par moyenne géométrique puis normalisées sur une échelle de 0 à 100, avant qu'un score global par méthode ne soit obtenu en calculant la moyenne arithmétique des scores de précision et de rappel ainsi obtenus. (cf. figure 28)

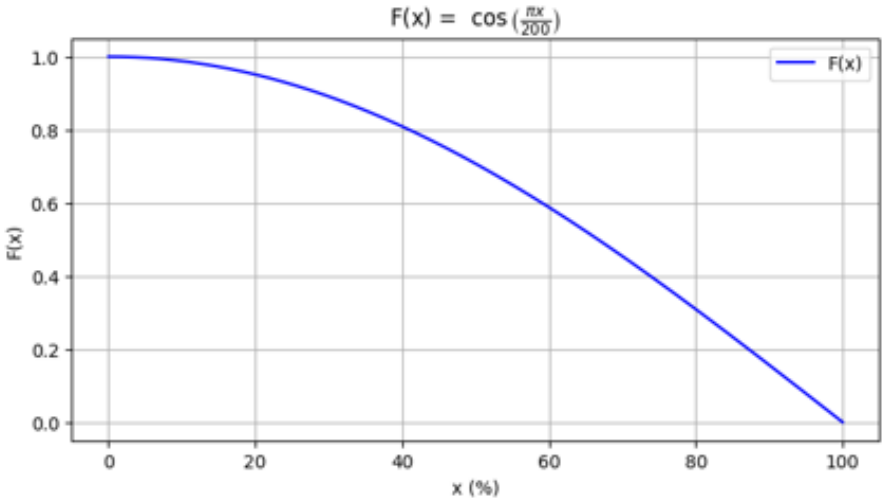


FIGURE 28 – Transformation de rescaling

9.5 Résultats et discussion

L'application de cette métrique de comparaison aux huit combinaisons testées montre que la méthode K-means appliquée au jeu de données Wav2Vec2 obtient les meilleurs résultats globaux. Deux limites subsistent néanmoins : deux clusters distincts sont associés à l'émotion Happy (ce qui reste exploitable, puisque les deux clusters peuvent être réunifiés lors de l'identification), et un cluster confond les émotions Sad/Neutral (rappel de 49% pour ce cluster). Cette dernière ambiguïté peut être levée en s'appuyant en complément sur le jeu de données eGeMAPS, où K-means isole nettement l'émotion Neutral (rappel de 66%) : un enregistrement classé Sad/Neutral par le modèle Wav2Vec2 peut ainsi être désambiguïsé en vérifiant son appartenance au cluster Neutral du modèle eGeMAPS. (cf. figure 29)

		Kmeans	Agglomerative	Biclustering	SOM
eGemaps		51,71%	42,03%	31,42%	41,23%
	happy	44,40%	34,95%	39,45%	36,49%
	sad	65,01%	42,27%	27,38%	27,35%
	neutral	84,94%	47,78%	43,59%	67,83%
	ps	47,14%	37,67%	30,34%	28,16%
	fear	44,38%	38,15%	20,98%	46,47%
	disgust	41,40%	35,90%	30,97%	30,29%
	angry	27,68%	36,98%	22,03%	46,80%
Wav2vec2		87,72%	47,63%	44,91%	51,20%
	happy	46,85%	27,18%	30,05%	27,30%
	sad	100,00%	86,52%	49,70%	96,21%
	neutral	99,05%	76,37%	42,43%	89,25%
	ps	81,94%	26,96%	43,58%	76,23%
	fear	96,69%	47,54%	46,49%	54,38%
	disgust	97,63%	53,52%	64,00%	55,99%
	angry	95,79%	31,11%	41,68%	30,73%

FIGURE 29 – Matrice finale de comparaison

9.6 Bilan

La construction de métriques dédiées (précision, rappel, et un score de comparaison global) a permis de comparer rigoureusement plusieurs méthodes de clustering non supervisé sur deux représentations différentes des données du corpus TESS. Il ressort de cette étude que la combinaison K-means / Wav2Vec2 constitue la meilleure base pour la reconnaissance des émotions, et qu'une approche complémentaire combinant ce modèle avec K-means / eGeMAPS permettrait d'affiner la distinction entre les émotions Sad et Neutral, encore mal séparées par le premier modèle seul.

10 Conclusion

Ce projet a permis d'explorer, dans le domaine de la SER, une problématique originale : comment est-il possible de capter les émotions, a posteriori, de joueurs professionnels de LoL au cours d'un match à partir de leur communication vocale dans une optique de préparation mentale ? Contrairement aux corpus académiques classiques, le contexte eSport impose des contraintes fortes : signal bruité, locuteurs non natifs, segments audio courts, vocabulaire technique et absence de données annotées spécifiques au domaine.

Pour répondre à cette problématique, nous avons construit une démarche en plusieurs étapes. Un protocole de labellisation fondé sur le modèle PAD (Plaisir, Activation, Dominance) a été mis en place et appliqué à une première partie de Lille eSport (543 segments audio annotés), permettant d'obtenir une première base de comparaison. En parallèle, deux familles de features ont été extraites : des features interprétables (prosodiques, spectrales, de qualité vocale) destinées à l'analyse et à la visualisation, et des embeddings issus du modèle Wav2Vec2-Large, utilisés en entrée d'un modèle de régression pré-entraîné pour prédire automatiquement les scores PAD. Les prédictions du modèle ont ensuite été comparées aux annotations manuelles afin d'évaluer sa capacité à généraliser à notre contexte.

Les résultats obtenus sur cette première partie sont encourageants. L'analyse des scores PAD annotés manuellement fait apparaître une évolution cohérente avec le déroulement de la partie, avec une dégradation progressive du Plaisir et de l'Activation en fin de partie, en lien avec la défaite de l'équipe. La comparaison avec les prédictions automatiques montre un accord

satisfaisant : le modèle produit un écart nul avec l'annotation manuelle pour plus de deux tiers des segments audio, notamment sur les dimensions d'Activation et de Dominance, alors même qu'il n'a jamais été entraîné sur des données eSport. Enfin, l'exploration des features interprétables met en évidence des profils vocaux différenciés selon les joueurs, ouvrant une première piste pour caractériser individuellement l'implication ou le stress ressenti en cours de partie.

En complément de cette approche supervisée fondée sur le modèle PAD, une démarche de clustering non supervisé a également été menée sur le corpus TESS, afin d'évaluer si des méthodes de regroupement automatique (K-means, Agglomerative, Biclustering, SOM) permettaient de retrouver une structure émotionnelle cohérente à partir des features eGeMAPS et Wav2Vec2, sans recourir à une annotation manuelle préalable. La construction de métriques dédiées (précision, rappel et un score de comparaison global) a permis de comparer rigoureusement les huit combinaisons méthode/jeu de données testées. Il en ressort que la combinaison K-means / Wav2Vec2 offre les meilleurs résultats, et qu'une approche complémentaire combinant ce modèle avec K-means / eGeMAPS permettrait d'affiner la distinction entre les émotions Sad et Neutral, encore mal séparées par le premier modèle seul. Ces résultats, bien qu'obtenus sur un corpus académique et non sur nos données eSport, valident l'intérêt du clustering non supervisé comme approche complémentaire à l'annotation manuelle, et ouvrent la voie à son application directe sur les features interprétables extraites de nos communications de jeu.

Toutefois, ces résultats reposent sur une seule partie annotée par un unique annotateur, ce qui ne permet pas encore d'évaluer la fiabilité inter-annotateurs, ni la stabilité des tendances observées sur un échantillon plus large de parties et de joueurs. La qualité de la transcription automatique (environ 70% d'erreurs) et la part de segments audio inexploitables limitent également l'analyse du contenu verbal. Par ailleurs, le modèle utilisé reste un modèle généraliste, non fine-tuné sur des données eSport, ce qui explique les écarts observés en milieu et fin de partie, phases pourtant les plus critiques pour la préparation mentale des joueurs.

Ce travail constitue ainsi une première brique méthodologique plutôt qu'une solution aboutie. Plusieurs pistes se dégagent pour la suite : élargir la campagne d'annotation à plusieurs parties et plusieurs annotateurs afin de fiabiliser le protocole et de constituer un véritable dataset d'entraînement spécifique à l'eSport ; envisager un fine-tuning du modèle sur ces données annotées ; appliquer la démarche de clustering non supervisé, validée sur le corpus TESS, directement sur les features interprétables extraites de nos communications de jeu, afin d'identifier des patterns émotionnels récurrents propres au contexte eSport ; et, à plus long terme, enrichir l'approche par une dimension multimodale (voix, jeu, image) afin de gagner en robustesse et en précision. Ces perspectives permettraient de rapprocher progressivement cet outil d'une utilisation opérationnelle par Lille eSport, dans une logique de préparation mentale et de suivi individualisé des joueurs.

Perspectives futures

Mon stage s'inscrit donc dans un projet plus large d'amélioration des résultats sportifs d'une équipe d'eSport sur LoL, ce qui revient, dans l'absolu, à obtenir des résultats concrets sur les performances des joueurs durant les matchs compétitifs. Cependant, au vu du stade encore précoce de ce projet, les premiers résultats concrets risquent de n'être perceptibles que dans un futur lointain.

Malgré cela, mon projet ne constitue qu'une petite partie d'un plan plus large de reconnaissance des émotions à partir de données biométriques (vocales, oculaires, faciales, rythme cardiaque, respiration) et de données de gameplay (position dans la partie, détection du curseur), afin d'obtenir une vision globale des émotions et ressentis des joueurs tout au long du match. Ainsi, à l'avenir, le projet deviendra un projet multimodal, exploitant différentes sources de données.

C'est pourquoi ce projet pourrait être repris dans le cadre d'une étude scientifique, par l'intermédiaire d'un doctorant, qui pourrait orienter son travail selon deux axes. Une première partie technique, portant sur les méthodes d'extraction et d'apprentissage de modèles de reconnaissance des émotions à partir de différents jeux de données. Puis une seconde partie, orientée vers la psychologie comportementale, portant sur la reconnaissance et la définition des émotions humaines. Ainsi, dans un avenir proche, le projet s'orientera vers de la recherche pure, permettant également d'apporter au domaine de nouvelles connaissances pratiques.

Plus concrètement, le projet pourra être poursuivi selon plusieurs axes. Tout d'abord, il conviendra de débuter la campagne de labellisation des données du dataset eSport réel, qui sera utilisé directement pour la reconnaissance des émotions. Ensuite, la recherche pourra également se concentrer sur différentes approches de reconnaissance des émotions et sur leur définition. Puis, davantage de recherche technique pourra être menée afin d'affiner le choix des méthodes d'extraction des données et du modèle d'apprentissage pour la reconnaissance des émotions à partir de celles-ci. D'autres approches pourront également être explorées, comme la recherche de clusters non supervisés afin d'identifier des patterns de regroupement.

Finalement, ce projet ne constitue que le point de départ du projet global. Il sert de tremplin à la construction d'une thèse sur le sujet, dans le but d'apporter de véritables connaissances concrètes à ce domaine.

Analyse éthico-technique

11 Solution

11.1 Raison d'être

La solution repose sur des algorithmes d'IA capables d'analyser les caractéristiques vocales afin d'identifier les états émotionnels tels que le stress, la frustration ou la fatigue des joueurs eSport.

Cette détection pourrait être élargie au monde professionnel, en amont du stress ou de la fatigue chronique. L'objectif est de déceler le mal-être de personnes vulnérables dans différents environnements. Cela constitue une contribution à l'amélioration de la santé mentale et permet de diminuer les risques de troubles cardiovasculaires, de troubles du sommeil, de comportements addictifs ou agressifs, ou encore de troubles musculo-squelettiques. Cette solution s'inscrit dans l'ODD 3 : Bonne santé et bien-être.

Par ailleurs, ce projet peut également avoir un impact économique positif. Si les émotions sont mieux comprises, cela pourrait avoir un effet positif sur les performances en entreprise et aider à la prise de décision en réduisant la part d'impulsivité dans certaines prises de position. Cette solution s'inscrit également dans les ODD 8 et 9 : Travail décent et croissance économique, et Industrie, innovation et infrastructure.

11.2 Valeurs, promesses et pratiques

Les promesses portées par cette technologie sont doubles : une meilleure prévention des risques psychosociaux pour les individus, et une aide à la décision pour les organisations. Les personnes concernées sont en premier lieu les joueurs eSport, et, mais cela peut être élargi aux salariés dans un contexte professionnel. Le but associé à cette solution est la performance mais aussi la prévention, en supposant des pratiques honnêtes de la part des concepteurs, transparence sur l'usage des données, consentement éclairé, anonymisation.

Des usages non programmés restent néanmoins possibles : surveillance continue des salariés, évaluation biaisée de la performance individuelle, ou profilage émotionnel à des fins commerciales. Ces dérives potentielles justifient un encadrement par les pouvoirs publics, qu'il s'agisse de sensibilisation, d'éducation aux outils numériques ou, le cas échéant, de limitation réglementaire (RGPD, futur AI Act européen).

11.3 Limites

Cette solution comporte cependant des limites bien définies. D'un point de vue environnemental tout d'abord, l'analyse de données par IA nécessite une importante capacité de calcul, et donc un coût énergétique élevé pour être performante. Dans une optique de sobriété énergétique, cela pose problème : stocker un grand volume de données et exécuter des calculs lourds ne contribue pas à réduire l'empreinte carbone.

D'un autre point de vue, la collecte d'informations personnelles telles que les émotions des individus et leurs réactions face à certaines situations pose un problème éthique et social. Le consentement préalable des personnes concernées est indispensable, de même que le respect du RGPD sur les données personnelles des utilisateurs. Cela peut devenir problématique en cas de fuite de données, de surveillance de masse, d'évaluation déloyale, de discrimination de certains profils émotionnels ou encore d'atteinte à la vie privée.

Et enfin, d'un point de vue éthique, cette technologie pourrait être perçue comme un outil de manipulation ou de déshumanisation par l'IA. En effet, confier à une machine le soin de décrire nos émotions risque de nous faire perdre l'essence même de la complexité humaine. Dans un monde utopique, l'idée de reconnaître les émotions pourrait créer l'illusion d'agencéité (quand un humain attribue à tort des sentiments ou une conscience à une entité). À terme, nous pourrions assister à l'émergence d'une asymétrie relationnelle : en cherchant à maîtriser ou à modifier les réponses émotionnelles, nous risquerions d'altérer les compétences sociales et relationnelles des individus, ainsi que leur ipséité.

12 Analyse et évaluation

TABLE 12 – Analyse éthico-technique comparative entre analyse des émotions avec l'IA ou sans l'IA

Critère	Avec la SER	Sans la SER
Homme	Détection précoce du stress, de la fatigue et du mal-être. Amélioration du bien-être et de la santé mentale.	Forte demande de psychologues pour l'analyse, avec un temps d'analyse accru. Difficulté à identifier les signes de détresse, de stress chronique et d'épuisement.
Société	Amélioration des performances collectives, prévention des comportements agressifs et aide à la prise de décision.	Persistance des tensions, des conflits et des comportements impulsifs, pouvant dégrader l'environnement de travail ou de jeu.
Éthique	Exploitation de données personnelles potentiellement sensibles, avec des risques de discrimination ou de fuite de données.	Anonymisation des profils et respect d'une charte déontologique par les professionnels de l'analyse psychologique.
Planète	Exploitation énergétique importante liée au stockage des données et aux calculs computationnels.	Aucune dépense énergétique significative, hormis le stockage des enregistrements des matchs joués.

13 Justification et recommandations

Une attention particulière doit être portée à l'exploitation des données. Dans une logique de souveraineté numérique, le stockage des données devrait rester au sein de l'infrastructure de l'entreprise elle-même, afin de garantir qu'elles ne soient ni exploitées ni revendues à des tiers. De plus, l'entreprise proposant ce service de reconnaissance d'émotions doit garantir l'absence de fuite de données lors de son déploiement. Un cadre clair doit donc être établi entre les deux parties prenantes (client et ALTEN) concernant l'usage des données.

Ensuite, dans une logique de réduction de l'empreinte carbone, le choix de modèles d'IA moins coûteux en énergie doit être privilégié, et un arbitrage constant entre performance et coût computationnel doit être recherché.

D'un point de vue déontologique, le respect du consentement et de la vie privée des utilisateurs doit primer sur la performance du système ; d'un point de vue des conséquences, les bénéfices attendus (prévention du stress, amélioration du bien-être) doivent être mis en balance avec les risques de dérive (surveillance, discrimination).

En définitive, ce projet apparaît pertinent d'un point de vue technique et social, dans la mesure où il répond à un réel enjeu de santé publique. Il reste néanmoins risqué d'un point de vue éthique tant qu'aucune garantie de protection des données et de consentement n'est formellement assurée.

Bilan personnel

Ce stage a été pour moi une découverte du milieu de la R&D applicative, avec un sujet à la fois orienté recherche et répondant à des attentes concrètes. J'ai trouvé ce sujet particulièrement intéressant d'un point de vue technique, car il mêlait plusieurs domaines : le traitement du signal, un domaine que je connaissais grâce à l'ENIB, mais également l'intelligence artificielle, un domaine qui m'était moins connu et que j'ai donc dû approfondir de manière autonome, ainsi que la théorie des émotions, totalement inconnue pour moi. Ce stage m'a également permis de développer davantage ma capacité à travailler de manière indépendante, dans un environnement stimulant, composé majoritairement de stagiaires et situé à Toulouse, une ville particulièrement attractive pour de jeunes ingénieurs.
La bonne ambiance de travail m'a permis de créer de réelles relations avec d'autres stagiaires, avec lesquels j'ai partagé des moments extraprofessionnels. Alten est une entreprise intéressante pour développer des sujets innovants et stimulants. Elle offre également plusieurs avantages appréciables, tels que le CSE et les tickets restaurant.

Toutefois, l'environnement de type « grand open space » (plus de 30 personnes dans une même pièce), ainsi que les différents niveaux hiérarchiques présents, m'ont parfois posé problème sur le plan éthique et personnel. Le fait de me sentir régulièrement observé ne m'aidait pas à rester concentré, ni à exprimer pleinement mes idées. Par ailleurs, l'environnement était souvent bruyant, ce qui rendait parfois la concentration difficile.
Les horaires fixes et imposés témoignent d'une certaine rigueur et d'une volonté de l'entreprise de suivre les stagiaires dans leur travail. Je m'interroge néanmoins sur les répercussions que cela peut avoir sur la confiance accordée, ainsi que sur la représentation du métier d'ingénieur. Enfin, mon projet n'étant pas le seul suivi par mes encadrants, j'ai ressenti un manque de retours sur certaines étapes de ma démarche, comparativement aux autres projets. Davantage de feedback m'aurait permis de mieux défendre l'avancement du projet et les idées que je proposais. Cela a néanmoins été un véritable défi de travailler en autonomie et en autoévaluation, un défi que j'ai réussi à relever jusqu'au bout de mon projet.

Ce stage m'a conforté dans l'idée que les sujets liés au traitement du signal appliqué à différents domaines m'intéressent tout particulièrement. De plus, ce stage ne me ferme pas à une évolution future vers le milieu de la recherche scientifique, même si cela reste à définir dans des conditions claires. Par ailleurs, j'ai réalisé que le fait de travailler dans un grand open space nuisait directement à ma productivité. Ce constat me conforte dans l'idée que je m'oriente davantage vers un métier polyvalent, avec des missions se déroulant dans des environnements variés. Enfin, mon envie d'évoluer au sein d'une équipe aux profils variés (ingénieurs, techniciens, ouvriers) traduit un souhait plus large : celui de confronter différentes visions et points de vue sur des projets concrets, où la collaboration entre plusieurs corps de métier est nécessaire.

Bibliographie

[1] Yasser Atif. *Audio-to-Image Encoding for Improved Voice Characteristic Detection Using Deep Convolutional Neural Networks*. 10 mars 2025. DOI : 10.36227/techrxiv.174163928.83517889/v1.

[2] Alexei Baevski et al. *wav2vec 2.0 : A Framework for Self-Supervised Learning of Speech Representations*. 22 oct. 2020. DOI : 10.48550/arXiv.2006.11477. arXiv : 2006.11477.

[3] Iris Bakker et al. "Pleasure, Arousal, Dominance : Mehrabian and Russell revisited". In : *Current Psychology* 33.3 (sept. 2014), p. 405-421. DOI : 10.1007/s12144-014-9219-4.

[4] Amina Belaref et al. *Can AI Decode the Circumplex Model of Affect ? A Data-Driven Study*. Référence incomplète dans le document source (source et année non précisées).

[5] Amina Belaref et al. "Data-Driven Decoding of Russell's Circumplex Model of Affect". In : *IEEE Transactions on Affective Computing* (). Volume, numéro et année non précisés dans le document source.

[6] Nicole A. Beres, Madison Klarkowski et Regan L. Mandryk. "Playing with Emotions : A Systematic Review Examining Emotions and Emotion Regulation in Esports Performance". In : *Proceedings of the ACM on Human-Computer Interaction* 7.CHI PLAY (sept. 2023), p. 558-587. DOI : 10.1145/3611041.

[7] Carlos Busso et al. *The MSP-Podcast Corpus*. 11 sept. 2025. DOI : 10.48550/arXiv.2509.09791. arXiv : 2509.09791.

[8] Li-Wei Chen et Alexander Rudnicky. *Exploring Wav2vec 2.0 fine-tuning for improved speech emotion recognition*. 21 fév. 2023. DOI : 10.48550/arXiv.2110.06309. arXiv : 2110.06309.

[9] Alain de Cheveigné et Hideki Kawahara. "YIN, a fundamental frequency estimator for speech and music". In : *The Journal of the Acoustical Society of America* 111.4 (2002).

[10] Zeeshan Dair, Ruairi Donovan et Ruairi O'Reilly. *Linguistic and Gender Variation in Speech Emotion Recognition using Spectral Features*. 26 oct. 2022. DOI : 10.48550/arXiv.2112.09596. arXiv : 2112.09596.

[11] Cem Doğdu et al. "A Comparison of Machine Learning Algorithms and Feature Sets for Automatic Vocal Emotion Recognition in Speech". In : *Sensors* 22.19 (oct. 2022), p. 7561. DOI : 10.3390/s22197561.

[12] Paul Ekman. "An argument for basic emotions". In : *Cognition and Emotion* 6.3-4 (mai 1992), p. 169-200. DOI : 10.1080/02699939208411068.

[13] Paul Ekman et Wallace V. Friesen. "Constants across cultures in the face and emotion". In : *Journal of Personality and Social Psychology* 17.2 (1971), p. 124-129. DOI : 10.1037/h0030377.

[14] Paul Ekman et al. "Universals and Cultural Differences in the Judgments of Facial Expressions of Emotion". In : (). Référence incomplète dans le document source (journal, volume et année non précisés).

[15] Florian Eyben et al. "The Geneva Minimalistic Acoustic Parameter Set (GeMAPS) for Voice Research and Affective Computing". In : *IEEE Transactions on Affective Computing* 7.2 (avr. 2016), p. 190-202. DOI : 10.1109/TAFFC.2015.2457417.

[16] Florian Eyben et al. “Recent developments in openSMILE, the Munich open-source multimedia feature extractor”. In : *Proceedings of the 21st ACM International Conference on Multimedia*. Barcelona, Spain : ACM, oct. 2013, p. 835-838. DOI : 10.1145/2502081.2502224.

[17] Mireia Farrús, Javier Hernando et Pascual Ejarque. “Jitter and shimmer measurements for speaker recognition”. In : *Interspeech 2007*. ISCA, août 2007, p. 778-781. DOI : 10.21437/Interspeech.2007-147.

[18] Joana Fernandes et al. “Harmonic to Noise Ratio Measurement - Selection of Window and Length”. In : *Procedia Computer Science* 138 (2018), p. 280-285. DOI : 10.1016/j.procs.2018.10.040.

[19] Himanshu Gupta et Divya Gupta. “LPC and LPCC method of feature extraction in Speech Recognition System”. In : *2016 6th International Conference - Cloud System and Big Data Engineering (Confluence)*. Noida, India : IEEE, jan. 2016, p. 498-502. DOI : 10.1109/CONFLUENCE.2016.7508171.

[20] Anjali Jacob. “Speech emotion recognition based on minimal voice quality features”. In : *2016 International Conference on Communication and Signal Processing (ICCSP)*. Melmaruvathur, Tamilnadu, India : IEEE, avr. 2016, p. 0886-0890. DOI : 10.1109/ICCSP.2016.7754275.

[21] Catherine Kerbrat-Orecchioni. *Chapitre 2. Quelle place pour les émotions dans la linguistique du XXe siècle ? Remarques et aperçus*. Référence incomplète dans le document source (source et année non précisées).

[22] Md. Shafiul Khan et al. “CNN-XGBoost fusion-based affective state recognition using EEG spectrogram image analysis”. In : *Scientific Reports* 12.1 (août 2022), p. 14122. DOI : 10.1038/s41598-022-18257-x.

[23] Steven R. Livingstone et Frank A. Russo. “The Ryerson Audio-Visual Database of Emotional Speech and Song (RAVDESS) : A dynamic, multimodal set of facial and vocal expressions in North American English”. In : *PLoS ONE* 13.5 (mai 2018), e0196391. DOI : 10.1371/journal.pone.0196391.

[24] Beth Logan et Chris Ma. *Mel Frequency Cepstral Coefficients for Music Modeling*. Référence incomplète dans le document source (source et année non précisées).

[25] Gowhar Hamid Mohmad Dar et Radhakrishnan Delhibabu. “Speech Databases, Speech Features, and Classifiers in Speech Emotion Recognition : A Review”. In : *IEEE Access* 12 (2024), p. 151122-151152. DOI : 10.1109/ACCESS.2024.3476960.

[26] Avishek Mondal et Sanjay S. Gokhale. “Mining Emotions on Plutchik’s Wheel”. In : *2020 Seventh International Conference on Social Networks Analysis, Management and Security (SNAMS)*. Déc. 2020, p. 1-6. DOI : 10.1109/SNAMS52053.2020.9336534.

[27] Michael Neumann et Ngoc Thang Vu. *Attentive Convolutional Neural Network based Speech Emotion Recognition : A Study on the Impact of Input Features, Signal Length, and Acted Speech*. 2 juin 2017. DOI : 10.48550/arXiv.1706.00612. arXiv : 1706.00612.

[28] M. Kathleen Pichora-Fuller et Kate Dupuis. *Toronto Emotional Speech Set (TESS)*. Borealis, 2020. DOI : 10.5683/SP2/E8H2MF.

[29] Christian Plantin. “Une méthode d’approche de l’émotion dans le discours et les interactions”. In : *SHS Web of Conferences* 81 (2020), p. 01001. DOI : 10.1051/shsconf/20208101001.

[30] Robert Plutchik. “A General Psychoevolutionary Theory of Emotion”. In : *Theories of Emotion*. Elsevier, 1980, p. 3-33. DOI : 10.1016/B978-0-12-558701-3.50007-7.

[31] James A. Russell. "A circumplex model of affect". In : *Journal of Personality and Social Psychology* 39.6 (1980), p. 1161-1178. DOI : 10.1037/h0077714.

[32] James A. Russell et Albert Mehrabian. "Evidence for a three-factor theory of emotions". In : *Journal of Research in Personality* 11.3 (sept. 1977), p. 273-294. DOI : 10.1016/0092-6566(77)90037-X.

[33] P. Sandhya et al. "Spectral Features for Emotional Speaker Recognition". In : *2020 Third International Conference on Advances in Electronics, Computers and Communications (ICAECC)*. Bengaluru, India : IEEE, déc. 2020, p. 1-6. DOI : 10.1109/ICAECC50550.2020.9339502.

[34] Disa A. Sauter et al. "Cross-cultural recognition of basic emotions through nonverbal emotional vocalizations". In : *Proceedings of the National Academy of Sciences of the United States of America* 107.6 (fév. 2010), p. 2408-2412. DOI : 10.1073/pnas.0908239106.

[35] Cong Sun, Hong Li et Lin Ma. "Speech emotion recognition based on improved masking EMD and convolutional recurrent neural network". In : *Frontiers in Psychology* 13 (jan. 2023), p. 1075624. DOI : 10.3389/fpsyg.2022.1075624.

[36] Siqing Wu, Tiago H. Falk et Wai-Yip Chan. "Automatic speech emotion recognition using modulation spectral features". In : *Speech Communication* 53.5 (mai 2011), p. 768-785. DOI : 10.1016/j.specom.2010.08.013.

[37] Preeti Yadav et Vinod Kumar Jain. "MFCC and LPCC Analysis of Speech Signal for Different Languages". In : 4.12 (2017). Nom du journal non précisé dans le document source.

Annexes

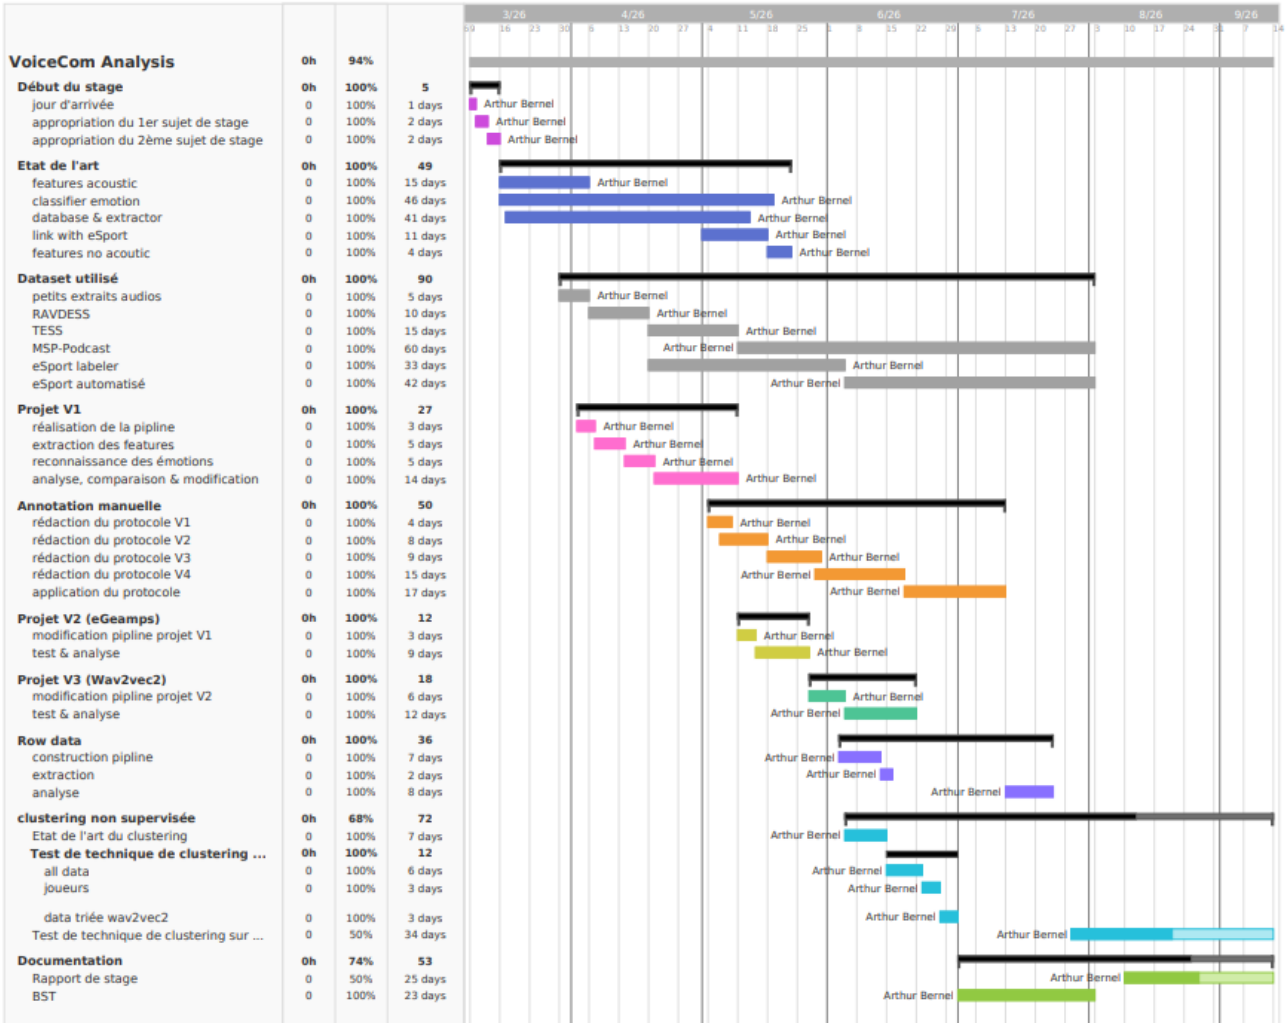


FIGURE 30 – Diagramme de Gantt

Métrique Précision							
Clusters	Happy	Sad	Fear	Neutral	Pleasant Surp	Angry	Disgust
1	0	100	0,75	99,5	0	0	0,25
2	48	0	0	0	0	2,25	0
3	0	0	0	0	7,5	0	98,75
4	2,25	0	1	0,5	0,25	97,75	0,25
5	0	0	98,25	0	0	0	0
6	49,75	0	0	0	2,25	0	0,5
7	0	0	0	0	90	0	0,25

(a) Précision

Métrique Recall							
Clusters	Happy	Sad	Fear	Neutral	Pleasant Surp	Angry	Disgust
1	0	49,87531172	0,374064838	49,62593516	0	0	0,124688279
2	95,52238806	0	0	0	0	4,47761194	0
3	0	0	0	0	7,058823529	0	92,94117647
4	2,205882353	0	0,980392157	0,490196078	0,245098039	95,83333333	0,245098039
5	0	0	100	0	0	0	0
6	94,76190476	0	0	0	4,285714286	0	0,952380952
7	0	0	0	0	99,72299169	0	0,27700831

(b) Recall

FIGURE 31 – Méthode K-Means avec Wav2vec2

Métrique Précision							
Clusters	Happy	Sad	Fear	Neutral	Pleasant Surp	Angry	Disgust
1	0,25	0	69,25	0,25	0	0	0
2	0	92,75	5,25	87	0	0	0
3	46,5	3,75	11	7	41,75	24,5	70,5
4	0	0	0	0	35,5	0	0,25
5	19,5	2	9,25	2,5	16,75	18	22
6	27,75	0	0,25	0,25	0	52	1,25
7	6	1,5	5	3	6	5,5	6

(a) Précision

Métrique Recall							
Clusters	Happy	Sad	Fear	Neutral	Pleasant Surp	Angry	Disgust
1	0,358422939	0	99,28315412	0,358422939	0	0	0
2	0	50,13513514	2,837837838	47,02702703	0	0	0
3	22,68292683	1,829268293	5,365853659	3,414634146	20,36585366	11,95121951	34,3902439
4	0	0	0	0	99,3006993	0	0,699300699
5	21,66666667	2,222222222	10,27777778	2,777777778	18,61111111	20	24,44444444
6	34,04907975	0	0,306748466	0,306748466	0	63,80368098	1,533742331
7	18,18181818	4,545454545	15,15151515	9,090909091	18,18181818	16,66666667	18,18181818

(b) Recall

FIGURE 32 – Méthode Agglomerative avec Wav2vec2

Métrique Précision							
Clusters	Happy	Sad	Fear	Neutral	Pleasant Surprise	Angry	Disgust
1	40,75	0	0	0	46	13	8
2	41,75	0	0	0	49	2	79
3	8,75	0	48,25	3	0	61,75	0
4	0	53,5	0,75	46,75	0	0	0
5	0,25	46,25	0	47,5	0	0,25	0,5
6	0,25	0	49,25	0,25	0	0,25	0
7	8,25	0,25	1,75	2,5	5	22,75	12,5

(a) Précision

Métrique Recall							
Clusters	Happy	Sad	Fear	Neutral	Pleasant Surprise	Angry	Disgust
1	37,819026	0	0	0	42,69141531	12,064965	7,424594
2	24,308588	0	0	0	28,52983988	1,1644833	45,997089
3	7,1868583	0	39,63039	2,4640657	0	50,718686	0
4	0	52,970297	0,7425743	46,287129	0	0	0
5	0,2638522	48,812665	0	50,131926	0	0,2638522	0,5277045
6	0,5	0	98,5	0,5	0	0,5	0
7	15,566038	0,4716981	3,3018868	4,7169811	9,433962264	42,924528	23,584906

(b) Recall

FIGURE 33 – Méthode Biclustering avec Wav2vec2

Métrique Précision							
Clusters	Happy	Sad	Fear	Neutral	Pleasant Surp	Angry	Disgust
1	49	0	0,75	0	87	0	72,25
2	0,75	98	1	94,25	0	0	0,5
3	3,5	1	3	1,75	3	2,75	4,75
4	3,5	0,5	0,5	0,5	1,75	16	0,75
5	19,25	0,5	23,25	3	6,25	36,75	21,5
6	0	0	70,75	0,5	0	0	0
7	24	0	0,75	0	2	44,5	0,25

(a) Précision

Métrique Recall							
Clusters	Happy	Sad	Fear	Neutral	Pleasant Surp	Angry	Disgust
1	23,44497608	0	0,358851675	0	41,62679426	0	34,56937799
2	0,385604113	50,38560411	0,514138817	48,45758355	0	0	0,257069409
3	17,72151899	5,063291139	15,18987342	8,860759494	15,18987342	13,92405063	24,05063291
4	14,89361702	2,127659574	2,127659574	2,127659574	7,446808511	68,08510638	3,191489362
5	17,42081448	0,452488688	21,04072398	2,714932127	5,656108597	33,25791855	19,45701357
6	0	0	99,29824561	0,701754386	0	0	0
7	33,56643357	0	1,048951049	0	2,797202797	62,23776224	0,34965035

(b) Recall

FIGURE 34 – Méthode SOM avec Wav2vec2

Métrique Précision							
Clusters	Happy	Sad	Fear	Neutral	Pleasant Surp	Angry	Disgust
1	49,5	79,25	0	2,25	48	0	43,75
2	46,25	0	2,75	0	0,25	23	0
3	0,5	0	50	0	0,5	50	0
4	3,75	0	45,75	0	0	18	0
5	0	0	1,5	0	50	7	0,5
6	0	15	0	91,75	1,25	0	6,5
7	0	5,75	0	6	0	2	49,25

(a) Précision

Métrique Recall							
Clusters	Happy	Sad	Fear	Neutral	Pleasant Surp	Angry	Disgust
1	22,22222222	35,57800224	0	1,01010101	21,54882155	0	19,64085297
2	64,01384083	0	3,806228374	0	0,346020761	31,83391003	0
3	0,495049505	0	49,5049505	0	0,495049505	49,5049505	0
4	5,555555556	0	67,77777778	0	0	26,66666667	0
5	0	0	2,542372881	0	84,74576271	11,86440678	0,847457627
6	0	13,10043668	0	80,13100437	1,091703057	0	5,676855895
7	0	9,126984127	0	9,523809524	0	3,174603175	78,17460317

(b) Recall

FIGURE 35 – Méthode K-Means avec eGempas

Métrique Précision							
Clusters	Happy	Sad	Fear	Neutral	Pleasant Surp	Angry	Disgust
1	0	47,5	1,25	1,25	0,25	2,25	50
2	11,75	46,5	0,25	49,75	10	0	13
3	2	0	7,25	0	49,5	8,25	0
4	0	0	48	0	0,25	48	0,25
5	48	0	42,25	0	0,5	41	0,25
6	0	1	0	48,75	0	0	0,25
7	38,25	5	1	0,25	39,5	0,5	36,25

(a) Précision

Métrique Recall							
Clusters	Happy	Sad	Fear	Neutral	Pleasant Surp	Angry	Disgust
1	0	46,34146341	1,219512195	1,219512195	0,243902439	2,195121951	48,7804878
2	8,952380952	35,42857143	0,19047619	37,9047619	7,619047619	0	9,904761905
3	2,985074627	0	10,82089552	0	73,88059701	12,31343284	0
4	0	0	49,74093264	0	0,259067358	49,74093264	0,259067358
5	36,36363636	0	32,00757576	0	0,378787879	31,06060606	0,189393939
6	0	2	0	97,5	0	0	0,5
7	31,67701863	4,140786749	0,82815735	0,207039337	32,71221532	0,414078675	30,02070393

(b) Recall

FIGURE 36 – Méthode Agglomerative avec eGempas

Métrique Précision							
Clusters	Happy	Sad	Fear	Neutral	Pleasant Surp	Angry	Disgust
1	4,5	0	40,25	1	10,75	44,25	0,25
2	0	27,75	0,5	1,75	0,5	12,75	49,75
3	0	24,25	0	47,5	0	1	1,25
4	49,25	0	21	0,25	0,5	27,25	0
5	42,25	0	10,75	1,75	35,5	5	24
6	3,25	3,5	0,75	47,75	6,25	0	24
7	0,75	44,5	26,75	0	46,5	9,75	0,75

(a) Précision

Métrique Recall							
Clusters	Happy	Sad	Fear	Neutral	Pleasant Surp	Angry	Disgust
1	4,455445545	0	39,85148515	0,99009901	10,64356436	43,81188119	0,247524752
2	0	29,83870968	0,537634409	1,88172043	0,537634409	13,70967742	53,49462366
3	0	32,77027027	0	64,18918919	0	1,351351351	1,689189189
4	50,12722646	0	21,3740458	0,254452926	0,508905852	27,73536896	0
5	35,42976939	0	9,014675052	1,467505241	29,76939203	4,192872117	20,12578616
6	3,801169591	4,093567251	0,877192982	55,84795322	7,30994152	0	28,07017544
7	0,581395349	34,49612403	20,73643411	0	36,04651163	7,558139535	0,581395349

(b) Recall

FIGURE 37 – Méthode Biclustering avec eGempas

Métrique Précision							
Clusters	Happy	Sad	Fear	Neutral	Pleasant Surp	Angry	Disgust
1	12	28,25	0	3,75	20	0	48,25
2	0	0	1,5	0,25	1,5	48	1
3	37,5	43	0,75	3,25	23,5	0,25	32,75
4	0	2,5	49	4,5	0	1,25	12,75
5	0,5	0	0	0	0	0,25	0
6	0,25	26,25	0,25	82,25	5,5	0,5	1,5
7	49,75	0	48,5	6	49,5	49,75	3,75

(a) Précision

Métrique Recall							
Clusters	Happy	Sad	Fear	Neutral	Pleasant Surp	Angry	Disgust
1	10,69042316	25,16703786	0	3,340757238	17,81737194	0	42,9844098
2	0	0	2,870813397	0,4784689	2,870813397	91,86602871	1,913875598
3	26,59574468	30,4964539	0,531914894	2,304964539	16,66666667	0,177304965	23,22695035
4	0	3,571428571	70	6,428571429	0	1,785714286	18,21428571
5	66,66666667	0	0	0	0	33,33333333	0
6	0,214592275	22,53218884	0,214592275	70,60085837	4,721030043	0,429184549	1,287553648
7	24,00482509	0	23,40168878	2,895054282	23,88419783	24,00482509	1,809408926

(b) Recall

FIGURE 38 – Méthode SOM avec eGempas